



小型微型计算机系统
Journal of Chinese Computer Systems
ISSN 1000-1220, CN 21-1106/TP

《小型微型计算机系统》网络首发论文

题目: ReRTG-SLAM: 基于三段式全局优化的实时大规模三维场景重建方法
作者: 陈泽西, 刘健波, 张严辞
DOI: 10.20009/j.cnki.21-1106/TP.2025-0368
收稿日期: 2025-09-15
网络首发日期: 2025-12-16
引用格式: 陈泽西, 刘健波, 张严辞. ReRTG-SLAM: 基于三段式全局优化的实时大规模三维场景重建方法[J/OL]. 小型微型计算机系统.
<https://doi.org/10.20009/j.cnki.21-1106/TP.2025-0368>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

ReRTG-SLAM: 基于三段式全局优化的实时大规模三维场景重建方法

陈泽西, 刘健波, 张严辞

(四川大学 视觉合成图形图像技术国家级重点实验室, 成都 610065)

E-mail: yczhang@scu.edu.cn

摘要: 3D 高斯泼溅 (3DGS) 能实现高保真三维重建却难以实时应用, SLAM 可实时定位建图但对精细渲染关注不足, 二者互补催生了实时高保真三维重建研究, 但现有方法在实时重建场景中常面临性能瓶颈或重建质量缺陷. 本文提出 ReRTG-SLAM 方法: 首先分析 3DGS 与 SLAM 结合方法存在的局部过拟合、场景表达精度不足, 尤其前后帧对过拟合高斯基元重整不足的问题; 其次提出三段式全局优化策略, 在每个关键帧仅优化当前帧与少量强约束历史帧构成的最小相关集, 减少冗余计算; 最后提出帧质量函数, 筛选更多代表性关键帧以更高频触发全局优化, 缓解过拟合并保持全局一致性. 在 Replica, TUM-RGBD 和 Azure 数据集上与多强基线方法对比, 实验结果表明, ReRTG-SLAM 在多数场景中重建质量与性能均优于现有方法, 可有效平衡局部拟合精度、全局一致性与实时性能, 为大规模三维重建提供新解决方案.

关键词: SLAM; 3D 高斯泼溅; 三维重建; 全局一致性; 优化

中图分类号: TP391

文献标识码: A

ReRTG-SLAM: Real-time 3D Reconstruction at Scale Based on Three-stage Global Optimization

CHEN Zexi, LIU Jianbo, ZHANG Yanci

(National Key Laboratory of Fundamental Science on Synthetic Vision, Sichuan University, Chengdu 610065, China)

Abstract: While 3D Gaussian Splatting (3DGS) enables high-fidelity 3D reconstruction, it struggles with real-time applicability; in contrast, SLAM excels at real-time localization and mapping yet falls short in prioritizing high-quality rendering. The complementary strengths of these two techniques have spurred research into real-time high-fidelity 3D reconstruction, but existing methods often face performance bottlenecks or reconstruction quality defects in real-time scenarios. To address these challenges, this paper proposes the ReRTG-SLAM method. First, it analyzes the limitations of existing 3DGS-SLAM integration approaches, including local overfitting, insufficient scene representation accuracy, and particularly the inadequacy of inter-frame information in rectifying overfitted Gaussian primitives. Second, it introduces a three-stage global optimization strategy that, for each keyframe, only optimizes the minimal relevant set composed of the current frame and a small number of strongly constrained historical frames, thereby reducing redundant computations. Finally, it presents a frame quality function to select more representative keyframes, triggering global optimization more frequently to alleviate overfitting and maintain global consistency. Comparative experiments against multiple strong baseline methods on the Replica, TUM-RGBD, and Azure datasets demonstrate that ReRTG-SLAM outperforms existing approaches in terms of both reconstruction quality and performance across most scenarios. It effectively balances local fitting accuracy, global consistency, and real-time performance, thus providing a novel solution for large-scale 3D reconstruction.

Key words: SLAM; 3D Gaussian splatting; 3D reconstruction; Global consistency; optimization

0 引言

近年来, 3D 高斯泼溅(3D Gaussian Splatting, 3DGS)在新

视点合成和显式场景表达中不断展现出潜力, 但其训练过程往往需要离线进行, 难以应用到机器人导航、虚拟/增强现

收稿日期: 2025-09-15 收修改稿日期: 2025-11-25 基金项目: 大规模元宇宙数字化场景构建关键技术研究与应用(2023YFG0122-LH)资助. 作者简介: 陈泽西, 男, 2001 年生, 硕士研究生, 研究方向为计算机图形学; 刘健波, 男, 1971 年生, 博士, 研究员, 研究方向为图形图像处理; 张严辞(通信作者), 男, 1975 年生, 博士, 教授, CCF 专业会员, 研究方向为计算机图形学.

实等实时需求中.与此同时,同步定位与建图(Simultaneous Localization and Mapping, SLAM)技术在大规模环境中进行在线位姿估计与增量式地图构建,却往往对照片级重建关注不足.将 3DGS 与 SLAM 有机结合^[1,2,3,4],既可发挥 3DGS 在渲染与场景表达上的高质量特点,也能借助 SLAM 的实时性与大规模场景适应能力,为大规模三维重建带来新的可能.

Peng 等人提出的 RTG-SLAM^[3]是目前在这一方向上的前沿工作,该方法的出现不仅验证了 3DGS 与 SLAM 在大规模场景上进行融合的可行性,也为大规模场景的高质量 and 低开销重建提供了一个新思路.

然而,在输入视角发生显著变化时,RTG-SLAM 仍会出现重建质量迅速下滑的问题.过度依赖局部优化会使部分高斯陷入过拟合;此外,发生在训练后期的全局优化,消耗时间过多且对累积误差的修正作用有限,难以全面提升整体重建质量与稳定性.

针对上述不足,本文提出了一种基于三段式全局优化策略的大规模三维场景重建方法,即 ReRTG-SLAM (Refined Real-time Gaussian-based Simultaneous Localization and Mapping),致力于在静态环境中实现局部细节的快速适应的同时,兼顾整体场景的一致性与实时性.该方法主要包含两项改进.一方面,提出一种三段式全局优化策略:当检测到新的关键帧时,构建由当前关键帧及相关强约束关键帧组成的最小相关集,并在此集合上进行跳变校正、峰值补偿及曝光保持三段优化.该策略在保证局部细节保真度的同时,有效缓解了局部过拟合现象,并且兼顾了实时性能,提升了系统的整体表现.另一方面,提出了帧质量函数,选取更多具有代表的帧作为关键帧,更频繁地执行全局优化维持场景的一致性.基于高斯泼溅的动态增删机制与周期性全局优化,本文发现多数情况下已能使当前观测与历史观测在几何与外观保持长期稳定、几乎无漂移的一致性状态,即全局一致性,因此在重建结束后无需额外的最终优化.这不仅显著降低了计算成本,也避免了冗余优化在误差较大时可能带来的负面影响,从而提升了重建结果的稳定性与准确性.

1 相关工作

1.1 3D 高斯泼溅

Kerbl 等人^[5]提出了一种基于 3D 高斯泼溅的实时辐射场渲染方法,该方法通过拟合椭球盘来减少渲染计算量,同时保持较高的视觉质量.Chung 等人^[6]通过引入深度正则化优化进一步提高了渲染方法的稳定性和准确性.Yang 等人^[7]提出了一种基于 3D 高斯泼溅的单目动态场景重建方法,该方法利用可变形高斯分布实现了动态场景的高保真重建.尽管 3DGS 在静态场景的重建中取得了显著进展,但在面对连续颜色深度图(RGB-D)输入时,其在线重建的性能和质量仍存在一定的局限性.

1.2 传统 SLAM

在过去的十余年中,利用 RGB-D 相机进行三维重建取得了显著进展.传统方法主要采用显式几何表示,能在大规模场景中实现实时且高精度的在线重建,如点云^[8]、面元^[9,10,11]、Hermite 径向基函数^[12]以及截断有符号距离场^[13,14,15,16,17,18].其中,BundleFusion^[14]通过按需表面重融,ElasticFusion^[11]利用面元表示与彩色深度结

合,DI-Fusion^[19]则借助神经网络对局部几何与不确定性进行整合.

相较于传统方法,神经辐射场(Neural Radiance Fields, NeRF)的引入推动研究者将隐式表征融入 RGB-D SLAM,以实现几何重建与真实感渲染的兼顾.以单一多层感知机进行全场景编码的 iMap^[20]、结合多分辨率特征网格与预训练解码网络的 NICE-SLAM^[21]、基于八叉树结构管理体素隐式表面的 Vox-Fusion^[22]、借助多层次特征网格与哈希网格的 ESLAM^[23]和 Co-SLAM^[24],以及通过神经点云实现体渲染的 Point-SLAM^[25]等,均显著提升了视觉逼真度.然而,这些方法的体渲染往往需要高计算开销和内存需求,导致在处理大规模场景时往往难以保持实时性.

1.3 基于 3DGS 的 SLAM

随着研究的深入,3DGS 技术逐渐应用于 SLAM 领域,催生了多种 3DGS-SLAM 方法.Yan 等人^[4]提出了一种自适应扩展策略,旨在通过动态添加或删除高斯分布,处理 RGB-D 输入序列,并利用从粗到细的技术选择可靠的高斯分布进行跟踪.Matsuki 等人^[2]提出了一种基于高斯分布的 SLAM 方法,该方法通过统一的高斯表示实现了准确、高效的跟踪、建图 and 高质量渲染.Huang 等人^[26]引入了基于高斯金字塔的训练方法,逐步学习多级特征,从而提高了建图的性能.Keetha 等人^[27]提出的 SplatTAM 方法通过可微分渲染和轮廓引导优化策略,将高斯分布应用于密集 RGB-D SLAM,显著提高了目标跟踪和场景重建的效率.尽管这些方法推动了 3DGS 在线重建应用的发展,但在大规模复杂场景中仍面临诸多挑战,如高斯分布的过拟合导致视觉伪影,以及全局一致性不足等问题.

1.4 实时 3DGS-SLAM

近年来,实时 3DGS-SLAM 方法在提升重建效率和质量方面取得了显著进展.Dapeng Feng 等人^[1]提出的 CaRtGS 方法采用自适应计算对齐策略,有效解决了训练不足、长尾优化和弱约束等问题,显著提升了渲染质量和实时性能.Huang 等人^[26]开发的 Photo-SLAM 框架结合了显式几何特征和隐式光度特征,实现了高质量的实时定位与环境重建,展现了良好的实时性能和映射质量.Peng 等人^[3]提出的 RTG-SLAM 通过紧凑的高斯表示和动态优化策略提高了大规模场景的重建效率,并通过局部与全局优化策略确保场景表示的一致性.然而,这些研究在复杂环境中依然可能出现不稳定性或过高的资源需求,难以兼顾大规模场景与动态环境的多样需求.此外,过度依赖局部优化也会导致高斯分布过拟合、产生视觉伪影,甚至出现与真实视角偏差过大的问题,最终影响重建质量.

2 方法

在本节中,首先对现有方法在实际应用中暴露出的不足进行分析;随后,针对这些问题提出改进方法 ReRTG-SLAM,并解释其核心思路,包括提出了基于帧质量评估的关键帧选取策略,以及在最小相关集上执行的三段式全局优化策略.

为更直观地展示本文方法的整体流程,图 1 给出了 ReRTG-SLAM 的整体框架示意图.该框架主要包括了帧质量检测与三段式全局优化两个核心模块.




图 1 ReRTG-SLAM 方法概览。

Fig. 1 Overview of the ReRTG-SLAM method.

2.1 基础知识

近年来,不少以紧凑 3D 高斯泼溅为核心表达的三维重建算法^[2,3,4,5]在运行速度与可视化质量上都有了显著提升。此类方法在接收新的输入帧 I_i 后,会根据其与现有的 3DGS 场景 G_{i-1} 之间的误差(其中 G_{i-1} 表示根据前 $i-1$ 帧输入构建的 3DGS 场景),决定是否插入新高斯基元或更新既有高斯基元的参数,来构建一个更逼近原始场景的。

在大规模环境中兼顾实时性能与整体一致性,不少研究^[1,2,3,4]都引入了关键帧机制。当检测到相机出现较大运动或视差变化时,系统将当前帧 I_i 标记为关键帧 I_i^{key} ;根据关键帧判定的结果,分别使用如下两种优化策略:

- 局部优化:当未检测到关键帧时,利用 I_i 以及相邻连续多个非关键帧带来的信息,系统集中修正 I_i 与邻近帧的高误差部分。这种优化方式能够快速提升细节拟合度,并且实时适应局部环境的变化。由于局部优化只针对 I_i 及其邻近区域进行调整,无需对整个场景的所有高斯基元进行更新,从而获得较高的实时响应能力;
- 全局优化:当检测到关键帧时,系统会整合 I_i 和之前所有关键帧的观测数据,对历史关键帧观测范围内的高斯基元进行整体校正。这一过程有助于修正先前局部优化过程中可能遗留的误差累积,从而确保全局一致性。在重建过程的后期,系统还会利用所有关键帧的观测数据进行一次全局优化,以提高整体场景的重建精度和质量。

2.2 问题分析

上述优化策略存在以下两个问题。

2.2.1 局部过拟合及全局一致性问题

由于关键帧的数量较少,这些算法^[2,3]实质上以局部优化为主,旨在迅速贴合当前或邻近视角下的观测。然而,缺乏对更广范围信息的约束,易使部分高斯基元对局部观测产生过拟合。即便在关键帧到来时进行全局优化,但其频度和覆盖范围往往不足以及时应对局部过拟合带来的累积误差,使得全局几何约束强度不足,最终造成全局一致性缺失,常会出现“漂浮”或“重影”等伪影。

2.2.2 长尾优化冗余

这些方法^[1,2]会在重建结束后进行一次完整的全局优化,以期进一步提高重建精度。然而,如果在早期已经累积了相当规模的误差,单次的最终全局优化往往难以彻底消除这些误差。而更重要的是,为进行最后的整体修正,需要遍历全部关键帧并对所有高斯参数做调整,导致计算量十分庞大,制约了实际应用时的

实时性。若能在重建过程中就持续维护全局一致性,绝大部分误差可被及时抑制或修正,进而无需依赖这一步骤来进行“兜底”式的整体校正。

为了解决上述问题,本文提出在重建过程中更多地引入全局优化减少误差的扩散,以提升全局一致性的思路。首先,本文提出了基于帧质量评估的关键帧选取机制,在这个机制下,有更多帧会被作为关键帧并被纳入全局优化,从而在空间与时间上提供更密集的约束。其次,为了控制对更多的关键帧进行全局优化所导致的性能开销,本文在每个关键帧上,仅在当前关键帧及少量强约束关键帧构成的最小相关集执行优化,并结合三段式优化策略将优化过程拆分为不同阶段,以减少全局优化的性能开销。这样既能更多地触发全局优化,避免误差累积,又能保证计算代价可控,使得最终结果保持全局一致性。

2.3 帧质量函数

在实时三维重建系统中,关键帧选取策略对重建质量与计算效率具有决定性影响。本文从函数逼近理论出发,将三维重建建模为图像平面到三维空间的映射关系:

$$f: \mathbb{R}^2 \rightarrow \mathbb{R}^3, (u, v) \rightarrow (x, y, z) \quad (1)$$

其中图像坐标 (u, v) 通过映射转换为世界坐标 (x, y, z) 。当系统选取 N 个关键帧时,其空间采样点集可表示为:

$$\mathcal{P} = \{P_i = f(u_i, v_i)\}_{i=1}^N \quad (2)$$

根据 Monte-Carlo 积分理论:

$$\iint_{\Omega} g(f(u, v)) d\Omega \approx \frac{|\Omega|}{N} \sum_{i=1}^N g(P_i) + O(N^{-0.5}) \quad (3)$$

该收敛性揭示了采样规模 N 与精度间的权衡,即重建误差以平方根倒数速率衰减,但计算代价随 N 呈三次方增长。这一理论框架为关键帧采样提供了数学基础,同时也凸显了现有策略^[17]的三重缺陷:空间覆盖不足导致未观测区域依赖外插重建,引入系统性偏差;冗余视角使调整复杂度增至 $O(N^3)$,制约了实时性能;相机几何约束强度则受限于基线长度 $\|P_i - P_j\|$ 与深度测量噪声 σ 的耦合效应,根据深度估计差模型:

$$\delta z \propto \frac{\sigma}{\|P_i - P_j\|} \quad (4)$$

短基线会显著放大噪声影响,而长基线虽增强几何约束却可能导致场景覆盖稀疏化。

为了解决上述问题,本文建立了综合帧质量评估体系。当系统接收到输入帧 I_i 时会启动评估流程,根据所有历史关键帧量化其潜在价值,决定是否应被选为关键帧。

系统首先计算当前帧 I_i 可见区域 $\mathcal{A}_i$ 相对于此前已稳定建图区域 Ω 的相对大小,即空间覆盖率 ρ ,量化该帧捕捉到的新场景信息量。数学表达式如式(5)所示:

$$\rho = \frac{\mu(\bigcup_{i=1}^N \mathcal{A}_i)}{\mu(\Omega)} \quad (5)$$

其中, N 表示纳入当前帧的所有关键帧总数量。若 $\rho \rightarrow 1$,意味着该帧观测到了较多未观测到的区域,更有价值被选为

关键帧。

关键帧必须能够为系统提供高质量的几何信息。实际应用中深度测量常伴有噪声 σ ，导致并非所有新视角都能同等有效提升定位与重建精度。关键帧形成的几何构型抑制噪声传播、保证估计稳定性方面至关重要。为此，评估流程需要量化输入帧 I_i 在提供稳健几何约束方面的效能。通过计算其相机位置 P_i 相对于历史关键帧 P_j 的平均基线-噪声比 $\mathcal{B}$ ，如式(6)所示：

$$\mathcal{B} = \frac{2}{N(N-1)\sigma} \sum_{i < j} \|P_i - P_j\| \quad (6)$$

该指标综合了基线长度与噪声水平。因此， $\mathcal{B} \rightarrow 1$ 时表明当前帧 I_i 能提供更强的几何约束力，进而显著提升系统整体的鲁棒性，从而使其成为更优的关键帧选择。

为进一步优化关键帧选择、避免因视角分布不均导致的重建偏差或方向性失真，评估流程还需考量当前帧 I_i 对整体关键帧空间分布均匀性的潜在影响。系统通过计算纳入当前帧后的所有关键帧相机中心点集 $\{c_k\}$ 的协方差矩阵 $\sum_c$ ，并依据其最小及最大特征值之比，得到分布各向异性系数，如式(7)所示：

$$\mathcal{I} = \frac{\lambda_{\min}(\sum_c)}{\lambda_{\max}(\sum_c)}, \quad \sum_c = \frac{1}{N} \sum_{i=1}^N (c_i - \bar{c})(c_i - \bar{c})^T \quad (7)$$

该系数量化了关键帧空间采样的均匀度。当 $\mathcal{I} \rightarrow 1$ 时表明关键帧的分布接近理想的各向同性状态，视角覆盖更为均衡。因此，能够维持或提升 $\mathcal{I}$ 值的候选帧，将被视为更优选择。

系统进而将空间覆盖率 ρ 、平均基线-噪声比 $\mathcal{B}$ 与分布各向异性系数 $\mathcal{I}$ 的独立评估结果，整合为综合性的单一指标，即帧质量函数：

$$\mathcal{Q} = \rho \cdot \mathcal{B} \cdot \mathcal{I}, \quad \hat{\mathcal{Q}} = \min\left(1, \frac{\mathcal{Q}}{\mathcal{Q}_{\max}}\right) \quad (8)$$

该函数能够衡量当前帧 I_i 作为关键帧的整体适宜性，反映了其在满足新信息量、几何强度及分布均衡性等多重标准上的综合表现。为了应用明确的选取准则，系统进一步将 $\mathcal{Q}$ 值进行归一化处理得到 $\hat{\mathcal{Q}}$ 。当 $\hat{\mathcal{Q}} \rightarrow 1$ 时表征系统达到最优采样状态，同时满足覆盖完备性、强几何约束与各向同性分布条件。

2.4 三段式全局优化策略

为了解决全局优化中的性能开销问题，本文提出将全局优化操作拆解为多个阶段，并仅在最相关的关键帧构成的最小相关集上执行优化。通过这种方式，能确保被频繁触发的全局优化的性能开销在可控范围内。

2.4.1 最小相关集构建

为缓解局部过拟合与全局一致性不足，通过帧质量评估选取更多关键帧以强化约束强度，但新增关键帧易含视角重叠或基线不合理的冗余帧，增加计算开销且影响实时性，传统全局优化也未精准筛选关键帧的约束有效性；因此需构建仅含当前关键帧与强约束关键帧的最小相关集，剔除冗余帧，在保证约束有效的同时控制计算量，平衡约束密度与实时重建性能。最小相关集构成如式(9)所示：

$$\mathcal{S}_k = \{k\} \cup \mathcal{N}(k) \quad (9)$$

其中， k 为当前关键帧， $\mathcal{N}(k)$ 为相关的强约束关键帧集合。

从历史关键帧中选择与当前关键帧 k 有较强几何约束的帧，这些帧能有效提供全局优化所需的几何信息。选取标准包括空间覆盖度 $\text{Cov}(N, k)$ 以及基线长度 $\text{Baseline}(N, k)$ ，选取的历史帧 N 满足以下条件：

$$\mathcal{N}(k) = \{N \mid \alpha_1 \text{Cov}(N, k) + \alpha_2 \text{Baseline}(N, k) > \tau\} \quad (10)$$

其中， α_1 和 α_2 是权重系统，分别用于调节空间覆盖度 $\text{Cov}(N, k)$ 和基线长度 $\text{Baseline}(N, k)$ 在评估历史关键帧 N 与当前关键帧 k 之间约束强度时的相对重要性。

2.4.2 三段式全局优化

三段式全局优化按分层递进处理的思路，将传统全局优化中耦合的几何、外观与亮度参数依次分配至三个独立阶段完成优化。通过参数解耦和任务聚焦，可以有效消除跨参数的干扰以保障优化精度，同时减少冗余计算开销，从而高效、稳定地维持全局一致性。

方法将优化过程分为跳变校正、峰值补偿和曝光保持三个阶段，分别优化不同类型的参数。为消除重建场景中产生的“漂浮”或“重影”等结构性伪影，跳变校正阶段 E_1 通过快速修正选中关键帧及其相关高斯基元的几何参数，优先恢复场景的几何准确性，为后续优化提供稳固的结构基础。为了达到此目的，该阶段的优化目标被设定为最小化几何投影误差：

$$E_1 = \min_{X_k} \sum_{i \in \mathcal{S}_k} \|H_i(X_k) - Z_i\|^2 \quad (11)$$

通过调整高斯基元的几何参数 X_k ，确保其通过投影函数 H_i 得到的结果与真实测量值 Z_i 之间的差异最小化。

在场景的几何结构得到初步校正后，渲染误差主要体现在局部的颜色或纹理失真。峰值补偿阶段 E_2 在此基础上，将优化过程完全聚焦于微调高斯基元的外观参数，从而引导优化过程高效、鲁棒地收敛。这一阶段通过优化高斯基元的外观参数 C_k ，最小化外观渲染函数 R_i 的输出与真实测量值 Z_i 之间的外观渲染误差：

$$E_2 = \min_{C_k} \sum_{i \in \mathcal{S}_k} \|R_i(C_k) - Z_i\|^2 \quad (12)$$

场景的几何结构与局部外观均得到有效校正后，为解决不同关键帧之间因相机自动曝光等因素产生的亮度差异，会导致场景中产生视觉伪影，破坏场景的真实感。曝光保持阶段 E_3 引入了曝光控制参数 T_k 表示一个应用于整张渲染图像的全局光度调整，能够暂时将相机曝光伪影与场景的固有外观属性分离，避免了将前者错误归因于后者，从而维护最终重建结果的全局光度一致性与真实感。通过优化此参数，曝光调整函数 I_i 得以对渲染结果进行整体补偿。这一阶段的优化目标为最小化光度误差：

$$E_3 = \min_{T_k} \sum_{i \in \mathcal{S}_k} \|I_i(T_k) - Z_i\|^2 \quad (13)$$

2.4.3 权重分配机制

为了实现这三个阶段在实时优化中的高效协同,系统并未采用固定的资源分配策略,而是依据当前渲染误差的严重程度,引入了一套自适应权重调度机制:

$$\omega_1 = \max\left(0, \frac{H_t - \eta}{\eta}\right) + \beta, \omega_2 = \min\left(1, \frac{H_t}{\eta}\right), \omega_3 = \alpha \quad (14)$$

其中, ω_1 、 ω_2 和 ω_3 分别对应于跳变校正、峰值补偿和曝光保持阶段的执行权重。

该机制以当前关键帧渲染与真实图像之间的最大像素误差 H_t 为核心驱动,并与预设的局部峰值误差阈值 η 相比较,从而将计算资源动态地引导至最关键的修正环节。当出现显著的渲染误差时,主要归因于几何结构的不匹配,因此跳变校正阶段 E_1 以最大像素误差超出阈值作为优先修正几何的强信号,并且权重增量与超出阈值幅度成正比;反之,则表示场景几何结构相对稳定,此时跳变校正阶段的权重降低,将资源转向峰值补偿阶段 E_2 进行外观拟合。曝光保持阶段 E_3 并非是对强烈误差的影响,它是一种持续的正则化步骤,因此 α 确保了在优化时都需要投入一部分基础资源来维护场景的全局光度一致性。

基于此机制,若一次更新计划执行 B 次梯度更新,各阶段迭代次数为:

$$n_i = B \cdot \frac{\omega_i}{\omega_1 + \omega_2 + \omega_3}, i = 1, 2, 3 \quad (15)$$

2.4.4 免除长尾优化的合理性

上述策略显著降低了单次全局优化的计算开销和参数耦合带来的干扰。这种效率的提升是本文整体框架的关键,因为它使得系统能够有效支持由2.3节所述的帧质量函数所驱动的、更频繁的关键帧选取和全局优化触发。

与传统建图过程通常依赖重建结束后利用所有历史关键帧执行一次全局优化来集中消除积累误差、提高全局一致性的做法不同,本文的方法通过这种高频触发、低耗执行的全局优化机制,得以在重建过程中持续地维护场景的全局一致性。每次优化仅针对当前关键帧及强约束关键帧构成的子集,并分阶段处理特定参数,避免了全局参数同时优化带来的复杂性和高计算量。这种设计使得优化过程能够在关键帧之间逐步收敛,有效抑制误差的累积和扩散。

因此,由于全局一致性在重建过程中得到了有效维护,传统方法中为了修正累积误差而进行的大规模最终优化步骤,在本方法中变得不再必要。省略此步骤不仅大幅降低了整体计算负担、保证了系统的实时性能,同时也能获得高质量的重建结果,实现了精度与效率的更优平衡。

3 实验

3.1 实验设置

3.1.1 实验环境

本文所有实验均在一台高性能台式计算机上进行, GPU 配置为英伟达 RTX 4090。系统使用 Python 编程语言实现, 关键计算模块通过 CUDA 加速, 以确保实时性能。本文在

RTG-SLAM^[17]的基础上实现了 ReRTG-SLAM, 并为准确评估所提出策略的改进效果, 本文在测试时对整个系统进行了重新编译和调试, 确保各模块能够高效协同工作。

为确保本文定量评估结果的稳定性并减少潜在异常值的影响, 所有涉及数值指标的实验均在每个测试序列上独立运行了 5 次, 并且最终报告的数值均为这 5 次运行结果的中位数。

3.1.2 数据集

本文使用了三个具有代表性的标准数据集进行实验。Azure 数据集^[3]涵盖了多种室内环境, 如走廊、储藏室和酒店房间等, 场景面积从 43 平方米到 100 平方米不等, 主要用于测试系统在实际应用中的稳定性和实时性能。Replica 数据集^[28]提供了高精度的合成室内场景, 其高质量的 RGB-D 图像使其成为评估系统在几何构建和图像渲染方面准确性的理想选择。TUM-RGBD 数据集^[29]则包含真实世界的 RGB-D 序列和精确的相机位置信息, 是评估 SLAM 系统常用的基准之一。在本文的实验中, 主要使用了该数据集的 fr1_desk、fr2_xyz、fr3_long_office_household 序列, 用于测试系统在复杂环境下的跟踪能力。

3.1.3 基线方法

本文将提出的方法与现有的一些主流 SLAM 方法进行了比较, 包括 RTG-SLAM^[3]、NICE-SLAM^[21]、Point-SLAM^[25]、Co-SLAM^[24]和 ESLAM^[23]。这些方法代表了当前领域内不同的技术路线, 涵盖了从传统几何方法到基于深度学习的神经辐射场方法。为了确保比较的公平性和准确性, 本文采取了各方法的原版实现, 并在相同的实验环境下进行测试, 确保硬件配置和软件环境一致, 排除外部因素对实验结果的潜在影响。

3.2 重建评估

本文在 Azure、Replica 和 TUM-RGBD 数据集上进行了性能和质量评估实验, 评估 ReRTG-SLAM 相较于原始方法的有效性。本文还与其他经典方法进行了对比实验, 以全面评估 ReRTG-SLAM 在不同场景下的性能和质量。

图 2 展示了基准方法 RTG-SLAM 与 ReRTG-SLAM 在三个代表场景中性能与渲染质量的直观对比。

3.2.1 性能评估

本文在该实验中主要比较了不同方法在性能方面的差异, 包括重建速度和内存占用。重建速度通过每秒帧数 (Frames Per Second, FPS) 进行衡量, 该指标反映了系统处理输入数据的实时能力, 通过记录系统处理每一帧所需的平均时间 (Mapper) 得到。而内存占用 (Memory) 则记录运行过程中的峰值内存消耗。

如表 1 所示, ReRTG-SLAM 与各基线的表现在不同序列上各有差异。在内存占用方面, 与 RTG-SLAM 相比内存消耗各有增减, 并未呈现单向的大幅增加或减少。这说明本文引入的优化机制在内存需求上, 与基线方法基本保持同一水

表 1 重建的时间(单位:s)、帧率(单位:FPS)和内存(单位:MB)性能结果.

Table 1 Reconstruction performance results in terms of time(unit: s), frames per second(unit: FPS) and memory(unit: MB).

方法	指标	Replica								TUM-RGBD			Azure
		off0	off1	off2	off3	off4	room0	room1	room2	fr1_desk	fr2_xyz	fr3_long_office_ho usehold	Hotel
NICE-SLAM	Mapper ↓	1.6356	1.5799	1.4836	1.3141	1.2103	1.1505	1.0541	1.3203	12.0457	21.8846	17.5240	1.1552
	FPS ↑	0.61	0.63	0.67	0.76	0.83	0.87	0.95	0.76	0.08	0.05	0.06	0.87
	Memory ↓	10069	10134	11986	10113	10106	11428	11094	12417	12654	13397	12444	13183
Co-SLAM	Mapper ↓	0.1010	0.3000	0.2042	0.1086	0.1055	0.0991	0.1012	0.0999	0.1497	0.1506	0.1585	0.1220
	FPS ↑	9.90	3.33	4.89	9.21	9.48	10.10	9.88	1.00	6.68	6.64	6.31	8.20
	Memory ↓	<u>3683</u>	3684	3683	3690	3687	3688	3684	3681	5003	4743	4182	16551
ESLAM	Mapper ↓	0.1419	0.2324	0.1477	0.1793	0.1415	0.1421	0.1366	0.1411	2.9611	×	2.9686	×
	FPS ↑	7.04	4.30	6.78	5.57	7.07	7.04	7.33	7.07	0.34	×	0.34	×
	Memory ↓	10037	11223	11103	11164	11183	11131	9158	11264	9385	×	20991	×
Point-SLAM	Mapper ↓	2.5893	3.2752	2.7478	2.5115	2.5543	2.7596	2.5766	2.4307	3.7551	3.4624	4.3791	3.6749
	FPS ↑	0.39	0.31	0.36	0.39	0.39	0.36	0.39	0.41	0.26	0.29	0.23	0.27
	Memory ↓	7726	7402	7572	8213	8331	7933	7560	7749	7308	7002	7403	13123
RTG-SLAM	Mapper ↓	0.0597	0.0582	<u>0.0699</u>	<u>0.0726</u>	<u>0.0701</u>	<u>0.0719</u>	0.0665	<u>0.0695</u>	<u>0.0896</u>	<u>0.0696</u>	<u>0.0989</u>	<u>0.1683</u>
	FPS ↑	16.74	17.19	<u>14.29</u>	<u>13.78</u>	<u>14.27</u>	<u>13.91</u>	15.03	<u>14.38</u>	<u>11.15</u>	<u>14.37</u>	<u>10.11</u>	<u>5.94</u>
	Memory ↓	3162	2841	<u>4287</u>	4840	5593	4785	4169	4174	<u>2061</u>	<u>1703</u>	3650	<u>12205</u>
Ours	Mapper ↓	<u>0.0611</u>	<u>0.0618</u>	0.0635	0.0618	0.0660	0.0676	<u>0.0672</u>	0.0692	0.0724	0.0594	0.0789	0.1297
	FPS ↑	<u>16.38</u>	<u>16.17</u>	15.73	16.16	15.15	14.79	<u>14.89</u>	14.45	13.80	16.82	12.67	7.71
	Memory ↓	3645	<u>2928</u>	4738	<u>4705</u>	<u>5405</u>	<u>4539</u>	<u>4107</u>	<u>4058</u>	1912	1678	3521	10594

注. 粗体表示最优值, 下划线表示次优值, “×”表示无法完成重建.

Note: Bold indicates the best result, underline indicates the second-best, and “×” denotes failure to complete the reconstruction.



图 2 RTG-SLAM(第一行)与 ReRTG-SLAM(第二行)性能与渲染质量对比.

Fig. 2 Performance and rendering quality comparison between RTG-SLAM (first row) and ReRTG-SLAM (second row).

平, 并未带来显著的额外负担.

在运行帧率方面, ReRTG-SLAM 在多数测试场景下展现出比其他基线更高的实时处理能力. 尽管在少数几个 Replica 序列中, 帧率略低于 RTG-SLAM 基线, 但整体观察到的趋势是本文方法通常能够有更高的运行速度. 这印证了本文提出的三段式全局优化策略在减少不必要计算、提升效率方面的有效性.

3.2.2 质量评估

为了评估重建结果的视觉质量, 本文采用峰值信噪比 (Peak Signal-to-Noise Ratio, PSNR)、结构相似性指数 (Structural Similarity Index, SSIM) 和学习感知图像块相似度

(Learned Perceptual Image Patch Similarity, LPIPS)作为评价指标. PSNR 主要基于像素误差衡量重建图像与真实图像的相似度, 值越高表示失真越小; SSIM 从亮度、对比度和结构三方面综合评估图像的结构相似性, 值越接近 1 表示结构越相似; LPIPS 则旨在模拟人类视觉系统的感知特性, 评估图像块之间的感知差异, 值越低表示感知上越相似.

如表 2 所示, ReRTG-SLAM 在各主流数据集和多数场景下实现了最优或近似最优的重建质量表现. ReRTG-SLAM 的 SSIM 和 PSNR 指标普遍高于其他基线, 而 LPIPS 指标在所有测试序列上全面领先. 结合图 3 所示的可视化对比, 可以进一步观察到本方法在结构细节和整体纹



图 3 重建质量比较.

Fig. 3 Reconstruction quality comparison

理的还原效果均显著优于其它方案.

这种全方位的质量提升, 是本文核心优化机制共同作用的结果. 一方面, 帧质量函数驱动了更频繁的全局优化触发, 使得系统能够及时整合全局信息并维持一致性; 另一方面, 三段式全局优化策略通过对几何、外观和曝光的解耦调整, 保证了优化的效率与平滑性. 正是这两个机制的协同, 有效缓解了局部过拟合、抑制了误差累积, 并避免了传统方法中容易出现几何错误或感知失真.

3.2.3 相机追踪精度

本文采用广泛使用的绝对轨迹误差(Absolute Trajectory Error, ATE)指标来评估相机追踪的全局精度, 该指标计算估计轨迹与真实轨迹对齐后的均方根误差, 值越低表示估计的相机轨迹与真实轨迹之间的全局偏差越小.

在 TUM-RGBD 数据集上对相机追踪精度的对比结果如表 3 所示. 从整体平均水平来看, 本文方法与 RTG-SLAM 的表现相当, 平均误差仅 0.02cm, 而两者在三个数据集上均明

表 2 重建质量结果.

Table 2 Reconstruction quality results.

方法	指标	Replica								TUM-RGBD			Azure
		off0	off1	off2	off3	off4	room0	room1	room2	fr1_ desk	fr2_ xyz	fr3_long_ office_ household	Hotel
NICE-SLAM	PNSR ↑	25.3	27.2	25.8	25.1	28.7	24.0	24.7	26.1	16.8	17.1	16.6	28.9
	LPIPS ↓	0.354	0.349	0.315	0.348	0.317	0.477	0.407	0.308	0.408	0.343	0.411	0.372
	SSIM ↑	0.876	0.827	0.829	0.761	0.800	0.613	0.766	0.840	0.599	0.639	0.610	0.625
Co-SLAM	PNSR ↑	31.6	33.0	31.4	28.7	30.3	26.6	28.6	28.9	16.2	18.8	18.3	30.7
	LPIPS ↓	0.275	0.242	0.327	0.338	0.302	0.390	0.364	0.309	0.581	0.451	0.561	0.575
	SSIM ↑	0.882	0.884	0.795	0.775	0.857	0.697	0.771	0.829	0.540	0.522	0.519	0.508
ESLAM	PNSR ↑	32.2	<u>33.7</u>	29.4	29.3	31.6	26.6	29.3	30.1	<u>19.2</u>	×	<u>20.0</u>	×
	LPIPS ↓	0.234	0.243	0.279	0.244	0.229	0.340	0.336	0.268	0.405	×	0.375	×
	SSIM ↑	0.897	0.899	0.832	0.829	0.883	0.718	0.780	0.848	0.676	×	0.667	×
Point-SLAM	PNSR ↑	32.6	31.1	30.0	<u>30.8</u>	<u>34.8</u>	<u>32.1</u>	31.6	30.1	18.6	16.2	15.0	29.8
	LPIPS ↓	<u>0.130</u>	<u>0.140</u>	<u>0.211</u>	0.237	0.138	0.160	0.204	0.156	0.590	0.523	0.572	0.541
	SSIM ↑	0.925	0.909	0.872	0.840	0.916	0.849	0.851	0.912	0.456	0.545	0.489	0.523
RTG-SLAM	PNSR ↑	<u>32.8</u>	<u>32.9</u>	<u>31.6</u>	30.2	34.4	30.4	<u>32.1</u>	<u>30.6</u>	18.7	<u>19.3</u>	18.5	<u>31.4</u>
	LPIPS ↓	0.148	0.191	0.238	0.292	<u>0.115</u>	<u>0.155</u>	<u>0.129</u>	0.136	<u>0.441</u>	<u>0.372</u>	<u>0.371</u>	<u>0.413</u>
	SSIM ↑	<u>0.945</u>	<u>0.913</u>	<u>0.925</u>	<u>0.951</u>	<u>0.989</u>	<u>0.944</u>	<u>0.983</u>	0.985	<u>0.769</u>	<u>0.807</u>	<u>0.807</u>	<u>0.913</u>
Ours	PNSR ↑	33.8	34.8	34.2	31.5	37.1	32.6	34.3	32.1	20.4	20.3	20.7	32.5
	LPIPS ↓	0.095	0.135	0.078	<u>0.284</u>	0.111	0.152	0.123	<u>0.142</u>	0.345	0.327	0.324	0.357
	SSIM ↑	0.987	0.987	0.988	0.956	0.989	0.945	0.985	<u>0.981</u>	0.801	0.825	0.843	0.929

表 3 TUM-RGBD 数据集上的追踪精度(单位:cm).

Table 3 Tracking accuracy on the TUM-RGBD (unit:cm).

方法	fr1_ desk	fr2_ xyz	fr3_long_ office_ household	Avg.
NICE-SLAM	2.79	2.52	15.04	6.78
Co-SLAM	3.03	2.11	2.57	2.57
ESLAM	2.53	1.16	2.78	2.16
Point-SLAM	2.67	1.35	4.26	2.76
RTG-SLAM	<u>1.57</u>	0.37	<u>1.09</u>	<u>1.01</u>
Ours	1.56	<u>0.38</u>	1.04	0.99

显优于其他对比方法. 其中, NICE-SLAM 在 fr3_long_office_household 上的误差甚至达到 15.04cm, 而 ReRTG-SLAM 与 RTG-SLAM 的误差均控制在 1cm 附近. 这表明在实现重建质量和效率提升的同时, 本文方法成功保持了与 RTG-SLAM 同等水平的高精度相机追踪性能.

3.3 消融实验

验证两项关键改进对重建效果与性能的综合影响, 本文在 Replica 数据集上进行消融实验, 依次移除 ReRTG-SLAM 的核心模块, 结果如表 4 所示.

若恢复使用 RTG-SLAM 基线优化策略, 仅移除最终全局优化, 虽然平均帧率略有上升, 但重建质量出现显著下滑. 这充分证明基线方法对最终全局优化的依赖, 以及本文通过在线维护全局一致性的策略是成功的. 其次考察了在本文方法基础上额外进行最终全局优化的影响. 数据显示, 重建质量提升极为有限且不一致, 但带来的计算附带却相当显著.

这一实验结果有力地证明了, 本文算法通过在重建过程中持续、高效地维护全局一致性, 能够在无需进行耗时且收益甚微的最终全局优化的情况下, 实现高质量重建与高实时性能的良好平衡, 展现出更优秀的综合表现.

4 结语

本文提出了一种基于三段式优化策略的 3D 重建方法, 旨在提升大规模场景下的实时性能和重建质量. 通过在重建过程中构建最小相关集, 并将优化过程拆解为跳变校正、峰值补偿和曝光保持三个阶段, 本文方法有效降低了计算开销并提高了优化效率. 每次全局优化仅在最相关的参数上进行, 避免了全局优化时参数量膨胀的情况, 从而提高了系统的实时性.

此外, 本文还提出了一种综合帧质量评估体系, 在关键帧选择时结合空间覆盖率、基线-噪声比和分布各向同性等指标, 确保优化过程中约束密集且均匀, 从而提升了全局一致性和细节恢复能力. 实验结果表明, ReRTG-SLAM 在大规模复杂场景中的性能和效率得到了显著提升.

尽管如此, 该方法在应对复杂多变的场景仍存在局限. 具体来说, 场景中的不稳定材质或动态目标将直接导致系统错误地拟合高斯基元, 从而严重破坏解耦的几何与外观矫正目标, 影响优化策略的收敛与效率; 同时, 动态目标或光照变化强烈的环境会引入不一致的几何信息, 导致帧质量评估体系无法准确评估帧的代表性, 并且场景中会出现几何错误或视觉伪影, 降低该方法的鲁棒性. 鉴于此, 提升优化策略的适应性是未来研究的明确目标, 研究将着重于动态变化场景的重建, 进一步拓展该方法的应用范围.

表 4 消融实验结果.
Table 4 Ablation study results.

方法	指标	Replica								Avg.
		off0	off1	off2	off3	off4	room0	room1	room2	
RTG-SLAM	Mapper ↓	<u>0.0597</u>	<u>0.0582</u>	0.0699	0.0726	0.0701	0.0719	<u>0.0665</u>	0.0695	0.0673
	FPS ↑	<u>16.74</u>	<u>17.19</u>	14.29	13.78	14.27	13.91	<u>15.03</u>	14.38	14.85
	PNSR ↑	32.8	32.9	31.6	30.2	34.4	30.4	32.1	30.6	31.8
	LPIPS ↓	0.148	0.191	0.238	0.292	0.115	0.155	0.129	0.136	0.176
	SSIM ↑	0.945	0.913	0.925	<u>0.951</u>	0.989	0.944	<u>0.983</u>	0.985	0.954
Ours	Mapper ↓	0.0611	0.0618	0.0635	0.0618	<u>0.0660</u>	<u>0.0676</u>	0.0672	<u>0.0692</u>	<u>0.0648</u>
	FPS ↑	16.38	16.17	15.73	16.16	<u>15.15</u>	<u>14.79</u>	14.89	<u>14.45</u>	<u>15.43</u>
	PNSR ↑	<u>33.8</u>	<u>34.8</u>	<u>34.2</u>	31.5	<u>37.1</u>	32.6	<u>34.3</u>	<u>32.1</u>	<u>33.8</u>
	LPIPS ↓	0.095	<u>0.135</u>	<u>0.078</u>	<u>0.284</u>	<u>0.111</u>	<u>0.152</u>	<u>0.123</u>	0.142	<u>0.140</u>
	SSIM ↑	0.987	<u>0.987</u>	<u>0.988</u>	0.956	<u>0.989</u>	<u>0.945</u>	0.985	<u>0.981</u>	0.977
w/ Origin Optimization	Mapper ↓	0.0579	0.0581	<u>0.0655</u>	<u>0.0644</u>	0.0671	0.0673	0.0651	0.0677	0.0642
	FPS ↑	17.27	17.16	<u>15.26</u>	<u>15.53</u>	14.90	14.86	15.35	14.76	15.57
	PNSR ↑	30.1	30.6	29.8	26.5	31.7	25.7	28.9	29.2	29.1
	LPIPS ↓	0.172	0.228	0.198	0.461	0.165	0.324	0.208	0.267	0.253
	SSIM ↑	0.936	0.911	0.897	0.868	0.967	0.874	0.956	0.917	0.916
w/ Final Optimization	Mapper ↓	0.0684	0.0668	0.0706	0.0714	0.0729	0.0707	0.0721	0.0726	0.0707
	FPS ↑	14.63	14.97	14.17	14.00	13.71	14.15	13.87	13.78	14.14
	PNSR ↑	34.7	35.1	35.3	<u>31.2</u>	37.9	<u>29.8</u>	34.5	33.3	34.0
	LPIPS ↓	<u>0.102</u>	0.129	0.074	0.261	0.102	0.145	0.119	<u>0.151</u>	0.135
	SSIM ↑	<u>0.985</u>	0.989	0.988	0.948	0.990	0.947	0.979	0.976	<u>0.975</u>

参考文献

[1] Feng D, Chen Z, Yin Y, et al. CaRtGS: computational alignment for real-time gaussian splatting SLAM[J]. IEEE Robotics and Automation Letters, 2025, 10(5): 4340-4347.

[2] Matsuki H, Murai R, Kelly P H J, et al. Gaussian splatting SLAM[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024: 18039-18048.

[3] Peng Z, Shao T, Liu Y, et al. RTG-SLAM: real-time 3D reconstruction at scale using Gaussian splatting[C]//Special Interest Group on Computer Graphics and Interactive Techniques Conference Conference Papers, 2024, doi: 10.1145/3641519.3657455.

[4] Yan C, et al. GS-SLAM: dense visual slam with 3D Gaussian splatting[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024: 19595-19604.

[5] Kerbl B, Kopanas G, Leimkuehler T, et al. 3D Gaussian splatting for real-time radiance field rendering[J]. ACM Transactions on Graphics, 2023, 42(4): 1-17.

[6] Chung J, Oh J, Lee K M. Depth-regularized optimization for 3d gaussian splatting in few-shot images[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2024: 811-820.

[7] Yang Z, et al. Deformable 3D Gaussians for high-fidelity monocular dynamic scene reconstruction[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024: 20331-20341.

[8] Du H, et al. Interactive 3D modeling of indoor environments with a consumer depth camera[C]//13th

International Conference on Ubiquitous Computing, 2011: 75-84.

[9] Kong J, Zhou T, Wang H, et al. Real-time high-accuracy 3D reconstruction based on texture and geometric features[C]//Proceedings of the 41st Chinese Control Conference, 2022, doi: 10.23919/CCC55666.2022.9901893.

[10] Keller M, et al. Real-time 3D reconstruction in dynamic scenes using point-based fusion[C]//International Conference on 3D Vision, 2013, doi: 10.1109/3DV.2013.9.

[11] Whelan T, Salas Moreno R F, Glocker B, et al. Elastic fusion[J]. The International Journal of Robotics Research, 2016, 35(14): 1697-1716.

[12] Xu Y, et al. HRBF-fusion: accurate 3D reconstruction from RGB-D data using on-the-fly implicit[J]. ACM Transactions on Graphics, 2022, 41(3): 1-19, doi: 10.1145/3516521.

[13] Chen J, Bautembach D, Izadi S. Scalable real-time volumetric surface reconstruction[J]. ACM Transactions on Graphics, 2013, 32(4): 1-12, doi: 10.1145/2461912.2461940.

[14] Dai A, Nießner M, Zollhöfer M, et al. BundleFusion: real-time globally consistent 3D reconstruction using on-the-fly surface reintegration[J]. ACM Transactions on Graphics, 2017, 36(4): 1-17, doi: 10.1145/3072959.3054739.

[15] Huang S, et al. Real-time globally consistent 3D reconstruction with semantic priors[J]. IEEE Transactions on Visualization and Computer Graphics, 2023, 29(4): 1977-1991.

[16] Newcombe R A, et al. Kinect fusion: real-time dense surface mapping and tracking[C]//10th IEEE International Symposium on Mixed and Augmented Reality (ISMAR), Basel,

Switzerland,2011:127-136.

[17] Nießner M,Zollhöfer M,Izadi S,et al.Real-time 3D reconstruction at scale using voxel hashing[J].ACM Transactions on Graphics,2013 , 32 (6): 1-10 , doi: 10.1145/2508363.2508374.

[18] Zhang Y,Xu W,Tong Y,et al.Online structure analysis for real-time indoor scene reconstruction[J].ACM Transactions on Graphics,2015,34(5):1-12,doi:10.1145/2768821.

[19] Huang J,Huang S,Song H,et al.DI-fusion: online implicit 3D reconstruction with deep priors[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition,2021,doi: 10.1109/CVPR46437.2021.00882.

[20] Sucar E,Liu S,Ortiz J,et al.iMAP: implicit mapping and positioning in real-time[C]//IEEE/CVF International Conference on Computer Vision,2021:6209-6218.

[21] Zhu Z,et al.NICE-SLAM: neural implicit scalable encoding for SLAM[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition,2022:12776-12786.

[22] Yang X,et al.Vox-fusion: dense tracking and mapping with voxel-based neural implicit representation[C]//IEEE International Symposium on Mixed and Augmented Reality,2022:499-507.

[23] Johari M M,Carta C,Fleuret F.ESLAM: efficient dense SLAM system based on hybrid representation of signed distance fields[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR),2023:17408-17419.

[24] Wang H,Wang J,Agapito L.Co-SLAM: joint coordinate and sparse parametric encodings for neural real-time SLAM[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition,2023:13293-13302.

[25] Sandström E,Li Y,Van Gool L,Oswald M R. Point-SLAM: Dense neural point cloud-based SLAM[C]//IEEE/CVF International Conference on Computer Vision,2023:18387-18398.

[26] Huang H,Li L,Cheng H,et al.Photo-SLAM: real-time simultaneous localization and photorealistic mapping for monocular, stereo, and RGB-D cameras[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition,2024: 21584-21593.

[27] Keetha N,et al.SplaTAM: splat, track & map 3D Gaussians for dense RGB-D SLAM[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition,2024: 21357-21366.

[28] Straub J,et al.The replica dataset: a digital replica of indoor spaces[J].arXiv Preprint arXiv:1906.05797,2019.

[29] Sturm J,et al.A benchmark for the evaluation of RGB-D

SLAM systems[C]//IEEE/RSJ International Conference on Intelligent Robots and Systems,2012:573-580.