



激光与光电子学进展
Laser & Optoelectronics Progress
ISSN 1006-4125, CN 31-1690/TN

《激光与光电子学进展》网络首发论文

题目：几何感知调控与掩码稀疏化的高斯场景压缩
作者：王禹童，李少波，刘昭，肖博，张广成
收稿日期：2025-11-26
网络首发日期：2026-01-22
引用格式：王禹童，李少波，刘昭，肖博，张广成. 几何感知调控与掩码稀疏化的高斯场景压缩[J/OL]. 激光与光电子学进展.
<https://link.cnki.net/urlid/31.1690.TN.20260121.1923.100>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

几何感知调控与掩码稀疏化的高斯场景压缩

王禹童¹, 李少波^{1*}, 刘昭¹, 肖博¹, 张广成¹

¹ 内蒙古科技大学 自动化与电气工程学院, 内蒙古 包头 014010

摘要 三维高斯溅射 (3DGS) 由于缺乏基于几何特征的理论指导, 其启发式致密化策略易引发高斯基元的无效增殖与存储开销激增, 成为限制其广泛部署的关键瓶颈。本文提出一种高效压缩框架 GADC-GS。该框架从几何感知调控、渐进式稀疏化与存储压缩三方面协同优化, 设计基于 Hessian 矩阵的二阶分裂机制以优化几何分布并抑制无效增殖, 引入图像纹理掩码稀疏化策略实现过程主动剪枝, 并采用多模态融合技术达成终端参数的极致压缩。在 Mip-NeRF 360 及 Tanks & Temples 数据集上验证, 在保持甚至超越原始 3DGS 重建质量的同时, 将模型存储体积降低约 26 倍并显著提升了渲染速度, 为资源受限场景下的高质量实时渲染提供了有效技术方案。

关键词 3D 高斯溅射; 模型压缩; 智能密度控制; 残差矢量量化

中图分类号 TP391.9 **文献标志码** A

1 引言

三维计算机视觉的核心挑战之一是如何有效地重建三维场景的信息^[1]。在这领域中, 神经辐射场 (NeRF)^[2]及其后续变体 (Mip-nerf^[3]和 InstantNGP^[4]) 作为代表性工作, 通过隐式表达和先进的网络结构, 在视图合成质量上取得了显著突破, 国内学者也对该领域的最新进展进行了深入的梳理与展望^[5-6]。此外 TensoRF^[7]、Ds-NeRF^[8]、K-Planes^[9]和 MW-NeRF^[10]则分别从模型压缩、数据效率、显式表征和信号调制等角度持续拓展 NeRF 技术, 然而其连续场景查询的内在机制仍导致了高昂的计算开销, 使得训练与推理过程耗时较长, 这成为其在 VR/AR 等实时性要求高或资源受限场景中部署的关键瓶颈。此外, 针对 MLP 表达能力的不足, 侯耀斐^[11]等人提出了基于多特征联合学习的改进方法以提升重建细节。

在此背景下, 3D 高斯溅射^[12]作为新兴的显式表示方法, 通过显式点云表达和高度并行化的可微分光栅化管线, 显著提升了训练速度和渲染效率, 为实时高质量三维重建提供了新的解决方案。然而, 3DGS 依赖自适应密度控制 (Adaptive Density Control, ADC) 机制, 通过在致密化阶段克隆与分裂高斯点以捕捉场景细节, 这一过程缺乏严谨的理论指导, 其分裂时机与方向选择依赖于启发式规则, 极易引发高斯点云的过度膨胀, 从而导致模型内存占用与存储开销急剧增长, 制约了其实际应用。

为此, 相关研究已从多个方向寻求优化。3DGS-MCMC^[13]将致密化与剪枝重构为 MCMC 采样, 引入了 SGLD, 取代了传统依赖启发式克隆与分裂的密度控制策略。Revising-3DGS^[14]

引入了一种由随机优化视角推导出的概率密度控制策略,改进了高斯泼溅中的密度控制过程。Taming-3DGS^[15]引入一种针对受限场景设计的训练策略与架构修改,改进了 3D 高斯泼溅的资源效率与渲染质量。

另一方面,为了缓解存储压力,模型压缩技术成为研究热点。LightGaussian^[16]通过显著性计算进行剪枝并引入蒸馏技术恢复质量; Scaffold-GS^[17]利用锚点结构生成高斯分布,有效降低了冗余; Pup 3DGS^[18]通过基于方差的概率模型来量化高斯点的重要性并进行不确定性剪枝; Compact 3DGS^[19]和 Mini-Splatting^[20]则关注于去除尺度过大或贡献微弱的基元。CaM-NFGS^[21]通过将输入坐标映射为调制信号来动态调控神经网络的前向过程,在量化方面 RMF-3DGS^[22]与 C3DGS^[23]探索了基于码本的矢量量化 (Vector Quantization) 方案,通过参数共享实现了高效的几何表示。这些研究证明了剪枝与量化在 3DGS 模型压缩任务中的巨大潜力。

尽管如此,现有压缩方案仍因多重内在矛盾而难以在资源受限场景下实现理想的轻量高效部署。具体而言,大多数剪枝方法为后处理策略,即先训练庞大的冗余模型再进行剪枝,导致训练阶段显存开销依然巨大,且难以弥补早期错误分裂带来的几何伪影。现有的密度控制多依赖一阶梯度或随机采样,缺乏对场景二阶几何特性的显式感知,导致在平坦区域产生大量无效分裂。此外简单的参数量化往往在训练后独立进行,忽略了量化误差对渲染质量的影响。

本文提出一种紧凑的 3D 高斯表示框架,通过三重机制解决冗余高斯点导致的高内存与存储开销:一是构建几何感知密度调控框架,利用 Hessian 矩阵推导二阶分裂准则,以自适应优化密度控制,从源头抑制无效增殖并构建高精度的几何表征;二是设计渐进式掩码稀疏化策略,针对 3DGS 致密化引入的冗余,基于体积的掩蔽策略在训练过程中精准剔除弱贡献点;三是采用多模态融合存储压缩,利用码本建模对剩余高斯元的几何属性进行参数共享,通过存储索引代替完整参数生成极紧凑表示。通过三者协同在保持高质量重建的同时实现极致轻量与加速渲染。

在 Mip-NeRF 360 和 Tanks & Temples^[24]数据集上对所提方法进行了广泛评估。本文方法在保持与原始 3DGS 相当甚至更优重建质量 (以 PSNR 衡量) 的同时,本文的紧凑表示始终实现了约 26 倍的存储削减与更快的渲染速度,为资源受限场景的高效压缩提供了有效的技术方案。

2 方法

2.1 三维高斯介绍

3D 高斯溅射(3DGS)框架图如图 1 所示，作为 NeRF 的继任者，在实现高分辨率大规模场景实时渲染的同时，能够提供卓越的新视角合成质量。不同于 NeRF 的体积表示，3DGS 将三维场景表示为高斯基元的混合模型，每个基元由位置、协方差、不透明度和球谐系数等参数定义。借助 GPU 加速的光栅化管线，该方法实现了极高效率的前向渲染与反向传播，显著加快了场景重建与新视角生成的速度。




图 1 3DGS 框架图

Fig. 1 3DGS Framework Diagram

3D 高斯通过最小化渲染图像与真实图像之间的 L1 损失与结构相似性损失（SSIM），以驱动渲染结果在像素精度与感知质量上逼近真实场景。为实现从稀疏点到稠密表达的演化，其核心依赖于一套自适应致密化流程，该流程通过监控高斯中心位置梯度的累积强度，并在其超越固定阈值时触发后续操作，对于大尺度高斯执行沿梯度方向的克隆以扩展覆盖，而对小尺度高斯则进行尺度减半的分裂并施加随机扰动以填充细节。同时，辅以对不透明度过低高斯的定期剪枝来维持效率。

然而，这种完全依赖位置梯度强度的几何启发式机制存在根本性局限：在高频纹理区域，梯度信号因分散而难以达到分裂阈值，导致细节重建不足；而在平滑区域，优化噪声却易误触发冗余分裂。更关键的是，其致密化方向缺乏理论指引，仅依赖随机扰动，致使优化效率低下且点云结构松散。同时，整个优化过度依赖多视图颜色一致性，缺少对几何合理性的显式正则化，极易产生几何失真与漂浮伪影。这些缺陷共同揭示了传统 3DGS 在重建均衡性、优化效率与几何正确性上的深层不足。

2.2 方法介绍

本文提出的基于几何感知调控与掩码稀疏化的高斯场景压缩方法（GADC-GS），建立在（3D Gaussian Splatting, 3DGS）的基础上。其核心流程包含四个主要阶段：三维高斯初始化、几何感知密度调控、渐进式掩码稀疏化以及最终的模型存储压缩。

为缓解 3DGS 因海量高斯点导致的 GPU 显存占用高昂与移动端部署瓶颈，已有研究尝

试通过向量量化与参数剪枝等手段实现模型压缩。然而，其采用的全局统一压缩策略未能充分考虑不同高斯点在空间与特征维度上的重要性差异，在提升压缩率的同时，往往导致关键细节的严重损失。为进一步实现压缩效率与重建质量的协同优化，本文提出 GADC-GS 框架，旨在构建一个从源头抑制、过程淘汰到最终压缩的完整技术链，以实现显存效率、模型大小与渲染质量的高效权衡。其核心思想是：首先通过几何感知密度调控（Geometry-Aware Density Regulation, GADR）从致密化源头生成更优质、分布更精准的高斯点云；在此基础上，利用渐进式掩码稀疏化（Progressive Masking Sparsification, PMS）动态淘汰其中贡献微弱的点，实现模型的主动稀疏化；最后，对经过优化和稀疏化的轻量模型施加多模态融合存储压缩（Multimodal Fusion Storage Compression, MFSC），实现显著的存储效率。三者环环相扣，前一阶段为后一阶段奠定基础，共同构成了一个协同高效的压缩系统。整体框架流程图见图 2。




图 2 GADC-GS 整体框架图

Fig. 2 GADC-GS Overall Framework Diagram

2.2.1 几何感知密度调控

传统 3DGS 算法依赖启发式分裂策略进行自适应密度控制，其分裂决策仅基于位置梯度幅值与固定阈值的简单比较。该机制虽能实现基础的点云生长，但未能充分考虑损失函数的优化轨迹与几何特性，导致训练过程中高斯点数量急剧膨胀且分布与真实几何结构脱节，产生大量无效的冗余计算，限制了训练效率与场景几何表达的准确性。

在原始方法中，在优化陷入停滞时，即梯度幅值显著减小但重建误差依然较大，算法面临根本性的判别困境。此时，微弱的一阶梯度信号无法区分两种本质不同的情况：该区域是因几何平坦而无需细化，还是因单个高斯元覆盖了具有高曲率或方向冲突的复杂结构而导致优化陷入局部最优。后者恰是细节缺失与伪影频现的根源，而原始方法对此缺乏有效的识别能力，常引发分裂时机滞后与方向失准，进一步加剧高斯点的无效增殖与收敛迟滞。

为了改善上述现象，本文引入了几何感知密度调控框架（Geometry-Aware Density Regulation, GADR），通过引入基于损失函数二阶几何特性（Hessian 矩阵）的分裂准则，构建具有理论指导的自适应分裂机制。该框架旨在以数学推导为基础，精准判定分裂时机并沿几何主曲率方向进行对齐，从而在显著提升训练收敛速度的同时，自适应优化高斯点的空间分布并显著提升几何重建质量，如图 3 所示。




图 3 高斯点分裂示意图

Fig. 3 Gauss point splitting Diagram

本文方法在训练循环中设置监控机制，每 100 次迭代触发一次。该机制仅对满足条件的高斯点计算损失函数对其中心位置的梯度向量。首先计算损失函数对高斯中心位置坐标的梯度向量 $\mathbf{j} \in \mathbb{R}^{3 \times 1}$ ：

$$\mathbf{j} = \frac{\partial \mathcal{S}}{\partial \boldsymbol{\alpha}} = \begin{bmatrix} \frac{\partial \mathcal{S}}{\partial x} \\ \frac{\partial \mathcal{S}}{\partial y} \\ \frac{\partial \mathcal{S}}{\partial z} \end{bmatrix} \in \mathbb{R}^{3 \times 1} \quad (1)$$

通过对一阶梯度向量 $\mathbf{j}$ 求导得到 Hessian 矩阵 $\mathbf{H}$ ，但由于直接计算 Hessian 矩阵的计算量较大，本文选择采用自动微分技术高效计算 Hessian 矩阵：

$$\mathbf{H} = \begin{bmatrix} \frac{\partial^2 \mathcal{S}}{\partial x^2} & \frac{\partial^2 \mathcal{S}}{\partial x \partial y} & \frac{\partial^2 \mathcal{S}}{\partial x \partial z} \\ \frac{\partial^2 \mathcal{S}}{\partial y \partial x} & \frac{\partial^2 \mathcal{S}}{\partial y^2} & \frac{\partial^2 \mathcal{S}}{\partial y \partial z} \\ \frac{\partial^2 \mathcal{S}}{\partial z \partial x} & \frac{\partial^2 \mathcal{S}}{\partial z \partial y} & \frac{\partial^2 \mathcal{S}}{\partial z^2} \end{bmatrix} = \begin{bmatrix} \text{JVP}(\mathbf{j}, \boldsymbol{\alpha}, [1, 0, 0]^T) \\ \text{JVP}(\mathbf{j}, \boldsymbol{\alpha}, [0, 1, 0]^T) \\ \text{JVP}(\mathbf{j}, \boldsymbol{\alpha}, [0, 0, 1]^T) \end{bmatrix} \quad (2)$$

本文定义分裂矩阵 $\mathbf{S} = -\mathbf{H}$ 。该矩阵表征了损失函数在当前点的负曲率，其最大特征值方向指示了最优的分裂方向。

对分裂矩阵进行特征分解：

$$\mathbf{S}\mathbf{v} = \lambda\mathbf{v} \quad (3)$$

特征值按降序排列 $\lambda_1 \geq \lambda_2 \geq \lambda_3$ 并选取最大特征值 λ_1 和对应的特征向量 $\mathbf{v}_1$ 。

用当前高斯点对损失函数的贡献相关的量 ϵ （不透明度 α 以一个常数缩放因子 X ）和最大特征值 λ_1 计算出最优步长 η ：

$$\epsilon = \alpha \cdot X \quad (4)$$

$$\eta = \sqrt{\frac{2\epsilon}{\lambda_1}} \quad (5)$$

分裂条件判定为 $\lambda_1 > 1e-5$ 且 $\eta < 0.1$ 。设定分裂阈值 $\lambda_1 > 1e-5$ 旨在过滤由图像噪声引起的微小梯度波动，确保仅在几何结构具有显著曲率特征时触发分裂。对于步长限制 $\eta < 0.1$ ，这是为了防止在优化初期因特征值过小导致的步长爆炸，确保新生成的子高斯点位于局部几何邻域内。

若满足分裂条件，则执行分裂操作：父高斯点被删除，并沿特征向量 $\mathbf{v}_1$ 指示的主方向创建两个新的子高斯点，其位置更新公式如下：

$$\begin{aligned}\mu_1 &= \mu + \eta \cdot v_1 \\ \mu_2 &= \mu - \eta \cdot v_2\end{aligned}\tag{6}$$

其中 μ 是父高斯点的位置， v 是分裂矩阵对应最大特征值 λ 的特征向量。分裂后，父高斯点被删除，由两个子点替。新点的颜色与旋转属性继承自父点，缩放属性为父点的 0.5 倍，以保持分裂前后的几何覆盖范围近似一致，防止体积膨胀。不透明度属性为父点的 0.8 倍，作为一种正则化手段，防止因高斯重叠导致的局部密度过高和渲染伪影。

上述几何感知密度调控机制通过理论指导的分裂策略，使模型能够精准识别并逃离鞍点区域，在训练初期即有效规避了由图像噪声引发的无效分裂。该策略不仅提升了点云的几何重建精度与结构对齐性，更从源头优化了高斯基元的有效性，确保生成的致密点云能够精确覆盖复杂几何细节，为后续基于掩码的精准稀疏化奠定了高质量的结构基础。

2.2.2 渐进式掩码稀疏化

传统 3DGS 算法依赖启发式分裂与克隆策略进行自适应密度控制，虽能提升细节表示，但缺乏有效的淘汰机制，易导致高斯数量无限膨胀与大量冗余计算。此外，其原始优化过程仅通过梯度下降更新高斯属性，无法主动识别并移除对渲染贡献微小或处于空白区域的高斯，造成了显存与计算资源的持续浪费，并限制了场景表示的紧凑性。

在原始方法的高斯增殖虽在策略上具备可逆性，但其淘汰机制依赖固定截断阈值，阈值的设置不参与梯度计算和反向传播。导致因早期估计偏差产生的冗余高斯在尺度、透明度或位置失效后，难以被及时精准地剔除。因此，高斯总量在训练中持续累积，造成渲染效率与模型紧凑性之间的冲突。

为了达成上述目标，本文引入了渐进式掩码稀疏化（Progressive Masking Sparsification, PMS）。该机制通过一个联动渲染损失的可学习二值掩码，实现对高斯分布的动态稀疏化控制。在前向传播中，硬二值掩码直接剪除冗余高斯。反向传播时，借助停止梯度技巧，仅优化掩码概率以自主决定高斯的去留。通过将掩码激活率作为正则项，该模块在保障渲染质量的同时，持续自适应地淘汰无效高斯，最终显著提升训练效率、降低资源占用并增强场景表示的紧凑性。

首先，通过 sigmoid 函数 σ 将可学习参数 y_n 转换为介于 0 和 1 之间的值 $\sigma(y_n)$ ，表示该高斯的保留概率，将这个概率 $\sigma(y_n)$ 与预设阈值 ϵ 进行比较。

本文采用固定阈值策略，设定 $\epsilon = 0.5$ 。该阈值作为二值化的决策边界，直接调控稀疏化

的力度。较高的阈值能带来更高的压缩率，但可能导致细节丢失；较低的阈值则能保留更多几何细节，但会增加存储开销。

使用指示函数 $\mathbf{1}[\cdot]$ 生成一个硬二值输出，引入停止梯度操作 $\text{sg}()$ 来阻断指示函数项的梯度反向传播，最后将停止梯度后的二值结果与 $\sigma(y_n)$ 输出相加，得到最终的二值掩码 Y_n ：

$$Y_n = \text{sg}(\mathbf{1}[\sigma(y_n) > \epsilon] - \sigma(y_n)) + \sigma(y_n) \quad (7)$$

该二值掩码 Y_n 在前向传播中表现为 0 或 1，用于屏蔽或保留高斯，而在反向传播中梯度仅通过 $\sigma(y_n)$ 流动，从而优化参数。

用二值掩码 Y_n 分别与原始尺度 c_n 和原始透明度 t_n 相乘得到掩码后的尺度和透明度：

$$\hat{c}_n = Y_n c_n, \quad \hat{t}_n = Y_n t_n \quad (8)$$

将所有高斯掩码率求和后除以高斯总数 N 计算平均值得到掩码损失 L_m ：

$$L_m = \frac{1}{N} \sum_{n=1}^N \sigma(y_n) \quad (9)$$

掩码损失 L_m 作为正则项，该策略在渲染精度与模型稀疏性之间实现了动态平衡，通过在整个训练阶段持续执行掩码操作，有效剔除冗余的高斯基元，从而确保了训练阶段的高效计算与低显存占用。

大量高斯基元共同构建了场景，针对其中相似的几何结构，可通过共享参数来降低存储开销。大多数高斯分布的几何形状非常相似，只有在尺度和旋转上有微小的差异。因此，可以通过使用向量来学习代表几何分布的码向量，通过使用矢量量化（VQ）^[25]来学习尺度和旋转，但是直接使用矢量量化需要很高的计算复杂度和 GPU 内存，因此采用残差矢量量化（R-VQ）^[26]如图 4 所示。




图 4 残差向量量化示意图

Fig. 4 Schematic of Residual Vector Quantization

对于第 n 个高斯，在第 1 阶段，从码本 $\mathcal{Z}^k$ 中选取索引为 i^k 的码向量，然后将从第 1 阶段到第 q 阶段的所有选中的码向量加起来，得到第 q 阶段的量化结果：

$$\hat{o}_n^q = \sum_{k=1}^q \mathcal{Z}^k [i^k], \quad q \in \{1, \dots, Q\} \quad (10)$$

在第 q 阶段，计算当前残差(原始旋转向量 o_n 减去前 $q-1$ 阶段的量化结果)与第 q 个码本 $\mathcal{Z}^q$ 中每个码向量 $\mathcal{Z}^q[l]$ 的欧氏距离，选择距离最小的码向量索引 r_n^q 作为当前阶段的最优索引：

$$r_n^q = \underset{l}{\operatorname{argmin}} \left\| \mathcal{Z}^q[l] - (o_n - \hat{o}_n^{q-1}) \right\|_2^2, \quad \hat{o}_n^0 = \vec{0} \quad (11)$$

通过计算当前残差 $o_n - \hat{o}_n^{q-1}$ 并对其应用停止梯度 $\operatorname{sg}(\cdot)$ ，计算该冻结残差与对应阶段所选码向量 $\mathcal{Z}^l[r_n^q]$ 的欧氏距离平方，对所有 N 个高斯和所有 Q 个阶段的这些平方距离进行求和，将总和除以高斯数量 N 和码本大小 C 得到训练码本的目标函数 L_r ：

$$L_r = \frac{1}{NC} \sum_{l=1}^Q \sum_{n=1}^N \left\| \operatorname{sg}[o_n - \hat{o}_n^{l-1}] - \mathcal{Z}^l[r_n^q] \right\|_2^2 \quad (12)$$

最终，量化后的尺度 $\hat{c}_n$ ，不透明度 $\hat{t}_n$ 和旋转 $\hat{o}_n^q$ 示被送入光栅化器用于渲染图像。整个模型基于总损失函数 L 进行端到端协同训练：

$$L = L_{ren} + \lambda_m L_m + L_r + L_s \quad (13)$$

其中， L_{ren} 为渲染损失， λ_m 是调节稀疏力度的超参数，分别对应旋转和尺度的码本量化损失。 L_r 和 L_s 该目标函数同时驱动了渲染质量优化、高斯数量稀疏化以及几何属性的紧

凑表达。

通过上述优化，模型在训练后期能够有效屏蔽冗余高斯点，并利用码本大幅压缩剩余点的几何属性这种。这种基于数量和属性的双重压缩策略，使模型能够得到参数分布极度集中的轻量化表示，为后续的 MFSC 编码压缩创造了极为有利的条件。

2.2.3 多模态融合存储压缩

传统 3DGS 算法依赖原始浮点格式存储高斯参数，存在显著的数值精度冗余，且未充分利用参数的空间局部性与长尾分布特性，导致存储效率低下，严重限制了大规模场景的传输与部署。

经过前序 GADR 和 PMS 的两阶段协同优化，模型已具备极高的稀疏性与几何紧凑性。在此基础上，作为压缩管道的最终环节，本文提出多模态融合存储压缩（MFSC）机制。该机制是一个离线后处理步骤，旨在通过数值量化、贡献度剪枝与熵编码的级联策略，在不显著损失视觉质量的前提下消除剩余的数值与统计冗余，实现极致的存储压缩率。

为了消除浮点表示的位宽冗余，首先对高斯属性进行线性映射量化。将连续的 32 位浮点数值映射为离散的 8 位整数空间。对于参数集合中的任意值 z ，其量化公式如下：

$$z_q = \text{round} \left[\frac{z - z_{\min}}{z_{\max} - z_{\min}} \times (2^8 - 1) \right] \quad (14)$$

当需要加载模型进行渲染时，需要将压缩的模型数据恢复为可计算的浮点数格式。将整数 z_q 除以 255 映射回 $[0, 1]$ 区间，接着乘以 $(z_{\max} - z_{\min})$ 恢复到原始数值范围，最后添加 $z_{\min}$ 平移回原始数值区间：

$$z_d = z_{\min} + \frac{z_q}{2^8 - 1} \times (z_{\max} - z_{\min}) \quad (15)$$

尽管已剔除了无效高斯点，但剩余高斯点的某些属性可能仍接近于零，对最终渲染图像的贡献微乎其微。为了进一步提升编码效率，本文引入基于渲染贡献度的阈值截断策略：

$$p_r = \begin{cases} 0 & \text{if } |p| < 0.1 \\ p & \text{otherwise} \end{cases} \quad (16)$$

对渲染贡献度 $|p|$ 小于阈值 0.1 的参数直接置为 0。这一步操作显著增加了数据流中 0 的出现频率，极大地降低了数据的信息熵，为后续的熵编码创造了有利条件。

经过量化与剪枝后，数据序列表现出极强的不均匀分布特性。利用这一统计特性，本文

采用无损的霍夫曼编码，对量化后的 8 位整数序列进行压缩。该算法首先统计量化整数序列中各符号 $\{s_1, \dots, s_n\}$ 的出现频率 $\{f_1, \dots, f_n\}$ ，并以此构建最小优先队列。在编码树的构建过程中，算法迭代地从队列中取出两个频率最小的节点作为左右子节点，合并生成一个新的父节点，其频率设为两子节点频率之和，随后将该父节点重新插入队列。这一过程持续重复，直至队列中仅剩唯一的根节点，从而完成霍夫曼树的构建。最后，通过从根节点遍历至所有叶子节点，根据路径分配二进制编码，确保高频数值被映射为短码字，低频数值映射为长码字，生成最终的霍夫曼编码表以实现最小平均码长。

通过引入多模态融合存储压缩，模型在存储阶段能更智能地识别并利用参数分布的统计特性，从而以更紧凑的数据表示和更高的编码效率实现质量保持的压缩效果。该机制从根源上抑制了存储资源的浪费，将高质量稀疏模型转化为极度紧凑的二进制码流，为 3DGS 在移动端的实时应用扫清了存储障碍。

3 实验

3.1 实验环境与配置

3.1.1 硬件与软件环境

实验硬件环境采用 Intel Platinum 8358P CPU，80G 内存以及 NVIDIA RTX4090（24GB）显卡，选择在 PyTorch 2.0.0，Python3.8(ubuntu20.04)，CUDA 11.8 系统下进行操作。

3.1.2 训练策略与参数设置

为了保证对比的公平性，所有对比方法（包括原始 3DGS、Pixel-GS 等）均使用其官方开源代码在上述统一硬件平台上从头进行训练（Retrained from scratch），不加载任何预训练权重。

本文算法以 3DGS 为基准框架。为保证对比公平性，严格遵循其训练策略、超参数配置及评估脚本，所有场景均经 30,000 次迭代训练。几何感知密度调控（GADR）每 100 次迭代触发一次，渐进式掩码稀疏化（PMS）的掩码损失权重设定为 0.001。

3.1.3 数据集

为验证本文提出的 GADC-GS 框架的有效性，本文选取了五个具有代表性的场景进行实

验。这些场景包括 Mip-Nerf-360 数据集中的 Kitchen、Bicycle 和 Flowers，以及 Tanks & Temples 数据集中的 Truck 和 Barn，涵盖了单一物体、室内环境和复杂的室外场景，能够全面评估算法性能。

3.2 评估指标

本实验分别从图像质量、渲染效率与模型紧凑性等多个维度综合评估模型性能，具体采用以下指标：峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）、结构相似性指数（Structural Similarity Index, SSIM）、学习感知图像块相似度（Learned Perceptual Image Patch Similarity, LPIPS）、帧率（Frames Per Second, FPS）以及模型存储大小。

3.3 实验结果与分析

本文通过将 GADC-GS 与当前在渲染质量上表现优异的 Pixel-GS^[27]以及广泛采用的原始 3DGS 基线进行系统对比，以验证其在压缩效率与重建质量之间的平衡能力。实验结果表明，GADC-GS 成功实现了渲染质量与存储效率的同步提升：在 Mip-NeRF 360 等数据集上，其渲染质量与 Pixel-GS 持平甚至部分指标更优（SSIM, LPIPS），同时，其模型体积仅约为 Pixel-GS 的 1/45，原始 3DGS 的 1/22。这一突破性优势证明，GADC-GS 并非以牺牲质量来换取压缩，而是通过其创新的架构，从根本上提升了三维高斯表示的紧凑性，为其在移动端应用部署扫清了存储障碍，可视化对比如图 5。

第一列为真值，第二列为本文方法。红色框内展示了局部细节放大图。可以看出，本文方法在保持与 Pixel-GS 相当的细节锐度的同时，文件体积显著更小。




图 5 Mip-NeRF 360 与 Tanks & Temples 数据集上的可视化重建对比

Fig. 5 Visual reconstruction comparison on Mip-NeRF 360 and Tanks & Temples datasets

3.3.1 在 Mip-NeRF 360 数据集上的对比试验

为评估 GADC-GS 算法在三维重建中的性能优势, 本文选取一些代表性方法构建了对比试验。实验结果如表 1 所示。其中 3DGS*是重新训练的 3DGS 模型, 性能更优。**加粗**表示最佳方法, 下划线表示次优方法, $\uparrow$ 表示数值越大越优, $\downarrow$ 表示数值越小越优。

表 1 Mip-NeRF 360 对比试验结果

Table 1 Comparison test results of Mip NeRF 360

Method	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$	Storage(MB) $\downarrow$	FPS $\uparrow$
Mip-NeRF 360	27.73	0.791	0.237	8.6	0.06
3DGS*	27.25	0.815	0.219	734	<u>120.0</u>
2DGS	27.37	0.816	0.221	328	41.3
INGP	25.58	0.698	0.324	48	11.7
Plenoxels	27.55	0.822	0.223	2150.4	6.79
Pixel	27.79	<u>0.831</u>	<u>0.176</u>	1422.6	101.7
Ours	<u>27.71</u>	0.835	0.174	<u>28.3</u>	129.0

表 1 展示了本文提出的 GADC-GS 方法与当前主流三维重建算法在 Mip-NeRF 360 数据集上的定量对比结果。从整体性能来看, GADC-GS 在保持卓越重建质量的同时实现了存储

效率的突破性提升。

在重建质量方面，GADC-GS 的 SSIM 指标达到 0.835，LPIPS 指标为 0.174，均优于所有对比方法，体现了其在结构保持和感知质量方面的优势。虽然 PSNR 指标略低于 Pixel-GS，但差距不足 0.1dB。在存储效率方面，GADC-GS 的表现尤为突出。其模型大小仅为 28.3MB，相比原始 3DGS*压缩了约 26 倍，相比性能相近的 Pixel-GS 更是实现了近 50 倍的存储节省。这种压缩效果主要得益于本文提出的掩码稀疏化与码本压缩机制，能够在保持视觉质量的同时大幅削减冗余参数。与此同时，GADC-GS 的渲染速度达到 129.0FPS，优于 3DGS*的 120.0FPS 与 Pixel-GS 的 101.7FPS，说明其不仅在存储上极为紧凑，在渲染效率上也具有明显优势。

与其他方法相比，GADC-GS 展现出独特的综合优势：相比传统 NeRF 方法，在训练效率上具有数量级优势。相比于 3DGS 方向的新型方法，在各项质量指标上保持一致。

为直观展示 GADC-GS 在性能和效率权衡上的优势，图 6 绘制了各方法的存储质量速度散点图。其中横轴为模型大小，纵轴为 PSNR，散点颜色深浅表征渲染速度（FPS），越靠近左上方区域且颜色越深说明性能越优，本文的 GADC-GS 在存储略微大于 Mip-NeRF 360 的情况下其质量与最优的 Pixel-GS 相当，存储却仅为其 1/45，还实现了最高的渲染速度。分别存在存储冗余（如 Plenoxels^[28]、Pixel-GS）、质量不足（如 INGP）或速度欠佳（如 2DGS^[29]、3DGS*）等局限。Mip-NeRF 360 虽存储较小，但速度极慢（颜色最浅）。该可视化结果有力证明 GADC-GS 成功突破了传统方法在质量、存储与速度间的三难困境。




图 6 Mip-NeRF 360数据集上的PSNR-存储-FPS评估图

Fig. 6 PSNR-Storage-FPS Assessment on the Mip-NeRF 360 Dataset

3.3.2 在 Tanks & Temples 数据集上的对比实验

为验证 GADC-GS 在不同场景类型下的泛化能力, 本文进一步在 Tanks & Temples 数据集上进行了对比实验。该数据集以大规模室外场景和复杂的空间结构为特点, 对算法的几何重建能力提出了更高要求。实验结果如表 2 所示。

表 2 Tanks & Temples 对比试验结果

Table 2 Comparison test results of Tanks & Temples

Method	PSNR↑	SSIM↑	LPIPS↓	Storage(MB)↓	FPS↑
Mip-NeRF 360	19.65	0.731	0.281	9.4	0.14
3DGS*	23.95	<u>0.851</u>	<u>0.157</u>	411	<u>160.0</u>
2DGS	23.12	0.831	0.212	203	51.2
INGP	21.92	0.745	0.305	46	17.1
Plenoxels	21.08	0.719	0.379	2355.2	13.0
Pixel	24.38	<u>0.851</u>	0.178	832	104.0
Ours	<u>24.30</u>	0.856	0.152	<u>21.9</u>	184.0

实验结果表明, GADC-GS 在此类具有挑战性的场景中依然保持领先。其在结构一致性、感知质量和渲染速度上均位列第一, 充分证明了该方法在复杂几何与遮挡关系下的重建鲁棒性。GADC-GS 将模型压缩至仅 21.9MB, 相较 Pixel-GS 实现 38 倍存储缩减, 同时渲染速度高达 184.0FPS, 大幅领先 3DGS* (160.0FPS) 与 Pixel-GS (104.0FPS)。这种压缩与加速并未以牺牲几何完整性为代价, 相较于 2DGS 等同类紧凑表示方法, GADC-GS 在渲染速度与所有关键质量指标上均全面占优, 凸显了其压缩策略的综合优越性。

图 7 所示的存储质量速度散点图进一步直观印证了上述优势。GADC-GS 占据左上角区域且颜色最深, 表明其在极小存储下实现了优异质量与最快渲染速度, 其余方法则各有短板 (Plenoxels、Pixel-GS) 存在存储冗余, (2DGS、INGP、Mip-NeRF 360) 存在速度受限。该结果充分验证了 GADC-GS 在不同场景中兼顾高质量、轻量化与实时渲染的综合能力。




图 7 Tanks & Temples数据集上的PSNR-存储-FPS评估
Fig. 7 PSNR-Storage-FPS Assessment on the Tanks & Temples Dataset

3.4 消融试验

为系统验证 GADC-GS 框架中各核心模块的有效性 with 协同机制，本文在 Mip-NeRF 360 数据集上设计了系统性的消融实验。实验中通过控制变量法逐步引入 GADR、PMS 与 MFSC 三个核心模块，从图像质量与存储效率两个维度综合评估模型性能，结果如表 3 所示。

表 3 消融试验结果
Table 3 Results of ablation experiment

GADR	PMS	MFSC	PSNR↑	SSIM↑	LPIPS↓	Storage(MB)↓	Point Count↓
×	×	×	27.25	0.815	0.219	734	1585530
√	×	×	27.55	0.828	0.198	489	1654164
√	√	×	27.68	0.833	0.179	157	1169535
√	√	√	27.71	0.835	0.174	28.3	1169535
×	√	×	27.45	0.823	0.205	385	1121009
×	×	√	27.18	0.812	0.222	312	1585530

注：“√”代表使用相应方法，“×”代表未使用相应方法；↑表示数值越大越优，↓表示数值越小越优。

首先引入几何感知密度调控（GADR），使 PSNR 提升 0.3 dB、LPIPS 下降 0.021，虽然此时高斯点数略有增加如表 3，但得益于更合理的高斯基元分布，存储开销却降低了 33%。这一结果验证了 GADR 并非单纯的抑制机制，而是通过优化高斯基元的空间分布，显著提升了模型对场景几何的表达准确性与信噪比。

为了研究各模块对高斯数量演变的动态影响，本文绘制了训练过程中的点数变化曲线如图 8 所示。




图 8 高斯基元数量变化的消融实验

Fig. 8 Ablation Study on the Variation of Gaussian Primitives

在仅加入 GADR 的情况下，最终高斯数（1.65M）略高于 Baseline（1.59M），该现象表示 GADR 并非单一的抑制基元数量，而是利用 Hessian 矩阵精准定位高曲率区域，并在这些区域分配更多高斯以强化几何细节的表达。该策略为后续高质量重建奠定了结构基础。

在此基础上加入 PMS，训练后期呈现阶梯状陡降，高斯数由 1.65M 锐减至 1.17M。作为对照，若移除 GADR 而仅保留 PMS，虽然最终点数更低（1.12M），由于缺乏早期的几何引导，PSNR 仅为 27.45dB，低于完整模型。该实验说明，单纯追求最小基元数量并不能获得最优的压缩效果。本文通过 GADR 维持几何重建精度，PMS 降低冗余基元的协同策略，在重建精度与压缩率之间实现了最优权衡。

最终施加多模态融合存储压缩（MFSC），在视觉质量无损的条件下，存储压缩至 28.3MB，相较基线实现 26 倍压缩比，且重建质量（PSNR27.71dB）几乎无损甚至略优。这验证了 MFSC 能够高效地将前序步骤产生的稀疏参数映射为紧凑的存储表达。

反之，如消融试验所示，若跳过源头优化而直接在冗余基线上剪枝，性能提升极为有限，印证了 PMS 在低质量点云上难以实现精准操作。若直接对未经优化的冗余模型施加压缩，底层参数冗余将放大量化误差，导致重建质量明显下降。这从反面验证了模块间协同的必要性，说明压缩管道的前端环节不可缺失。

综上所述，GADR、PMS 与 MFSC 构成递进式的协同压缩系统，GADR 从源头保障了几何结构的完整性与准确性，为 PMS 创造了结构清晰的剪枝环境。PMS 进一步降低了点数量级，为 MFSC 提供了低熵的底层参数分布。三者递进协作，最终实现存储效率与重建质量的同步优化。

4 结 论

本文提出的基于改进 3DGS 的几何感知调控与掩码稀疏化的三维高斯高效压缩框架 GADC-GS，通过引入几何感知密度调控（GADR）机制，从二阶几何优化的视角改进了传统的密度控制策略，推导了基于 Hessian 矩阵的分裂准则，从源头优化了高斯基元的空间分布并抑制了无效增殖。在此基础上，集成了渐进式掩码稀疏化（PMS）与多模态融合存储压缩（MFSC），构建了从精确致密化、参数稀疏到几何压缩的完整过程。

在 Mip-NeRF 360 与 Tanks & Temples 等数据集上，本文方法在重建质量（PSNR, SSIM, LPIPS）上达到或超越了原始 3DGS 及当前高性能方法的同时，将模型存储占用降低了超过

26 倍，并实现了渲染速度的显著提升。

综上所述，本文确立了高视觉质量、高紧凑性与实时渲染的新基线，为资源受限环境下的三维重建提供了有效的解决方案，将推动该技术在移动设备与虚拟现实等领域的广泛应用。未来工作将围绕提升方法在极端复杂场景下的鲁棒性及其跨尺度适应能力展开。

参考文献

- [1] 高建, 陈林卓, 沈秋, 等. 基于三维高斯溅射技术的可微分渲染研究进展 (特邀) [J]. 激光与光电子学进展, 2024, 61(16):163-175.
- [2] SRINIVASAN S, RAMACHANDRA G. RePose-NeRF: Robust radiance fields for mesh reconstruction under noisy camera poses[J/OL]. arXiv preprint arXiv:2511.08545, 2025.
- [3] BARRON J T, MILDENHALL B, VERBIN D, et al. Mip-NeRF 360: Unbounded anti-aliased neural radiance fields[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans: IEEE, 2022: 5472-5481.
- [4] MÜLLER T, EVANS A, SCHIED C, et al. Instant neural graphics primitives with a multiresolution hash encoding[J]. ACM Transactions on Graphics, 2022, 41(4): 1-15.
- [5] 李吉洋, 程乐超, 何靖璇, 等. 神经辐射场的研究现状与展望[J]. 计算机辅助设计与图形学学报, 2024, 36(7):995-1013.
- [6] 何高湘, 朱斌, 解博, 等. 基于神经辐射场的新视角合成研究进展[J]. 激光与光电子学进展, 2024, 61(12):1200005.
- [7] CHEN A P, XU Z B, ZHANG R, et al. TensorRF: Tensorial radiance fields[C]//European Conference on Computer Vision (ECCV). Cham: Springer Nature Switzerland, 2022: 333-350.
- [8] DENG K, LIU A, ZHU J Y, et al. Depth-supervised NeRF: Fewer views and faster training for free[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans: IEEE, 2022: 12897-12906.
- [9] FRIDOVICH-KEIL S, MEANTI G, WARBURG F R, et al. K-Planes: Explicit radiance fields in space, time, and appearance[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver: IEEE, 2023: 12479-12488.
- [10] RHO D, LEE B, NAM S, et al. Masked wavelet representation for compact neural radiance fields[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver: IEEE, 2023: 20680-20690.
- [11] 侯耀斐, 黄海松, 范青松, 等. 基于改进多层感知机的神经辐射场三维重建方法[J]. 激光与光电子学进展, 2024, 61(4):0415004.
- [12] KERBL B, KOPANAS G, LEIMKUEHLER T, et al. 3D gaussian splatting for real-time radiance field rendering[J]. ACM Transactions on Graphics, 2023, 42(4): 1-14.
- [13] KHERADMAND S, REBAIN D, SHARMA G, et al. 3D Gaussian Splatting as Markov Chain Monte Carlo[C]//European Conference on Computer Vision (ECCV). Cham: Springer Nature Switzerland, 2024: 178-195.
- [14] BULÒ S R, PORZI L, KONTSCHIEDER P. Revising densification in Gaussian Splatting[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle: IEEE, 2024: 21677-21687.

- [15] MALLICK S S, GOEL R, KERBL B, et al. Taming 3DGS: High-quality radiance fields with limited resources[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle: IEEE, 2024: 20665-20675.
- [16] FAN Z, WANG K, WANG Z, et al. LightGaussian: Unbounded 3D gaussian compression with 15x reduction and 200+ FPS[C]//Advances in Neural Information Processing Systems 37 (NeurIPS 2024). 2024: 140138-140158.
- [17] Lu T, Yu M L, Xu L N, et al. Scaffold-GS: Structured 3D Gaussians for view-adaptive rendering[C]. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024: 20654-20664.
- [18] HANSON A, TU A, SINGLA V, et al. PUP 3D-GS: Principled uncertainty pruning for 3D gaussian splatting[C]//2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2024: 5949-5958.
- [19] MORGENSTERN W, BARTHEL F, HILSMANN A, et al. Compact 3D scene representation via self-organizing gaussian grids[C]//European Conference on Computer Vision (ECCV). Cham: Springer Nature Switzerland, 2024: 333-350.
- [20] Fang G C, Wang B. Mini-splatting: Representing scenes with a constrained number of gaussians[C]. European Conference on Computer Vision (ECCV), 2024: 402-418.
- [21] LEE J C, LEE S J, KIM S, et al. Coordinate-aware modulation for neural fields[C]//The Twelfth International Conference on Learning Representations (ICLR). Vienna: OpenReview, 2024.
- [22] PAPANTONAKIS P, KOPANAS G, KERBL B, et al. Reducing the memory footprint of 3D gaussian splatting[J]. Proceedings of the ACM on Computer Graphics and Interactive Techniques, 2024, 7(1): 1-17.
- [23] He Y, Wang Y G, Liu H J, et al. C3DGS: Compressing 3D Gaussian model for surface reconstruction of large-scale scenes based on multiview UAV images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 5625114.
- [24] KNAPITSCH A, PARK J, ZHOU Q Y, et al. Tanks and temples: Benchmarking large-scale scene reconstruction[J]. ACM Transactions on Graphics, 2017, 36(4): 1-13.
- [25] GRAY R. Vector quantization[J]. IEEE ASSP Magazine, 1984, 1(2): 4-29.
- [26] ZEGHIDOUR N, LUEBS A, OMRAN A, et al. SoundStream: An end-to-end neural audio codec[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 30: 495-507.
- [27] ZHANG Z, HU W, LAO Y, et al. Pixel-GS: Density control with pixel-aware gradient for 3D Gaussian splatting[C]//European Conference on Computer Vision (ECCV). Cham: Springer Nature Switzerland, 2024: 355-372.
- [28] Fridovich-Keil S, Yu A, Tancik M, et al. Plenoxels: Radiance fields without neural networks[C]. 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022: 5501-5510.
- [29] HUANG B, YU Z, CHEN A, et al. 2D gaussian splatting for geometrically accurate radiance fields[C]//SIGGRAPH '24: ACM SIGGRAPH 2024 Conference Papers. Denver: ACM, 2024: 1-11.

Geometry-Aware Regulation and Mask Sparsity for 3D Gaussian Scene Compression

Wang Yutong¹, Li Shaobo^{1*}, Liu Zhao¹, Xiao Bo¹, Zhang Guangcheng¹

¹ *School of Automation and Electrical Engineering, Inner Mongolia University of Science and Technology, Inner Mongolia Baotou 014000, China;*

Abstract

Objective: 3D Gaussian Splatting (3DGS) has emerged as a promising explicit representation for high-quality real-time 3D reconstruction. However, its reliance on heuristic adaptive density control (ADC) mechanisms often leads to an ineffective proliferation of Gaussian primitives, resulting in excessive storage costs and memory consumption. This limitation constitutes a critical bottleneck for its deployment in resource-constrained scenarios, such as VR/AR or mobile devices. Existing compression methods often involve post-processing pruning or lack second-order geometric guidance, which may cause geometry artifacts or insufficient optimization. This work develops an efficient compression framework that integrates geometric guidance and active sparsification to achieve extreme compression while maintaining high rendering quality.

Methods: We propose GADC-GS, an efficient compression framework that optimizes 3DGS through three synergistic dimensions (Fig. 2). Through Geometry-Aware Density Regulation (GADR), we devise a second-order splitting mechanism based on the loss function's Hessian matrix that adaptively determines optimal splitting times and directions along principal curvatures, thereby optimizing geometric distribution and suppressing ineffective proliferation, and yielding high-fidelity geometric representations (Fig. 3). To eliminate redundant Gaussians during training, Progressive Masking Sparsification (PMS) introduces a learnable binary mask coupled with the rendering loss, which actively prunes low-contribution points via a progressive masking strategy while preserving fine-grained details (Fig. 8). Terminal parameters are further reduced by Multimodal Fusion Storage Compression (MFSC), a multimodal fusion approach that employs codebook modeling through Residual Vector Quantization for parameter sharing (Fig. 4), succeeded by linear quantization to 8-bit integers, contribution-based pruning, and lossless Huffman coding to eliminate statistical redundancy.

Results and Discussions: The proposed GADC-GS was evaluated on the Mip-NeRF 360 and Tanks & Temples datasets. Quantitative results show that GADC-GS achieves a storage reduction of approximately $26\times$ compared to the original 3DGS* while maintaining or even surpassing the reconstruction quality in terms of SSIM and LPIPS (Table 1, Table 2). On the Mip-NeRF 360 dataset, our method reached an SSIM of 0.835 and a rendering speed of 129.0 FPS, significantly outperforming Pixel-GS and 3DGS* in both efficiency and quality (Table 1, Fig. 6). Ablation studies further confirm the effectiveness of each module: GADR improves PSNR by 0.3 dB and reduces storage by 33%, while PMS dramatically decreases the point count in the later training

stages (Table 3, Fig. 8). The visualization results demonstrate that our framework preserves high-frequency textures while maintaining a clean geometry (Fig. 5).

Conclusions: This study presents GADC-GS, a comprehensive framework for 3D Gaussian scene compression. By integrating geometry-aware regulation, progressive masking, and multimodal storage compression, the framework successfully addresses the conflict between rendering quality, storage size, and processing speed. Experimental evidence demonstrates that GADC-GS provides an effective solution for high-quality real-time rendering in resource-constrained environments, breaking the trilemma of quality, storage, and speed in traditional methods.

Key words: 3D Gaussian Splatting; Model Compression; Intelligent Density Control; Residual Vector Quantization



网络首发:

标题: 几何感知调控与掩码稀疏化的高斯场景压缩

作者: 王禹童, 李少波, 刘昭, 肖博, 张广成

收稿日期: 2025-11-26

录用日期: 2026-01-08

DOI: 10.3788/LOP252467

引用格式:

王禹童, 李少波, 刘昭, 肖博, 张广成. 几何感知调控与掩码稀疏化的高斯场景压缩[J]. 激光与光电子学进展, 2026, 63(12): 1215010.

网络首发文章内容与正式出版的有细微差别, 请以正式出版文件为准!

您感兴趣的其他相关论文:

LiDAR点云深度学习模型的压缩和部署加速方法研究现状与展望 (特邀)

赵禄达 胡以华 赵楠翔 汪菲 王一程 董骁 韩飞 豆正磊 侯阿慧

国防科技大学电子对抗学院, 安徽 合肥 230037

激光与光电子学进展, 2024, 61(20): 2011005

基于融合差分卷积的受电弓安全触发目标实时检测定位方法

杨占山 张瀛 杜弘志 孙岩标 郝继贵

天津大学精密测试技术及仪器全国重点实验室, 天津 300072

激光与光电子学进展, 2024, 61(18): 1812001

基于深度学习的自适应动态滤波器剪枝方法

褚晶辉 李梦 吕卫

天津大学电气自动化与信息工程学院, 天津 300072

激光与光电子学进展, 2022, 59(24): 2415003

基于多粒度剪枝的水下遗迹实时目标检测

张有波 郭威 周悦 徐高飞 李广伟 孙洪鸣

上海海洋大学工程学院, 上海 201306

激光与光电子学进展, 2021, 58(14): 1410019

一种面向移动端的图像风格迁移模型压缩算法

裴斐 刘进锋 李峻河

宁夏大学信息工程学院, 宁夏 银川 750021

激光与光电子学进展, 2020, 57(6): 061021