

基于光照探针的三维高斯辐射场压缩算法*

宋明清^a, 郭尧^a, 李晓峰^{a,b}, 张严辞^{a,b†}

(四川大学 a. 计算机学院; b. 视觉合成图形图像技术国家级重点实验室, 成都 610065)

摘要: 针对三维高斯场景数据量庞大及视角相关外观难以保留的问题, 提出了一种基于光照探针的三维高斯辐射场压缩算法。该算法通过识别并裁剪冗余高斯图元、引入光照探针以降低球谐函数阶数, 以及基于图元重要性进行加权聚类, 有效减少了致密化策略以及表征视角相关颜色信息带来的冗余数据。主流数据集上的实验结果表明, 该方法有效降低了存储需求, 压缩率平均达 1/20, 同时保持高质量的视角效果与良好的视角相关性。该算法提供了一种有效压缩三维高斯场景的方式, 为三维高斯场景在游戏、虚拟现实及数字孪生等领域的应用提供了有力支持。

关键词: 新颖视图合成; 三维高斯泼溅; 模型压缩

中图分类号: TP391.41

文献标志码: A

文章编号: 1001-3695(2025)09-037-2840-07

doi: 10.19734/j.issn.1001-3695.2024.12.0512

Compression algorithm for 3D Gaussian radiance fields based on light probes

Song Mingqing^a, Guo Yao^a, Li Xiaofeng^{a,b}, Zhang Yanci^{a,b†}

(a. College of Computer Science, b. National Key Laboratory of Fundamental Science on Synthetic Vision, Sichuan University, Chengdu 610065, China)

Abstract: This paper proposed a compression algorithm for 3D Gaussian radiance fields using light probes to optimize storage efficiency while preserving view-dependent appearance. The algorithm identified and removed redundant Gaussian primitives, introduced light probes to lower the order of spherical harmonics, and employed weighted clustering based on the importance of Gaussian primitives. These operations effectively resolved data redundancy caused by densification strategies and view-dependent color representation approach. Experimental results on mainstream datasets demonstrated that the algorithm effectively reduces storage requirements. The algorithm achieves an average 1/20 compression ratio while maintaining visual quality and view-dependent appearance. It provides an effective method to compress 3D Gaussian scenes. It shows the potential in gaming, virtual reality, digital twins and other applications.

Key words: novel view synthesis (NVS); 3D Gaussian splatting (3DGS); model compression

0 引言

新颖视图合成(NVS)旨在以一组图像集作为输入, 得到任意新视角的高质量的三维场景图像, 在影视游戏、虚拟现实、数字孪生等领域有巨大潜力。神经辐射场^[1]是著名的 NVS 方法, 带来了卓越的重建质量。它通过基于多层感知机制(multi-layer perceptron, MLP)的神经网络, 对三维场景的密度和视角相关的颜色进行了高质量的重建。然而由于隐式方法和体渲染的计算开销较大, 即使有一些神经辐射场的变体进行了一定程度的优化, 训练和渲染的性能需求仍然难以满足对场景重建速度和渲染实时性具有较高要求的应用。最新的进展中, 基于点云的显式三维高斯泼溅方法(3D Gaussian splatting, 3DGS)^[2], 将三维场景的密度和颜色表征为三维高斯分布函数, 并使用泼溅的技术将点云渲染为场景。得益于显式的场景表征方式, 三维高斯泼溅方法在训练和渲染的效率以及渲染质量方面都达到了领先水平。

三维高斯泼溅的高质量重建主要依赖于三阶球谐函数对视角相关颜色的表征, 但这种方法也显著增加了每个高斯图元的空间开销。此外, 训练过程中采用的致密化策略显著增加了高斯图元的数量, 导致三维高斯场景在训练阶段的场景规模迅

速膨胀, 最终训练完毕的场景通常包含数百万个高斯图元。这种高密度数据表示显著提高了场景的存储需求。例如, 对于花园和自行车等场景, 存储空间需求超过了 1.3 GB。存储空间上的限制显著阻碍了三维高斯泼溅方法在实际应用中的推广。

为了减少三维高斯重建场景的存储空间, 同时尽可能保持渲染质量, 本文提出了一种针对三维高斯泼溅场景的压缩方法, 名为 Tiny GS。该方法的核心思想是减少冗余的信息。其中: 基于光照探针的压缩方法有效减少了球谐系数带来的存储负担; 改进的高斯图元裁剪方法能够利用基于光照探针着色反向传播的梯度以学习高斯图元的重要性并裁剪掉冗余高斯图元; 量化方法利用高斯图元的重要性减少了量化时所带来的质量损失。首先, 尽管三维高斯泼溅方法能够裁剪完全透明的高斯图元, 但该致密化策略仍会生成大量冗余的高斯图元。因此, 本文引入重要性属性以衡量每个高斯图元对场景重建质量的贡献, 利用该属性识别并裁剪对重建质量贡献较小的冗余图元。其次, 传统方法使用高阶球谐函数拟合高斯图元在不同视角下的颜色, 以表征视角相关的光照效果, 并占据了大量存储空间。实际上, 物体的颜色由视角、材质和光照共同决定, 因此本文利用光照探针拟合环境光照, 并对高斯图元进行重新着色, 以表征视角相关的颜色, 即采用存储空间更小的光照探针,

收稿日期: 2024-12-18; **修回日期:** 2025-02-12 **基金项目:** 四川省重点研发资助项目(2023YFG0122)

作者简介: 宋明清(1999—), 男, 重庆大足人, 硕士, CCF 会员, 主要研究方向为计算机图形学; 郭尧(2000—), 男, 河南焦作人, 硕士研究生, 主要研究方向为计算机图形学; 李晓峰(1973—), 男, 湖北枣阳人, 副教授, 主要研究方向为计算机应用、图形图像处理、视觉合成、三维人脸识别; 张严辞(1975—), 男(通信作者), 四川成都人, 教授, 博导, 博士, 主要研究方向为计算机图形学、并行绘制、虚拟现实、基于 GPU 的通用并行计算、3D 游戏技术(yzhang@scu.edu.cn)。

来代替原本占据大量存储空间的高阶球谐函数系数,以此对场景中的视角相关颜色进行重新建模,有效地减少了三维高斯场景的数据量。最后,本文对高斯图元的其他属性进行了进一步压缩,从而获得更为紧凑的表达。具体地,本文通过根据高斯图元的重要性对其缩放、基础颜色进行加权的矢量化,并根据其他属性的特点进行量化压缩,较大地减少了压缩所带来的质量损失,同时进一步降低了三维高斯场景的存储需求。

总而言之,本文的贡献如下:a)利用高斯图元的重要性裁剪冗余图元并加权量化高斯属性;b)将三维高斯的视角相关颜色用基于光照探针的着色来代替,使得三维高斯图元的属性更加紧凑;c)提出了一种基于光照探针的三维高斯场景压缩框架,三维高斯场景在接近原始建模质量的同时,极大减少了空间占用,并且拥有更好的光泽一致性。

1 相关工作

1.1 新颖视图合成

新颖视图合成技术是三维重建领域的重要研究方向,其主要目标是根据一组图像数据和位姿,生成任意指定视角下的图像。近年来,随着虚拟现实、自动驾驶等领域的迅速发展,利用新视图合成技术进行场景重建,从而创建虚拟资产或数字场景,已显著推动了多个领域的创新与进步。鉴于图像数据获取的便捷性及三维重建应用的广泛性,新颖视图合成技术已成为一个具有巨大潜力的研究方向。

神经辐射场(neural radiance fields, NeRF)利用神经网络表征场景,取得了新颖视图合成的惊艳效果。NeRF使用深度全连接神经网络将静态场景表征为连续函数,能够通过给定任意的坐标和方向,输出对应的体密度和视角相关的颜色,然后使用光线步进^[3]的方式混合采样得到的值。但是受限于神经网络的计算消耗,NeRF及相关神经辐射场的方法,例如基于体素^[4]以及哈希网格^[5]的方法,很难取得训练或渲染速度与图像质量的均衡。

点云是一种常用的三维场景表征方式,但基于点云的渲染通常面临孔洞和锯齿等问题。为克服这些缺陷,近年来的研究利用神经网络对三维点云及其相关特征进行建模,以表示辐射场,从而提供高质量的新颖视图合成结果,例如 Point-NeRF^[6]等。然而,由于仍依赖光线步进的渲染方法,需进行昂贵的体积采样来渲染像素,这使得该算法难以满足实时渲染的高计算需求。最近,三维高斯泼溅方法通过三维高斯点云显式地表征辐射场,并通过高斯图元的分裂、克隆和移动,实现了对场景几何信息的高质量重建。此外,三维高斯泼溅采用球谐函数来拟合视角相关的颜色信息,并通过高效的光栅化算法渲染新颖视图图像,从而实现了高质量的新颖视图合成与快速渲染。该算法的提出极大推动了新颖视图合成技术的实际应用。

1.2 三维高斯场景压缩

鉴于三维高斯泼溅在三维重建方面的巨大潜力,为解决其在存储成本上的瓶颈,目前已有多种针对三维高斯场景的压缩策略。

Compact GS^[7]提出了一种基于体积和不透明度的可学习高斯掩码,用于识别并剔除不必要的高斯图元。此外,该方法采用残差矢量化(R-VQ^[8])的方式,将高斯图元的缩放、旋转等几何属性映射到码本中。在视角相关颜色的表示上,该方法借鉴了类似于 Instant-NGP^[9]的基于网格的神经场来表征每个高斯图元的视角相关颜色。

Compressed GS^[10]主要基于矢量聚类对三维高斯场景进行压缩。该方法通过将图像质量与参数的梯度关联,视其为相关参数对最终图像质量的重要程度,在聚类过程中利用参数梯度

对距离进行加权,从而减小量化所带来的图像质量损失。此外,该方法采用量化感知机制对量化过程进行微调,以便使用较少的比特表示场景参数。在保存数据时,该方法还使用了 DEFLATE^[11]算法,对数据进行了进一步压缩,从而有效减小了三维高斯场景的存储需求。

Light GS^[12]通过统计每个高斯图元在各训练视角下占据的像素数量,结合不透明度和大小来衡量其在视图中的重要性,从而裁剪掉重要性得分较低的高斯图元,并对剩余图元进行微调,以恢复裁剪带来的重建质量损失。为进一步减少存储空间,该算法还采用数据蒸馏方法,利用三阶球谐函数生成新颖视图,并以此指导基于二阶球谐函数的场景训练,以减小球谐函数阶数降低视图相关颜色表征能力的影响。为满足不同高斯属性的需求,该方法对重要性较低的球谐函数应用矢量量化,对位置属性使用基于八叉树的无损压缩,且对其余属性采用半精度格式保存。

CompGS^[13]将矢量量化加入到了训练的过程中,并在此基础上,使用每个高斯点云相应的码字属性来替代其原有属性进行渲染和损失计算。此外,该算法还通过对索引进行排序,并使用类似游程编码的方法进一步压缩索引。为了促进剔除重要性较低的高斯图元,该算法引入了一种简单的正则化器,使这些图元的透明度属性趋向零,从而在较大程度上保持重建质量的同时,有效减少了高斯图元的数量。

Efficient GS^[14]通过隐式量化框架,利用 MLP 和解码器来压缩颜色和旋转属性,显著减少了每个高斯图元的内存使用量。然后引入渲染目标由粗糙到精细的训练策略,以更快、更稳定地优化高斯点云。

2 方法

本章首先介绍了三维高斯泼溅方法,然后详细阐述了为了减少三维高斯场景的存储空间而提出的改进高斯图元裁剪方法、基于光照探针的压缩方法以及基于图元重要性的量化方法。本文方法提出的压缩框架如图1所示。首先基于三阶球谐系数的三维高斯泼溅训练,得到三维高斯场景的图元分布;然后丢弃高阶的球谐系数,并利用基于物理的着色学习高斯图元的着色相关属性法线 n 、粗糙度 ρ 、反射率 f 以及附近的光照探针球谐系数。在初始化阶段,光照探针被均匀分布在场景空间中,同时剔除不会被任何高斯图元采样到的探针。在完成场景的训练后,本文会采用3.4节中提出的量化压缩方法,对三维高斯图元的其余属性进行压缩,并在压缩完成后移除高斯图元的重要性 w ,以进一步节省减少存储空间需求。




图1 本文压缩框架

Fig. 1 Compression framework in this paper

2.1 前置:三维高斯泼溅

三维高斯泼溅是一种强大的三维场景重建方法,利用高斯函数及其属性表征辐射场。之前的辐射场方法,例如 NeRF 等是隐式的方法,利用神经网络来表征三维场景的颜色和密度,然后使用光线步进的方法渲染图像进行可视化。而三维高斯泼溅是用点云来表征三维场景的显式方法,它使用高斯函数来表征三维空间的颜色和密度,同时保留了场景的可微特性,从而支持通过可微渲染框架优化高斯图元的几何和颜色属性。三维高斯泼溅利用显式的表征方式和高效的 GPU 并行算法,实现了快速的实时渲染。每一个三维高斯图元都由协方差矩

阵 Σ 和世界坐标下的中心 μ 定义:

$$G(x) = e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)} \quad (1)$$

为了保持协方差矩阵 Σ 的半正定,使用缩放矩阵 S 和旋转矩阵 R 来构建协方差矩阵, $\Sigma = RSS^T R^T$, 其中旋转和缩放矩阵分别以四元数 q 和三维向量 s 的形式来进行存储和优化。

三维高斯泼溅使用泼溅的方法渲染点云,这种方法会将三维高斯图元投影到二维的相机平面上,然后将重叠在每个像素上的 N 个图元进行排序,并通过混合得到该像素的最终颜色 C :

$$C = \sum_{i \in N} C_i \sigma_i \prod_{j=1}^{i-1} (1 - \sigma_j) \quad (2)$$

其中: σ_i 是由该高斯函数 $G_i(x)$ 和可优化的不透明度 α_i 相乘得到的密度值; $G_i(x)$ 是由可优化的高阶球谐函数表示的各向异性颜色值。使用 L 阶表示的颜色: $C_i = \sum_{l=0}^L \sum_{m=-l}^l c_l^m Y_l^m = \sum_{i=0}^L c_i Y_i$, 其中 c 为球谐系数, Y 为球谐基函数。

综上,每个高斯图元属性定义如下:决定高斯图元位置的均值 $\mu \in \mathbb{R}^3$ 、决定各向异性椭球形状的缩放 $s \in \mathbb{R}^3$ 和旋转 $q \in \mathbb{R}^4$ 、不透明度 $\alpha \in \mathbb{R}$ 、三阶球谐系数 $c \in \mathbb{R}^{48}$ 。如图 2 所示,每个高斯图元的属性由 59 个浮点数组成,其中大部分存储空间被用于高阶颜色球谐系数,以表征三维场景在不同视角下的辐射场信息。因此,在保留视角相关外观的前提下,减少球谐函数的空间占用成为压缩三维高斯泼溅场景的关键步骤。




图 2 每个高斯图元的空间占用百分比

Fig. 2 Percentage of space occupied by each Gaussian primitive

2.2 高斯图元裁剪

在场景训练过程中,高斯图元以稀疏点云为起点逐步生长,当检测到某些区域的高斯图元位置梯度过大时,通常表明该区域的重建质量仍需改进。为此,提出了一种基于高斯图元体积大小的致密化策略,通过克隆或分裂并调整位置,以进一步优化几何结构的重建效果。然而,该致密化策略引入了冗余的高斯图元,并且不同高斯图元对重建质量的贡献存在差异。因此,有效识别并裁剪这些冗余高斯点对于降低空间占用具有关键意义。受到 Compact GS^[7] 的启发,本文为高斯函数引入衡量其对重建质量重要性的属性 w 。重要性低于特定阈值的高斯图元可视作对重建质量无显著贡献,因此,这些低于设定重要性阈值 ε 的图元可以被合理裁剪以优化点云结构。为了增强属性 w 对高斯图元重要性的表征能力,引入先验的高斯图元显著性指标 $I^{[12]}$,并基于该指标对属性 w 进行了加权处理:

$$I_j = \sum_{i=1}^{MHW} H(G(X_j), T_i) \cdot \sigma_j \quad (3)$$

$$w_j = \sigma(m_j \cdot I_j)$$

其中: j 表示高斯图元的索引; MHW 表示视图的数量和尺寸; H 为指示函数,用于判断视线 T_i 是否与高斯图元相交; m_j 是引入的可学习实数掩码,用于学习高斯图元的重要性。

为了在将重要性依据阈值进行二值化(0 或 1)的同时,确

保梯度能够反向传播,引入了直通估计器来生成二值掩码 $M \in \{0, 1\}^N$:

$$M_i = \text{sg}(\mathcal{I}(w_i - \varepsilon) - w_i) + w_i \quad (4)$$

其中: sg 为梯度停止算子; $\mathcal{I}$ 为指示函数。体积和不透明度属性对衡量重要性有较大影响,把基于重要性生成的高斯掩码 M 作用在不透明度 α 和缩放 s 上:

$$\hat{s}_i = M_i s_i, \hat{\alpha}_i = M_i \alpha_i \quad (5)$$

其中: $\hat{s}_i$ 和 $\hat{\alpha}_i$ 为掩码化的缩放与不透明属性,在渲染中被实际使用。

为实现对高斯图元的有效裁剪,本文引入 L1 正则化项,在优化过程中引导重要性 w 在优化过程中趋向于 0,从而促使冗余图元被移除:

$$\mathcal{L}_w = \frac{1}{N} \sum_{i=0}^N |w_i| \quad (6)$$

2.3 视角相关颜色压缩

本文方法通过引入光照探针替代传统三维高斯泼溅中使用的高阶球谐函数,用于拟合场景中的光照信息。随后,基于拟合结果对高斯图元进行着色,以实现三维高斯场景中视角相关颜色的有效压缩。在三维高斯泼溅方法中,高阶球谐函数用于表示视角相关的辐射场信息,其中零阶球谐函数表征视角无关的漫反射颜色,而更高阶的球谐函数用于表征更复杂的视角相关光照效果。由于球谐系数的数量随着阶数呈平方速率增长,采用逐图元的球谐函数存储与视角相关的辐射场信息,将会导致显著的存储空间开销。现有方法中,一些直接对三维高斯分布的颜色进行量化压缩,另一些则通过新技术(如神经网络)重新表达颜色以实现压缩。然而,这些方法未能充分利用几何信息,常导致视角相关颜色信息的损失。高斯辐射场表征了场景中每一点沿各个方向的辐射度 $L(p, \omega)$, p 为空间中某一点的坐标, ω 表示一个单位方向向量,定义了辐射的方向。由于辐射度 L 是一个球面函数,会随着观察视角而变化,所以三维高斯泼溅方法使用球谐函数 $C(\omega)$ 来对 L 进行拟合,以表征视角相关颜色,但是大量的拟合系数带来了巨大的存储负担。本文用基于物理的渲染方程对场景中每个点的辐射度 L 进行建模,引入光照探针并基于拟合结果对高斯图元进行着色,实现对 L 的近似。传统三维高斯泼溅使用 $N \times 4^2 \times 3$ 个球谐系数来表征,而本文方法仅有少量光照探针和 $N \times 4$ 个高斯着色属性参数,替代了占用更多存储空间的高阶球谐系数表示方法,极大地减少了高斯图元的空间占用。并且由于利用了几何与光照的信息,拥有更好的视角相关颜色表现。

为了获取环境中的光照,本文引入了一种可优化的光照探针方法。光照探针是一种在计算机图形学中广泛应用的技术,用于记录特定位置的环境光照信息,包括直接光和间接光。通过在场景中不同位置布置光照探针,可以有效模拟不同区域的光照变化,从而提升整体光照的真实感。尽管光照探针可以采用立方体贴图进行表示,但这种表示方式会带来较大的存储开销。考虑到相较于镜面反射,光泽反射所需的环境光照信息属于相对低频信息,因此光照探针可以用球谐函数^[15]来表示,以减少存储需求。

为了更精确地表达视角相关的颜色变化,本文采用基于物理的渲染方法对高斯场景进行渲染。在基于物理的渲染框架中,物体表面的颜色由反射方程^[16]定义,该方程描述了物体表面在忽略自发光的情况下,如何接收环境光照并将其反射至观察视角的过程:

$$L_o(p, \omega_o) = \int_{\Omega} f_r(p, \omega_i, \omega_o) L_i(p, \omega_i) (n \cdot \omega) d\omega \quad (7)$$

根据 Cook-Torrance BRDF 模型^[17],上述光照方程可以分为漫反射环境光和光泽反射环境光两部分。

$$f_r(p, \omega_i, \omega_o) = k_d f_{\text{lambert}} + f_{\text{cook-torrance}} = k_d \frac{c}{\pi} + \frac{DFG}{4(\omega_o \cdot n)(\omega_i \cdot n)} \quad (8)$$

其中:漫反射部分会在所有出射角度上均匀地进行反射,对于每一个观察角度,积分的结果为常数,由零阶球谐进行表征。光泽反射部分则由双向反射分布函数(BRDF) $f_c = \frac{DFG}{4(\omega_o \cdot n)(\omega_i \cdot n)}$ 构成,其中各分量为法线分布函数 $D(n, h, \alpha)$ 、几何函数 $G(n, v, \alpha)$ 、菲涅尔函数 $F(h, v, F_0)$ 。其中, n 为法线、 h 为半程向量(视线和光线的中值)、 v 为视线、 F_0 为物体的基础反射率。光泽反射部分是一个依赖于观察视角的函数,对于每个观察视角,需要对入射光照进行积分。

为加速光泽反射的求解,本文采用分割近似求和方法^[18],将光泽反射部分的积分转换为两个积分的乘积形式。

$$L_s = \int_{\Omega} f_c(p, \omega_i, \omega_o) L_i(p, \omega_i) n \cdot \omega_i d\omega_i \approx \int_{\Omega} L_i(p, \omega_i) d\omega_i \times \int_{\Omega} f_c(p, \omega_i, \omega_o) n \cdot \omega_i d\omega_i \approx L_{\text{light}} \times F_{\text{spec}} \quad (9)$$

其中:光照项 L_i 的积分 L_{light} 可通过球谐函数来进行表征^[19]; BRDF 函数 $f_c(p, \omega_i, \omega_o)$ 的积分可以通过预计算生成查找纹理(LUT),并根据粗糙度 ρ 与视线和法线之间的余弦值进行查找,然后通过反射率 f 结合来得到反射系数 $F_{\text{spec}} = f \times LUT.x + LUT.y$ 。由于 BRDF 函数的定义域较小,所以该近似值趋近于真值。

为结合光照探针表达视角相关颜色,本文为每个三维高斯图元引入可学习的属性:法线 n 、反射率 f 、粗糙度 ρ ,并为三维高斯场景引入可学习的光照探针,以捕捉环境光照。通过基于物理的着色以代替原本的高阶球谐系数,每个高斯图元的着色公式如下:

$$C = C_0 + L_s \\ C_0 = L_{\text{light}} \times F_{\text{spec}} \quad (10)$$

其中: L_{light} 是通过对高斯图元附近的光照探针的采样结果进行三线性插值得到的。对于着色,本文引入可微渲染模块^[20],使得基于物理的着色过程可以通过梯度的反向传播优化。

为了估计正确的法线,受到文献[21]启发,本文使用高斯的位置渲染出深度图,并利用深度图的梯度导出预估法线 $\hat{n}$,利用预估法线来指导法线的学习。为了使法线更加平滑,应用平滑形式的 TV 项损失函数,法线的损失函数如下:

$$\mathcal{L}_n = \lambda_d \| \hat{n} - n \| + \lambda_n \sum_{u \in U} \sqrt{(n - n_u)^2} \quad (11)$$

其中: λ_d 和 λ_n 分别是参数; U 是 n 附近的法线集合。

2.4 属性压缩

量化能够将多维的数据映射到一个较小的离散集合中的元素,这个集合也被称为码本。码本是原始数据的紧凑表示,去除了冗余的信息,用最显著的特征来表征数据。在实验中,本文观察到高斯点的缩放 s 以及基础颜色呈现出明显的聚类特征,因此对这些属性应用矢量量化来进行压缩。

在普通的矢量量化压缩的基础上,本文引入了基于重要性的加权量化压缩方法。传统的矢量量化压缩对每个高斯图元的属性采用均等处理,但由于每个高斯图元对三维重建的影响程度不同,这种均等处理会导致重要性较高的高斯图元在压缩过程中产生较大的损失,从而影响压缩后场景的重建质量。因此,本文采用 2.2 节中引入的重要性,通过该重要性对高斯图元进行加权的 K-means 聚类。

$$c_k = \lambda \cdot c_k + (1 - \lambda) \cdot \frac{1}{T_k} \sum_{g_j \in \mathcal{R}(c_k)} w_j \cdot g_j \quad (12)$$

其中: c_k 为第 k 个聚类的中心; $\mathcal{R}(c_k)$ 为属于聚类中心对应的点云集合; g_j 为对应的高斯图元的属性; $T_k = \sum_{g_j \in \mathcal{R}(c_k)} w_j$ 。本文实

验表明,相对于普通的量化压缩所采用的聚类方法,通过加权的聚类方法对三维高斯场景进行压缩,能够产生更小的损失。

针对高斯图元的位置 μ ,本文发现对位置的量化会导致图元的混叠,实验结果表明,量化位置时会产生显著的精度损失,在渲染的图片上会出现明显的网格化的伪影。为此,本文选择使用半精度存储以平衡存储效率与渲染质量。针对旋转属性 r ,直接采用矢量量化会在几何边界处引入毛刺伪影,而通过对每个分量分别进行标量量化可有效避免这一问题。不透明度 α 为标量,其分布主要集中在 0、1 附近,因此适合采用标量量化方法。对于旋转属性 r 的各分量以及不透明度 α ,标量量化时采用量化感知技术^[10,22]模拟量化的影响,帮助三维高斯图元适应使用低精度数据进行渲染,从而减少量化引入的误差。对高斯属性采用伪量化方法,训练时参数仍以高精度存储,在训练完成后使用低精度方式存储。在渲染时首先使用将属性四舍五入到低精度表示:

$$q = \text{round}\left(\frac{x - x_{\min}}{\Delta}\right) \cdot \Delta + x_{\min} \quad (13)$$

其中: $\Delta = \frac{x_{\max} - x_{\min}}{2^8 - 1}$ 是量化的步长。然后将量化后的值反映射回浮点数范围,用于后续渲染与梯度计算。这个过程中通过量化的损失对参数的量化范围($x_{\min}$ 和 $x_{\max}$)进行动态调整,以适应不同属性值的分布,减小量化误差。在将三维高斯场景保存为文件的过程中,可以采用哈夫曼编码对数据进行压缩,从而进一步降低其存储空间需求。

2.5 损失函数

本文方法的总损失函数为式(14)。

$$\mathcal{L} = (1 - \lambda_r) \mathcal{L}_1 + \lambda_r \mathcal{L}_{\text{D-SSIM}} + \lambda_w \mathcal{L}_w + \mathcal{L}_n \quad (14)$$

其中: $\mathcal{L}_1$ 为渲染得到的图像与目标图像的绝对误差损失; $\mathcal{L}_{\text{D-SSIM}}$ 为结构相似性度量损失函数; λ 为超参数。

3 实验

3.1 数据集

为了全面验证本文方法的有效性,在 3DGS 中的 Mip-NeRF 360^[23] 的九个场景、Tanks&Temples^[24] 和 Deep Blending^[25] 的各两个场景,NeRF 中的 NeRF-Synthetic 的八个场景以及 NeRO^[26] 中的 Glossy Synthetic 的八个场景上进行验证。这些场景包含了室外的无边界的真实场景、室内场景以及以物体为中心的合成场景,场景内的物体有丰富的材质,包括漫反射的物体与光泽反射的物体。

3.2 实现细节

所有实验均在以下硬件环境中完成: Intel i7-12700 CPU、64 GB 内存、NVIDIA RTX 3090 GPU。

本文采用的超参数和 3DGS 一致,高斯场景训练和裁剪迭代 30 k 次,提取视角相关颜色训练迭代 20 k 次。光照探针采用 10 阶球谐函数以表达局部的环境光照。 λ_d 和 λ_n 的值分别为 0.001 和 0.01。由于真实场景与合成场景的规模不同,设置不同的超参数有助于在重建质量和存储成本之间取得平衡。对于真实场景, λ_w 为 $5\text{E-}4$,光照探针个数为 32^3 ;对于虚拟场景, λ_w 为 $2\text{E-}4$,光照探针个数为 8^3 。矢量量化的码本大小为 8 192,标量量化使用 8 位整数来表示数据。

对于 Compact GS^[7],本文实验时将残差矢量量化的码本大小和级数分别设置为 64 和 6。与视图相关的颜色的神经网络使用的哈希网格具有 2 通道的特征和 16 种不同分辨率,MLP 具有 2 层 64 通道。真实场景下,哈希表的大小设置为 2^{19} ,掩码超参数为 $5\text{E-}4$,掩码参数和神经网络的学习率为 $1\text{E-}2$,神经场

的学习率在 5 k、15 k 和 25 k 次迭代时会降低 0.33 倍。对于虚拟场景,哈希表的大小设置为 2^{16} ,掩码超参数为 $4E^{-3}$,掩码超参数和神经场的学习率设置为 $1E^{-3}$,神经场的学习率在 25 k 迭代时降低 0.33 倍。

对于 Light GS^[12],本文实验在训练迭代 20 k 时进行裁剪,裁剪比例为 0.6,裁剪所需的体积控制参数 β 为 0.1,执行蒸馏的迭代次数为 10 k 次,球谐阶数保留 2 阶。执行矢量量化的球谐比例为 60%,码本大小为 8 192,对不透明度、旋转和缩放使用半精度进行存储。

对于 CompGS^[13],本文实验时对旋转、缩放和零阶系数使用大小为 4 096 的码本进行压缩,对于高阶系数使用大小为 512 的码本进行压缩。每训练 100 次迭代 10 次聚类算法。不透明度的稀疏控制系数为 $1E^{-7}$ 。

对于 Compressed GS^[10],本文实验时使用衰减因子 $\lambda_d=0.8$ 进行批量聚类,其中高斯的几何属性每次更新迭代 800 次,球谐系数每次更新迭代 100 次。颜色特征使用的批量大小为 218,高斯的几何属性使用批量的大小为 220。使用 4 096 作为码本大小,要执行量化的阈值参数分别是:颜色参数 $\beta_c=6\times 10^{-7}$ 和几何参数 $\beta_g=3\times 10^{-6}$ 。量化感知微调的迭代次数为 5 000 次。

对于 Efficient GS^[14],本文实验分别对高阶球谐系数、旋转、不透明度使用维度为 16、8、1 的隐向量进行压缩,不对零阶球谐系数、缩放和位置进行隐式编码。训练过程中,目标图像的缩放因子从 0.3 开始,然后以余弦的方式增加到 1.0,对前

表 1 各方法的重建质量及存储空间

Tab. 1 Reconstruction quality and storage space of each method

方法	Mip-NeRF360				Tanks&Temples				Deep Blending				NeRF-Synthetic				Glossy Synthetic			
	SSIM ↑	PSNR ↑	LPIPS ↓	SIZE ↓	SSIM ↑	PSNR ↑	LPIPS ↓	SIZE ↓	SSIM ↑	PSNR ↑	LPIPS ↓	SIZE ↓	SSIM ↑	PSNR ↑	LPIPS ↓	SIZE ↓	SSIM ↑	PSNR ↑	LPIPS ↓	SIZE ↓
3DGS-L3	0.813	27.50	0.221	748.35	0.845	23.66	0.179	431.67	0.899	29.41	0.247	661.73	0.970	33.33	0.030	68.17	0.914	26.03	0.087	61.24
3DGS-L0	0.801	26.84	0.234	201.91	0.834	23.13	0.192	116.27	0.900	29.42	0.248	182.12	0.963	31.60	0.038	18.79	0.910	25.38	0.094	18.89
Compact GS	0.803	27.01	0.238	82.14	0.837	23.33	0.192	47.08	0.904	29.77	0.248	72.47	0.967	32.66	0.035	7.25	0.913	25.73	0.092	6.67
Light GS	0.796	26.85	0.253	65.18	0.816	23.02	0.230	38.22	0.870	26.96	0.302	45.32	0.962	31.84	0.043	5.78	0.914	25.97	0.096	4.61
CompGS	0.798	27.04	0.247	48.81	0.832	23.31	0.201	39.40	0.901	29.73	0.257	43.01	0.968	32.80	0.033	5.75	0.910	25.73	0.092	6.18
Compressed GS	0.802	27.15	0.242	27.95	0.841	23.56	0.188	17.62	0.903	29.42	0.255	23.76	0.968	32.95	0.032	3.79	0.913	26.00	0.088	3.81
Compressed GS*	0.802	27.15	0.242	49.36	0.841	23.56	0.188	30.05	0.903	29.42	0.255	42.99	0.968	32.95	0.032	6.10	0.913	26.00	0.088	5.92
Efficient GS	0.809	27.17	0.230	58.85	0.832	23.17	0.203	28.83	0.905	29.71	0.245	20.95	0.965	32.28	0.037	4.51	0.910	25.57	0.096	7.44
Tiny GS	0.802	26.94	0.238	40.36	0.829	23.32	0.210	32.79	0.892	29.57	0.256	40.59	0.965	32.61	0.036	3.98	0.916	27.09	0.085	4.39

3.4 对比

本文在真实和合成数据集的多个场景上验证了压缩后的重建质量,图 3 展示了具有代表性的场景及其存储空间占用情况。3DGS $L=0$ 是只用零阶球谐函数的三维高斯泼溅方法,它有效地降低了存储空间,但是带来了质量的损失,相比于使用三阶球谐函数的三维高斯泼溅方法,在视角相关颜色上表现不佳,具体表现为:花园中的桌子、茶壶盖子、架子鼓的擦片、铃铛下部的反射光泽几乎消失,茶壶壶身、铃铛中部上场景反射相比于三阶方法更加杂乱。Compressed GS 在 3DGS 的基础上对场景进行压缩,其在保持质量的同时,有效减少了存储的空间,但无法解决 3DGS 在反射光泽重建方面的缺陷。本文方法在上述区域拥有更好的视角相关颜色表现。实验结果表明,本文方法在显著减少三维高斯场景存储空间的同时,能够在较大程度上保留三维高斯泼溅的重建质量,并对场景中的反射光泽有较强的表征能力。

现有压缩方法主要通过量化等技术对高阶球谐函数进行压缩,以表达视角相关颜色。然而,这类方法在光泽反射的表达能力上存在局限性,难以在视角变化时保持物理一致性。本文提出了一种基于光照探针的视角相关颜色表达方法,采用基于物理的着色模型,每个点的颜色由视线、材质、几何与光照共同决定。相比传统方法,该方法在视角变化时表现出更高的颜色变化一致性。图 4 展示了本文方法在视角相关颜色表征方

70%的迭代执行目标图像缩放,后 30%的迭代以全分辨率训练。此外,将不透明度重置间隔固定为每 2 500 次迭代,将致密化频率固定为每 250 次迭代。

3.3 基准和指标

本文方法与分别采用 0 阶和 3 阶球谐函数的三维高斯泼溅方法、CompGS、Light GS、Compact GS、Compressed GS、Efficient GS 等方法的性能进行了对比分析,其结果如表 1 所示。表 1 数据基于使用推荐参数复现对应论文所得到的结果,与原文中提供的原始数据基本一致。本文遵循常见的图像质量评估指标,使用峰值信噪比(peak signal to noise ratio, PSNR)、结构相似性指数(structural similarity index, SSIM)和学习感知图像块相似度(learned perceptual image patch similarity, LPIPS)对重建质量进行评估。

表 1 中,Compressed GS 方法实现了最高的压缩比率,这得益于其采用了 DEFLATE 文件压缩算法,而其余方法并未对场景的点云文件进行基于熵编码的文件压缩。为了保证对比的公平性,Compressed GS* 为未采用 DEFLATE 文件压缩算法的场景大小。实验结果表明,在 Mip-NeRF360 和 Deep Blending 以及 NeRF-Synthetic 场景下,渲染质量优于平均的压缩算法,且达到了最小的存储空间。同时,本文方法在 Glossy Synthetic 场景上取得了效果和空间上的最优性能,表现了本文方法在压缩视角相关颜色方面的能力。

面的优势,随着视角移动,场景中物体的不同位置能够真实地反射光泽效果。




图 3 新颖视角合成的定性比较

Fig. 3 Qualitative comparison of novel view synthesis

3.5 消融实验

表 2 以 Mip-NeRF360 中的花园场景和 Glossy Synthetic 中的茶壶场景为例,展示了本文提出的压缩框架各个组成部分对于重建质量和存储空间的影响。首先,通过对冗余高斯图元裁剪,存储空间减少约为原来的 1/3;在此基础上,基于光照探针的视角相关颜色压缩,进一步节省了 2/3 的空间。完成上述步骤后,对其他属性进行压缩,存储空间再次减少至原来的 1/2。整体而言,本文方法最终将存储空间压缩至初始需求的约

1/20。同时,实验结果表明,基于重要性加权的矢量量化方法 能够有效地减少重建质量的损失。




图4 连续视角下的三维场景

Fig. 4 3D scenes from continuous perspectives

表2 消融实验

Tab. 2 Ablation experiment

方法	Mip-NeRF360				Glossy Synthetic			
	SSIM	PSNR/dB	LPIPS	SIZE	SSIM	PSNR/dB	LPIPS	SIZE
基准(3DGS)	0.856	27.29	0.122	1 336	0.876	21.05	0.103	52.9
+图元裁剪	0.845	27.01	0.141	412	0.870	21.19	0.100	16.20
-球谐系数	0.832	26.45	0.133	119	0.878	20.79	0.107	4.67
+光照探针	0.830	26.63	0.130	165	0.900	23.67	0.096	6.54
+量化	0.830	26.32	0.140	54.8	0.893	23.10	0.100	4.21
+加权量化	0.832	26.56	0.129	54.8	0.894	23.23	0.105	4.21

a) 图元裁剪。为了直观展示裁剪高斯图元对高斯图元密度和重建质量的影响,图5展示了在将高斯图元缩小至原始大小的1/100后的结果。裁剪后的高斯点云密度显著降低,但渲染质量并未明显下降。表3进一步对比了本文提出的裁剪方法与 Compact GS 方法的效果,结果表明,本文方法在保持接近重建质量的同时,具有更高的裁剪比率。此外,Compact GS 方法在某些场景中会导致过度裁剪,从而引发显著的质量损失,而本文基于重要性的裁剪方法有效避免了这一问题。



图5 裁剪前后点云对比

Fig. 5 Comparison of point clouds before and after pruning

表3 图元裁剪方法对比

Tab. 3 Comparison of primitive pruning methods

方法	garden		bicycle		room		teapot		lego	
	PSNR/dB	SIZE	PSNR/dB	SIZE	PSNR/dB	SIZE	PSNR/dB	SIZE	PSNR/dB	SIZE
3DGS	27.29	1336	25.11	1351	31.74	351	21.05	52.84	35.77	76.6
Compact GS	27.06	534	24.83	639	31.48	128	21.23	17.4	31.78	7.45
Tiny GS	27.01	412	24.74	417	31.36	83.5	21.19	16.2	34.41	23.6

b) 训练流程。本文采用的两阶段训练策略,在现有高斯点云分布基础上进行光照与属性的学习,从而生成更为准确的法线。该策略有效避免了联合优化初期在不正确几何模型上生成法线,进而防止法线收敛到错误的方向,如图6所示。

c) 光照探针。图7展示了裁剪与基于探针的光照对漂浮

物的影响。基于重要性的裁剪方法有效地减轻了漂浮物伪影的产生。漂浮物通常由三维高斯分布在特定视角下的过拟合现象引起,其重要性仅在少数视角下较高,因此在训练过程中,大部分漂浮物会因收敛至较低的重要性分数而被裁剪。基于探针的光照也有助于减少漂浮物的产生。与高阶球谐函数相比,基于探针的光照具有明确的物理基础,能够在视角变化时更真实地反映光照的变化情况,从而使高斯图元能够收敛到更加准确的几何表示。表2展示了光照探针对存储空间和重建质量的影响。在真实场景中,本文方法能够保留视角相关的颜色信息;而在虚拟场景中,相比于球谐函数,本文方法能够更有效地表征视角相关的颜色变化。




图6 预估法线对比

Fig. 6 Estimated normals comparison



图7 不同方法对漂浮物的影响

Fig. 7 Effects of different approaches on floaters

4 结束语

本文提出了一种基于光照探针的三维高斯场景压缩框架,

在保持重建质量的同时,显著减少了三维高斯场景的存储空间。该方法能够增强视角相关颜色的表现,并有效减少漂浮物等伪影的产生。实验结果表明,本文方法将存储空间压缩至原来的1/20。未来研究可进一步探索如何优化光照探针的位置和数量,或通过引入高斯图元的几何遮挡信息,以进一步提升视角相关颜色的表现。

参考文献:

- [1] Mildenhall B, Srinivasan P P, Tancik M, *et al.* NeRF: representing scenes as neural radiance fields for view synthesis [J]. *Communications of the ACM*, 2021, 65(1): 99-106.
- [2] Kerbl B, Kopanas G, Leimkuehler T, *et al.* 3D Gaussian splatting for real-time radiance field rendering [J]. *ACM Trans on Graphics*, 2023, 42(4): 1-14.
- [3] Levoy M. Efficient ray tracing of volume data [J]. *ACM Trans on Graphics*, 1990, 9(3): 245-261.
- [4] Chen Anpei, Xu Zexiang, Geiger A, *et al.* TensorRF: tensorial radiance fields [M]// Avidan S, Brostow G, Cissé M, *et al.* *Computer Vision*. Cham: Springer, 2022: 333-350.
- [5] Fridovich-Keil S, Yu A, Tancik M, *et al.* Plenoxels: radiance fields without neural networks [C]// Proc of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2022: 5491-5500.
- [6] Xu Qiangeng, Xu Zexiang, Philip J, *et al.* Point-NeRF: point-based neural radiance fields [C]// Proc of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2022: 5428-5438.
- [7] Lee J C, Rho D, Sun Xiangyu, *et al.* Compact 3D Gaussian representation for radiance field [C]// Proc of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2024: 21719-21728.
- [8] Zeghidour N, Luebs A, Omran A, *et al.* SoundStream: an end-to-end neural audio codec [J]. *IEEE/ACM Trans on Audio, Speech, and Language Processing*, 2021, 30: 495-507.
- [9] Müller T, Evans A, Schied C, *et al.* Instant neural graphics primitives with a multiresolution hash encoding [J]. *ACM Trans on Graphics*, 2022, 41(4): 1-15.
- [10] Niedermayr S, Stumpfegger J, Westermann R. Compressed 3D Gaussian splatting for accelerated novel view synthesis [C]// Proc of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2024: 10349-10358.
- [11] Deutsch P. DEFLATE compressed data format specification version 1.3 [J]. *RFC*, 1996, 1951: 1-17.
- [12] Fan Zhiwen, Wang K, Wen Kairun, *et al.* LightGaussian: unbounded 3D Gaussian compression with 15x reduction and 200+ FPS [EB/OL]. (2023-11-28). <https://arxiv.org/abs/2311.17245>.
- [13] Navaneet K L, Pourahmadi Meibodi K, Abbasi Koohpayegani S, *et al.* CompGS: smaller and faster Gaussian splatting with vector quantization [C]// Proc of the 18th European Conference on Computer Vision. Cham: Springer, 2024: 330-349.
- [14] Girish S, Gupta K, Shrivastava A. EAGLES: efficient accelerated 3D Gaussians with lightweight EncodingS [M]// Leonardis A, Ricci E, Roth S, *et al.* *Computer Vision*. Cham: Springer, 2024: 54-71.
- [15] Green R. Spherical harmonic lighting: the gritty details [C]// Proc of Game Developer's Conference. 2003: 10025393942.
- [16] Kajiya J T. The rendering equation [J]. *ACM SIGGRAPH Computer Graphics*, 1986, 20(4): 143-150.
- [17] Cook R L, Torrance K E. A reflectance model for computer graphics [J]. *ACM Trans on Graphics*, 1982, 1(1): 7-24.
- [18] Hill S, McAuley S, Belcour L, *et al.* Physically based shading in theory and practice [C]// Proc of ACM SIGGRAPH 2020 Courses. New York: ACM Press, 2020: 1-12.
- [19] Ramamoorthi R, Hanrahan P. An efficient representation for irradiance environment maps [C]// Proc of the 28th Annual Conference on Computer Graphics and Interactive Techniques. New York: ACM Press, 2001: 497-500.
- [20] Laine S, Hellsten J, Karras T, *et al.* Modular primitives for high-performance differentiable rendering [J]. *ACM Trans on Graphics*, 2020, 39(6): 1-14.
- [21] Jiang Y, Tu Jiadong, Liu Yuan, *et al.* GaussianShader: 3D Gaussian splatting with shading functions for reflective surfaces [C]// Proc of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2024: 5322-5332.
- [22] Jacob B, Kligys S, Chen Bo, *et al.* Quantization and training of neural networks for efficient integer-arithmetic-only inference [C]// Proc of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2018: 2704-2713.
- [23] Barron J T, Mildenhall B, Verbin D, *et al.* Mip-NeRF 360: unbounded anti-aliased neural radiance fields [C]// Proc of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2022: 5460-5469.
- [24] Knapitsch A, Park J, Zhou Qianyi, *et al.* Tanks and temples [J]. *ACM Trans on Graphics*, 2017, 36(4): 1-13.
- [25] Hedman P, Philip J, Price T, *et al.* Deep blending for free-viewpoint image-based rendering [J]. *ACM Trans on Graphics*, 2018, 37(6): 1-15.
- [26] Liu Yuan, Wang Peng, Lin Cheng, *et al.* NeRO: neural geometry and BRDF reconstruction of reflective objects from multiview images [J]. *ACM Trans on Graphics*, 2023, 42(4): 1-22.

下期要目

◆ 胶囊网络综述

◆ 深度学习小目标检测算法综述

◆ 基于智能合约信誉管理的 VANET 数据共享隐私保护方案

◆ 一种编辑可控且可追责的可编辑区块链方案

◆ 基于不确定性估计的微调代码生成模型与大语言模型的协同方法

◆ 基于提示引导多跳推理的医学诊断检索增强生成

◆ 基于练习题目文本语义嵌入的知识追踪

◆ 基于环境识别策略的多目标自适应粒子群算法及应用

◆ 考虑能耗的自动化集装箱码头 AGV 无冲突路径规划

◆ 易混淆样本驱动的簇间分布优化短文本聚类

◆ 融合实体特征聚合和关系语义聚合的推理模型

◆ 基于大模型的污染规范提取方法

◆ 面向函数图像数据的多模态大模型训练策略

◆ 基于动态页面映射的远程交换系统内存管理优化

◆ SIC: 面向大语言模型训练的增量检查点技术

◆ 移动边缘网络的内容缓存和推荐联合决策方案

◆ 基于任务抢占的 VEC 计算卸载与缓存优化方法

◆ 基于局部差分隐私的动态聚类个性化联邦学习

◆ DLC-TSM: 一种用以加密恶意流量分类的高维特征图方法

◆ 面向自动驾驶的稀疏深度图补全方法 SFN-D

◆ 基于 Mamba 空间注意力与通道交互注意力模块的双路径脑肿瘤分割方法

◆ 基于无监督学习的无砭轨道表面异常分割

◆ 多分支骨架特征输入下的歧义行为识别

◆ 基于多尺度模态融合的 RGB-D 显著性目标检测网络