



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目: 基于几何可见性感知体渲染显著性的紧凑 3DGS
作者: 何金旭, 薛苏玲, 李霁潼, 张塘, 娄路
网络首发日期: 2026-03-27
引用格式: 何金旭, 薛苏玲, 李霁潼, 张塘, 娄路. 基于几何可见性感知体渲染显著性的紧凑 3DGS[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20260326.1646.013>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于几何可见性感知体渲染显著性的紧凑 3DGS

何金旭, 薛苏玲, 李霁潼, 张塘, 娄路⁺

重庆交通大学 信息科学与工程学院, 重庆 400074

⁺ 通信作者 E-mail: cloudlou@163.com

摘要: 3D 高斯泼溅 (3D Gaussian Splatting, 3DGS) 虽在三维重建与新视角合成中表现优异, 但在复杂场景中易产生大量冗余基元, 显著增加计算与内存开销; 且其基于光栅化的渲染管线在处理复杂遮挡时面临排序挑战, 易导致高频细节区域出现模糊或伪影。为此, 提出一种基于几何可见性感知体渲染显著性的紧凑 3DGS 方法 (Geometric Visibility-Aware Volumetric Saliency based compact 3DGS, GVS-Gaussian)。该方法在体渲染框架下显式建模高斯基元在多视角条件下的可见一致性、几何结构贡献与透射率累积效应, 实现对基元重要性的全局评估; 提出基于多层感知机的自适应学习剪枝算法, 有效剔除低贡献冗余基元; 结合量化编码策略压缩主要参数, 降低模型存储空间。实验结果表明: 在 Blender 室内场景中, GVS-Gaussian 将高斯数量减少 84%, 实现 37.7 倍模型压缩率, 且渲染质量保持稳定; 在 Tanks and Temples 户外场景中, 基元数量减少 50%, 达到 11.66 倍模型压缩率, 渲染质量优于对比方法。

关键词: 新视角合成; 3D 高斯泼溅; 高斯剪枝; 光线追踪; 体渲染

文献标志码: A **中图分类号:** TP391.41 **doi:** 10.3778/j.issn.1002-8331.2509-0351

Compact 3D Gaussian Splatting via Geometric Visibility-Aware Volumetric Saliency

HE Jinxu, XUE Suling, LI Jitong, ZHANG Tang, LOU Lu⁺

School of Information Science and Engineering, Chongqing Jiaotong University, Chongqing 400074, China

Abstract: 3D Gaussian Splatting (3DGS) tends to produce numerous redundant Gaussian primitives in complex scenes due to its density control strategy, significantly increasing computational and memory costs. Additionally, the unordered nature of Gaussians poses sorting challenges in the rasterization-based rendering pipeline when handling occlusions, causing blurring or artifacts in high-frequency regions. To address these issues, this paper proposes a compact 3D Gaussian Splatting method based on geometric visibility-aware volumetric saliency (Geometric Visibility-Aware Volumetric Saliency based compact 3DGS, GVS-Gaussian). This method explicitly models multi-view visibility consistency, geometric structural contribution, and transmittance accumulation effects of Gaussian primitives within a volumetric rendering framework to achieve a global assessment of Gaussian importance. An adaptive MLP-based pruning algorithm is designed to remove redundant low-importance Gaussians. Furthermore, a vector quantization-based encoding strategy is employed to compress key Gaussian parameters, reducing model storage overhead. Experimental results demonstrate that on Blender indoor scenes, GVS-Gaussian reduces the number of Gaussian primitives by 84%, achieving a $37.7\times$ model compression ratio while maintaining stable rendering quality. On Tanks

基金项目: 国家自然科学基金资助项目(52172381); 重庆市自然科学基金资助项目(cstc2021jcyj-msxmX1121)。

作者简介: 何金旭(2001—), 男, 硕士研究生, CCF 学生会会员, 主要研究方向: 三维重建、新视角合成; 薛苏玲

(2001—), 硕士研究生, CCF 学生会会员; 李霁潼(2001—), 硕士研究生, CCF 学生会会员; 张塘(2001—), 硕士研究生, CCF 学生会会员; 娄路(1969—), 副教授, 博士, CCF 普通会员。

and Temples outdoor scenes, the number of Gaussians decreases by 50%, yielding an $11.66\times$ compression ratio with rendering quality superior to other baseline methods.

Key words: novel view synthesis; 3D gaussian splatting; Gaussian pruning; ray tracing; volume rendering

新视角合成技术在虚拟视觉、增强现实、自动驾驶和机器人等领域具有广泛应用前景,是当前计算机图形学和计算机视觉研究中的重要方向。近年来,可微分渲染技术的发展推动了该领域的快速进展,涌现出大量突破性成果^[1-2]。其中,神经辐射场(Neural Radiance Fields, NeRF)^[3]通过多层感知机(Multi-Layer Perceptron, MLP)学习从空间坐标到颜色和体密度的隐式映射,并结合体渲染^[4]实现高质量的新视角合成。相比之下,3D 高斯泼溅(3D Gaussian Splatting, 3DGS)^[5]采用显式的高斯基元(Gaussian)集合对场景进行建模,并利用传统光栅化管线将三维高斯投影至二维平面,实现了显著的渲染效率提升。然而,3DGS 的训练过程通常依赖启发式的稠密化-剪枝(densification-pruning)策略,即在优化初期通过高斯分裂与复制快速增加基元数量以拟合细节,再通过经验阈值进行剪枝,表现为“先激进增密、再大幅剪枝”。在复杂场景中,该策略容易引入大量低贡献或空间冗余的高斯基元,导致模型规模迅速膨胀,从而显著增加存储与计算开销,并对实际部署(如移动端或实时应用)造成负担^[6]。

为此,许多研究致力于在尽量保持渲染质量的前提下压缩高斯数量或参数规模,从不同角度推动了紧凑化 3DGS 表达的发展。部分启发式优化算法,如 SUNDAE^[7]从频域分析角度出发,指出高密度高斯集合中存在大量主要影响高频噪声而非结构信息的基元,并通过频谱剪枝移除对低频结构贡献有限的高斯,同时引入神经补偿网络对剪枝后的细节进行学习性恢复,从而在压缩模型规模的同时维持整体视觉质量。LP-3DGS^[8]将高斯剪枝建模为可学习的决策过程,通过神经网络预测高斯基元的保留概率,以动态平衡压缩率与重建质量。3DGS-MCMC^[9]从概率建模视角重新审视 3DGS 表达,将高斯基元视为潜在分布中的随机样本,并引入马尔科夫链与随机梯度朗之万动力学进行优化,在减少启发式规则依赖的同时提升对初始化的

鲁棒性,但其采样式优化带来了更高的训练复杂度。Revising 3DGS^[10]通过系统性重构密度控制机制,显式建模像素误差与高斯分布之间的关系,实现基于误差反馈的自适应高斯资源分配。

另一类方法侧重于基于重要性指标或参数冗余性的结构压缩。如 LightGaussian^[11]依据高斯与视线的交互频次进行剪枝,并结合向量量化与熵编码压缩高斯参数;Trimming the Fat^[12]联合利用不透明度与梯度信息识别低贡献高斯;SafeguardGS^[13]进一步引入多指标显著性评分以构建相对保守的剪枝机制,从而降低过度剪枝风险。EAGLES^[14]方法通过引入量化嵌入(Quantized Embeddings)显著降低单个高斯的参数存储开销,并结合由粗到细的训练策略与剪枝阶段,实现模型规模与训练效率的同步优化,在保持渲染质量的同时获得 10-20 倍的存储压缩率。RDO-Gaussian^[15]借鉴率失真优化框架,将剪枝、量化与编码统一纳入联合优化目标,实现可控的质量-码率权衡;Compact 3DGS^[16]通过可学习的高斯掩码与紧凑属性表示,实现结构压缩与参数压缩的协同优化。

此外,部分研究从加速或参数压缩角度对 3DGS 进行探索。如 Speedy-Splat^[17]通过稀疏像素采样与稀疏高斯渲染路径显著提升渲染速度,其重点在于降低计算开销而非显式消除结构冗余。Distilled-3DGS^[18]利用知识蒸馏获得轻量级高斯表达,但仍依赖原始高斯分布,难以从结构层面消除冗余基元。Mixture of Priors^[19]则从先验建模与细粒度量化角度提升参数压缩效率,其作用对象主要集中于参数表示空间,而未显式区分高斯基元在几何与可见性层面的冗余性。

当前这些紧凑或压缩 3DGS 方法在剪枝、量化、加速等方面已取得显著进展,但仍存在以下共性挑战:(1)启发式局限:多数方法依赖局部统计特征,缺乏对体渲染中透射率累积、遮挡关系、几何显著性的系统建模^[11-13];(2)场景适应不足:在遮挡复杂、视角稀疏或光照动态的场景中,易出现细节缺失与几何漂移^[8-9];

(3)效率与质量权衡: 部分方法虽提升压缩率, 但渲染质量损失明显, 或者引入了额外的训练或推理开销。

因此, 本文提出一种基于几何可见性感知的体渲染显著性的紧凑 3DGS 方法 (Geometric Visibility-Aware Volumetric Saliency based compact Gaussian, GVS-Gaussian)。该方法的核心创新是在体渲染框架下引入几何可见性感知的显著性思想, 对高斯基元在多视角条件下的全局重要性进行统一建模, 从而为后续的紧凑化建模提供有效依据。本文的主要贡献包括:

(1)设计基于几何可见性感知的体渲染显著性建模, 解决高斯缺乏显式拓扑结构与全局深度一致性的无序性问题, 提升渲染精度。

(2)提出一种自适应剪枝模块, 通过轻量级 MLP 自适应估计每个高斯基元的贡献, 在保证视觉保真度的同时实现对冗余基元的细粒度抑制。

(3)结合多视角几何一致性和光度损失解决 3DGS 多视角下不一致性问题, 弥补裁剪后可能引入的渲染质量退化。

1 方法

1.1 模型框架

本文提出 GVS-Gaussian 方法, 主要由三个核心模块组成: 基于几何可见性感知的体渲染显著性建模、高斯自适应剪枝及多视角一致性损失模块, 如图 1 所示。以 MipNeRF360 数据集的 Bicycle 场景为例, 相较于 3DGS, GVS-Gaussian 能够实现 9.7 倍压缩, 同时显著提升渲染质量, PSNR 提升 16%, SSIM 提升 25%, LPIPS 降低 29%。高压压缩率主要受益于自适应剪枝模块, 高质量渲染则是几何可见性感知的体渲染显著性建模与多视角一致性损失协同作用的结果。




图 1 整体框架

Fig.1 Overall framework

1.2 几何可见性感知的 3D 高斯体渲染框架

1.2.1 3DGS 的基础表示

3DGS 使用一组离散的高斯基元 G_i 来表示空间场景, 基元由预处理阶段稀疏点云初始化得到^[5], 每个高斯基元由下面公式(1)定义:

$$G_i(\mathbf{x} | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) = e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\mathbf{x}-\boldsymbol{\mu}_i)} \quad (1)$$

式中 $\boldsymbol{\mu}_i \in \mathbb{R}^{3 \times 3}$ 和 $\boldsymbol{\Sigma}_i \in \mathbb{R}^{3 \times 3}$ 分别对应基元的中心和协方差矩阵, 其中协方差矩阵由以下公式(2)定义:

$$\boldsymbol{\Sigma}_i = \mathbf{R}_i \mathbf{S}_i \mathbf{S}_i^T \mathbf{R}_i^T \quad (2)$$

式中 $\mathbf{S}_i \in \mathbb{R}^{3 \times 3}$ 和 $\mathbf{R}_i \in \mathbb{R}^{3 \times 3}$ 分别对应基元的尺度矩阵和旋转矩阵。

传统 3DGS 训练过程的高斯基元稠密化策略, 会导致高斯基元间交错堆叠, 缺乏显式拓扑结构与全局深度一致性, 即无序性问题。在采用传统高效的栅格化与 alpha 混合管线时, 高斯基元被投影到 2D 相机平面, 投影先后顺序决定渲染中的权重大小, 因此, 在处理复杂遮挡时的排序错误往往导致高频细节区域容易出现模糊或伪影。

1.2.2 基于几何可见性感知的体渲染显著性建模

本文借鉴 NeRF^[3]与 GOF^[20]的体渲染思想, 引入基于光线追踪的高斯-光线交互建模, 将无序分布的高斯基元统一纳入连续体渲染框架中, 从而为后续的可见性建模与多视角几何一致性分析提供统一的物理基础。

光线中沿途点定义如下:

$$\mathbf{x} = \mathbf{o} + t\mathbf{r} \quad (3)$$

式中 $\mathbf{o} \in \mathbb{R}^{3 \times 3}$ 和 $\mathbf{r} \in \mathbb{R}^{3 \times 3}$ 分别指的是光线起点和方向, t 指的是 $\mathbf{o}$ 与高斯-光线交点的距离。为实现后续的体渲染, 将公式(3)中的点转化到高斯局部坐标系下:

$$\mathbf{o}_i = \mathbf{S}_i^{-1} \mathbf{R}_i (\mathbf{o} - \boldsymbol{\mu}_i) \quad (4)$$

$$\mathbf{r}_i = \mathbf{S}_i^{-1} \mathbf{R}_i \mathbf{r} \quad (5)$$

$$\mathbf{x}_i = \mathbf{o}_i + t\mathbf{r}_i \quad (6)$$

式中 i 代表一个高斯基元中的局部坐标系。

当光线将穿过高斯基元, 联立公式(1)和公式(6)将得到沿光线的一维高斯函数公式(7),

$$G_k^{1D}(t) = G_k(\mathbf{x}_i) = \exp\left(-\frac{1}{2} \mathbf{x}_i^T \mathbf{x}_i\right) \quad (7)$$

式中 k 表示与高斯基元相交的光线, $\mathbf{x}$ 和 $\mathbf{x}^T$ 分别表示高斯基元局部坐标系下的坐标矩阵及其转置矩阵。

在实际渲染过程中, 沿每条光线对该一维高斯函数进行离散采样与数值积分, 以近似计算光线与多个高斯基元的累积交互贡献。

由于高斯基元在空间中的无序分布及其多视角可

见性差异, 光线-高斯的采样交互过程中仍易出现遮挡关系不稳定或者几何贡献分配不均的问题。为此, 本文进一步提出一种基于几何可见性感知的体渲染显著性建模方法, 用于对高斯基元在体渲染过程中的全局重要性进行显式表示, 如图 1 (b) 与图 2 所示。需要指出的是, 传统计算机视觉中的显著性通常指由局部特征对比度 (如颜色、亮度与方向) 驱动的视觉注意区域^[21], 其目标在于突出图像中更易被人眼感知的区域, 并不直接反映三维几何结构或多视角一致性贡献。而现有压缩型 3DGS 方法中, LightGaussian 主要依据高斯与光线的交互频次或访问统计来衡量其重要性, 其剪枝策略仅侧重于识别低频访问的冗余高斯基元; Compact 3DGS 则通过可学习掩码或参数约束, 从模型参数紧凑化角度削减高斯数量。不同于上述方法, 本文提出的 GVS-Gaussian, 从体渲染过程本身出发, 将高斯基元在多视角条件下对几何结构重建与可见性一致性的综合贡献定义其重要性, 亦即显著性, 显式建模遮挡关系、结构边界与透明度衰减等物理因素。采用可见性统计 (visibility field)、局部几何变化率 (normal variation) 以及透明度衰减特性三个维度构建体渲染显著性函数, 对高斯基元的重要性进行联合建模。显著性函数 s_i 定义如下:

$$s_i = \text{Norm}\left(\mathbf{f}_i^{wf} \cdot \exp(w_n \mathbf{g}_i) \cdot (1 - e^{-w_\alpha \alpha_i})\right) \quad (8)$$

其中, $\mathbf{f}_i$ 表示高斯基元 G_i 的多视角可见一致性, $\mathbf{g}_i$ 为其局部几何变化率, 通过法线场的方差表达结构边界, α_i 表示其不透明度贡献, 反映高斯在光线累计过程中的有效能见度, w_f , w_n , w_α 为权重系数。具体而言, $\mathbf{f}_i$ 和 $\mathbf{g}_i$ 的定义分别如下:

$$\mathbf{f}_i = \frac{1}{|\mathbf{R}_i|} \sum_{\mathbf{r} \in \mathbf{R}_i} \mathbf{I}(\mathbf{r} \cap G_i) \quad (9)$$

$$\mathbf{g}_i = \frac{1}{|\mathbf{R}_i|} \sum_{\mathbf{r} \in \mathbf{R}_i} \|\mathbf{n}_{i,\mathbf{r}} - \mathbf{n}_r\|^2 \quad (10)$$

$\mathbf{R}_i$ 是与高斯基元 G_i 相交的射线集合, $\mathbf{I}(\cdot)$ 为指示函数, 表示光线与高斯基元的相交情况 (1 表示相交, 0 则未相交); $\mathbf{n}_{i,\mathbf{r}}$ 为沿射线在该位置估计的法线向量, $\mathbf{n}_r$ 为其平均法线, 用于度量其几何变化幅度变化大小。

该显著性能够在多视角约束下同时反映结构边界、

遮挡过渡区与几何高频区域的响应强度,从而显著增强关键区域的采样密度。最终,将可见性、几何细节与透明度衰减统一到同一响应空间中,使得采样过程能够自适应聚焦于遮挡边界、薄结构与高频区域,从而显著提升渲染精度与训练稳定性。




图2 几何可见性感知体渲染采样图

Fig.2 Sampling guided by geometric visibility-aware volumetric saliency

光线在传播过程中依次穿过多个高斯基元,渲染时先对单个基元进行积分,再沿光线路径累加,最终得到各视角下的RGB、深度和法线图,如图1(d)所示的,其计算公式如下:

$$c(o, d) = \sum_{i=1}^N c_i \alpha_i E(G_i, o, d) \prod_{j=1}^{i-1} (1 - \alpha_j E(G_j, o, d)) \quad (11)$$

式中, $c(o, d)$ 是光线累积的颜色、法线及深度信息, α 是权重值, N 是高斯基元数, E 计算每个高斯基元内部的颜色、法线、深度值, 计算如下:

$$E(G_i, o, d) = G_k^{id}(t) \quad (12)$$

相较于仅基于射线访问频次或参数约束的高斯冗余裁剪压缩3DGS, 本文提出的GVS-Gaussian不仅准确建模光线与高斯基元的物理关系, 而且能够在多视角条件下同时表示高斯基元的可见稳定性与几何结构贡献, 有效区分“频繁出现但几何贡献有限”的冗余高斯, 以及“出现频率较低但对结构重建至关重要”的关键高斯, 更适用于遮挡关系复杂、几何变化剧烈的真实场景。

此外, 为避免显著性阈值的场景依赖性, GVS-Gaussian采用基于统计分布的自适应显著性筛选策略, 即从归一化后的显著性分布中选取其 p 分位数作为显著区域, 而无需人工设定静态阈值。

1.3 自适应剪枝

以几何可见性感知体渲染显著性建模为基础, 进一步提出基于学习掩模的自适应神经剪枝方法, 避免传统启发式规则剪枝方法过于依赖局部统计特征的缺点, 提高场景泛化能力, 如图1(c)所示。其核心思

路是在稠密化阶段, 利用MLP学习高斯基元重要性因子, 对其不透明度进行可微分调制, 实现高斯基元的自适应剪枝。

首先通过alpha混合计算多视角透射率:

$$T_i = \frac{1}{|V|} \sum_v \alpha_i \prod_{j=1}^{i-1} (1 - \alpha_j) \quad (13)$$

式中 α_i 指的是第 i 个高斯基元的不透明度值, 通过权重累积, 得到基元在当前视角下的透射率; V 表示相关视角的数量, T_i 为多个单视角透射率的平均值。

考虑到渲染结果中的伪影往往是半透明的空间杂质, 其透射率一般偏低, 因此计算高斯基元的透射率后, 剔除透射率最低的那部分基元, 能够减少伪影。

本文把深度 d_i 与法线 n_i 构成的特征向量 $v_i = [T_i, d_i, n_i] \in \mathbb{R}^{3 \times 3}$ 输入一个轻量级三层MLP, 其结构依次为输入层、两个包含64和32个神经元的全连接隐藏层以及一个输出层。隐藏层均采用ReLU激活函数, 输出层通过Sigmoid将结果映射至[0,1], 得到预测学习掩模 $F(m_i)$:

$$F(m_i) = \sigma(W_3 \phi(W_2 \phi(W_1 v_i + b_1) + b_2) + b_3) \quad (14)$$

并调整优化不透明度 α ,

$$\alpha_i^{new} = F(m_i) \cdot \alpha_i \quad (15)$$

然后采用稀疏约束损失 L_{sparse} 对MLP进行训练评估, 定义为:

$$L_{sparse} = \frac{1}{N} \sum_{i=1}^N F(m_i) \quad (16)$$

式中 N 为活跃高斯的数量。该损失经 N 归一化, 可解释为所有基元的平均保留概率。该项以权重形式集成到整体训练目标中。为提升训练稳定性与可复现性, MLP的训练参数与3DGS主网络保持一致, 包括优化器采用Adam(learning rate = 0.001), 训练轮数与3DGS保持同步更新。由于剪枝模块与主网络同时训练, 其学习率与迭代次数无需单独调整。

在训练结束后, 本文引入矢量量化(Vector Quantization, VQ)策略, 对高斯参数进行进一步压缩。具体而言, 我们针对球谐系数(Spherical Harmonics Coefficients)部分进行聚类量化, 通过将相似的特征向量映射到共享的码本(Codebook)索引, 实现参数共享

与存储压缩。与 LightGaussian 直接对整组高斯参数统一量化不同, 本文仅对辐射场相关的球谐系数进行编码压缩, 而保留几何参数的精度, 从而在减少模型大小的同时保持了渲染一致性与细节保真度。该步骤可在不重新训练的前提下, 将整体模型存储压缩率进一步提高 5.8 倍, 有效提升模型的可部署性。

1.4 损失函数

在存在遮挡、视角稀疏或光照动态等的复杂场景中, 高斯基元的优化目标须在多视角条件下保障几何结构与光度表现的一致性。因此, 高斯基元训练的损失函数设计至关重要。本文采用多项损失函数: 首先遵循已有研究, 采用 L1 损失与 D-SSIM 损失提高渲染图像的纹理保真度和结构相似性; 然后采用多视角几何一致性损失, 通过限制空间位置偏差, 确保重建结果在几何形态上的准确性; 此外, 引入光度一致性损失提升跨视角的稳定性和颜色一致性, 如图 1 (c) 所示。

1.4.1 多视角几何一致性损失

本文用 p 表示当前视角下的某个像素, p_r 表示邻近视角下对应的像素。通过单应性矩阵 H_{nr} 和 H_m 实现这两个视角之间的转换。

$$H_m = K_n \left(R_m - \frac{T_m n_r^T}{d_r} \right) K_r^{-1} \quad (17)$$

$$p_n = H_{nr} H_m p_r \quad (18)$$

式中 K_n 是相机内参矩阵, 法线 n_r 和深度 d_r 通过射线与高斯交点的训练得到。

通过计算 p_n 和 p_r 之间的误差, 可以得到在第 i 个视点下的误差 L_i 。然后计算所有视角的平均像素误差, 得到多视角几何一致性误差:

$$L_i = \|p_r - p_n\| \quad (19)$$

多视角几何一致性损失最小化相邻视角间对应 3D 点的位置差异, 从而抑制错位、模糊和形状不一致等问题。通过集成该约束, 模型可以生成更具空间准确性的表面, 提高在视角距离和角度变化的情况下的渲染精度。

将 L_i 相加得到总误差, 根据视角数可计算出多视角平均的几何一致性损失:

$$L_{\text{geo}} = \frac{1}{V} \sum_{i \in V} L_i \quad (20)$$

1.4.2 多视角光度一致性损失

光度一致性旨在保证不同视角下同一表面区域的颜色分布保持一致。本文中, 对于参考视角下的像素 p_r , 我们以其为中心裁剪 11×11 的小块, 并沿极线方向在源视角中搜索最相似的对块。搜索过程借助单应性矩阵 H_m 将参考小块映射到源视角, 得到候选块 p_n 。由于 H_m 取决于两视图的相机内外参以及像素的深度和法向信息, 映射误差实际上同时耦合了几何与外观信息。

相似度度量采用归一化互相关 (NCC), 其值域为 $[-1, 1]$, 对线性光照变化具有不变性, 可稳健判断两小块是否对应同一表面。遍历图像所有像素后, 平均 NCC 误差可得到多视角光度一致性损失 L_{pho} :

$$L_{\text{pho}} = \frac{1}{V} \sum_{p_i \in V} (1 - \text{NCC}(I_r(p_r), I_n(p_n))) \quad (21)$$

1.4.3 综合优化目标函数

在高斯泼溅常用的 L_{rgb} 、2DGS^[22]中提出的深度畸变损失 L_d 和法线一致性损失 L_n 基础上, 再引入前面的多视角几何一致性损失 L_{geo} 和多视角光度一致性损失 L_{pho} , 总的损失表示如下:

$$L = \gamma_s L_{\text{sparse}} + \gamma_r L_{\text{rgb}} + \gamma_d L_d + \gamma_n L_n + \beta_g L_{\text{geo}} + \beta_p L_{\text{pho}} \quad (22)$$

式中, β_g 为 0.05, β_p 为 0.3, γ_s 为 0.01, γ_r 为 0.2, γ_d 和 γ_n 均为 0.01, 显著性函数权重 w_f 为 1.0, w_n 为 1.0, w_a 为 3.0, 显著区域 p 值为 0.25。上述损失权重均参照现有研究中经过充分实验验证的经验值设定, 以确保与现有工作具备公平可比性。

2 实验结果与分析

2.1 数据集与实验参数设置

本研究选择通用数据集进行实验验证, 包括 Blender 虚拟仿真数据集^[3]、TnT 数据集^[23]、Mip-NeRF360 数据集^[24]和 Drone2Map 数据集。利用 Blender 数据集验证所提方法在虚拟仿真数据集上的渲染效果, 由 8 组 100 张 800×800 的多视角图像的小物体场景构成; MipNeRF360 数据集包含 5 组户外和 4 组室内场景, 每组场景为 140 至 300 张不等, 室内图像分辨率

约为 3000×2000 , 户外图像分辨率约为 5000×3200 ; 从无边界户外场景的 TnT 数据集中选取 6 组 250 至 1100 张不等的 1920×1080 分辨率多视角图像场景, 本文利用 MipNeRF360 和 TnT 数据集进行稠密视角下新视角合成实验。此外, 为进一步验证方法在稀疏视角场景中的重建能力, 本文引入 Drone2Map 低空无人机多视角数据集 (36 张图像, 分辨率 4530×3017), 该数据集视角覆盖稀疏且存在显著尺度变化, 能够有效评估算法在非稠密采样条件下的稳定性与泛化性。

所有实验均在单张 NVIDIA V100 GPU 上进行, 采用与常规 3DGS 相同的超参数设置和训练迭代总次数 (30k)。实验使用 COLMAP 的输出结果 (稀疏点云、相机姿态、多视角图片) 作为训练数据, 稠密化处理只在前 15k 迭代中进行, 在稠密化阶段, 参考 AbsGS^[25] 的做法, 采用绝对梯度值来指导高斯基元的生成, 从而提升稠密化过程的稳定性与可靠性。

训练完成后, 渲染输出 RGB、深度和法线图, 并采用与现有研究一致的评估标准。评价指标包括峰值信噪比 (Peak Signal-to-Noise Ratio, PSNR)^[26]、结构相似度指数 (Structural Similarity, SSIM)^[27] 和学习感知图像块相似度 (Learned Perceptual Image Patch Similarity, LPIPS)^[28]。此外, 还统计了不同方法在各场景下的高斯数量, 以评估模型的压缩性能; 同时报告推理阶段的帧率 (Frames Per Second, FPS), 用于衡量模型在渲染阶段的运行效率。在后续所有实验表格中, 本文根据是否引入显式高斯压缩策略, 将对比方法分为非压缩类方法与压缩类方法, 并在表中进行分组展示, 以提升结果比较的清晰性。

2.2 实验结果

2.2.1 仿真数据集

首先在 Blender 仿真数据集上验证了 GVS-Gaussian 在光照均匀、范围有限且纹理相对简单场景下的新视角合成性能。对比方法包括原始 3DGS、基于密度控制的 GOF 以及引入多视角约束的 PGSR^[29]。

图 3 直观展示了高斯基元数量的对比情况。可以看出, 本文方法在合成场景下实现了显著的模型压缩, 同时有效保证了渲染质量。




图 3 Blender 数据集的高斯数量对比

Fig.3 Comparison of the number of Gaussians in different methods of the Blender dataset

如表 1 所示, Ours* (GVS-Gaussian*) 表示仅采用剪枝策略, Ours (GVS-Gaussian) 表示完整模型。结果显示, 仅使用剪枝策略即可在保持渲染质量基本不变的情况下, 将高斯数量由 2.86M 减少至 0.44M, 减少了 84.6%, 对应的模型存储空间由 67.5MB 减少到 1.79MB, 压缩率达 37.7 倍; 在进一步结合体渲染与多视角一致性损失后, 本文方法的 PSNR、SSIM 和 LPIPS 分别达到 33.07、0.968 和 0.033, 性能与对比方法持平甚至略优。值得注意的是, 尽管体渲染显著性建模引入了一定的计算开销, 但得益于自适应剪枝对冗余基元的有效抑制, 以及多视角一致性损失带来的收敛稳定性, 整体推理速度仍保持在 126 FPS, 接近 3DGS 的实时渲染性能 (140 FPS)。这表明 GVS-Gaussian 在实现大幅度压缩的同时, 依然具备实时渲染能力。

表 1 Blender 数据集上的渲染质量与高斯数量对比

Table 1 Quantitative results of rendering quality for rendering and number of Gaussians on Blender dataset

Method	PSNR↑	SSIM↑	LPIPS↓	高斯数量($\times 10^5$)↓	压缩率↑	FPS↑
3DGS	<u>33.31</u>	0.969	<u>0.037</u>	2.86	1.00	140
PGSR	33.27	0.968	0.039	1.40	2.04	150
GOF	33.33	0.969	0.038	1.72	1.67	147
Ours*	32.35	0.965	0.038	0.44	37.7	155
Ours	33.07	<u>0.968</u>	0.033	0.44	37.7	126

注: 加粗数据为最优值, 下划线数据为次优值。

2.2.2 MipNeRF360 数据集

MipNeRF360 包含室内与户外两类场景, 对比方

法包括三种常规高斯泼溅方法 (3DGS、GOF、PGSR) 以及五种压缩型方法 (LP-3DGS、Compact 3DGS、LightGaussian、EAGLES 和 RDOGaussian)。对比实验结果如表 2 所示: (1) 整体效果上, 本文方法 GVS-Gaussian 将高斯数量由 3.40M 压缩至 1.92M, 实现 10.27 倍的存储压缩, 且保持较高渲染质量 (平均 PSNR 27.32, SSIM 0.826, LPIPS 0.198) 基本上压缩方法中最高。而尽管部分压缩方法, 如 EAGLES、LightGaussian、Compact 3DGS, 能够实现比本文方法略高的压缩率, 但其渲染质量都不如本文方法, 甚至比原始 3DGS 的渲染质量还低。能实现最高压缩率 (31.71 倍) 的 RDO-Gaussian, 其渲染质量是所有方法中最低的, 平均值 PSNR 26.03, SSIM 0.764, LPIPS 0.299, 相较原始 3DGS 的 PSNR 27.24、SSIM 0.803、LPIPS 0.246 退化严重。(2) 在室内场景中, 由于光照条件相对稳定、遮挡较少, 各类压缩方法在渲染质量上的差异相对较小。GVS-Gaussian 相较 3DGS 的 PSNR 略有下降 (约 1.9%), 但 SSIM 与 LPIPS 基本保持一致, 表明在高压压缩条件下仍能维持良好的结构一致性与感知质量。(3) 在户外场景中, GVS-Gaussian 的优势更加显著, 在 PSNR、SSIM 和 LPIPS 三项指标上分别达到 24.86、0.749 和 0.207, 均优于所有对比方法。(4) 相比主要依赖射线访问频次或参数级压缩的策略, GVS-Gaussian 通过几何可见性感知的体渲染显著性建模, 显式描述多视角条件下的遮挡关系与透射累积

效应, 使高斯筛选更聚焦于对几何稳定性与视觉质量具有关键贡献的区域。尽管 RDO-Gaussian 在压缩率上达到 31.71 倍, 但其在室内与户外场景中的 PSNR、SSIM 与 LPIPS 均显著劣于其他方法, 反映出过度强调参数压缩可能导致几何与外观信息的明显损失。相比之下, GVS-Gaussian 在压缩率、渲染质量与几何一致性之间实现了更均衡的权衡, 尤其适用于遮挡复杂、纹理变化剧烈的户外真实场景。

总体来看, 本文方法在渲染质量与模型压缩之间实现了较好的平衡性, 在户外复杂场景中优势更为明显。为进一步验证方法的有效性, 我们在 MipNeRF360 户外数据集上进行与 3DGS、PGSR 和 GOF 等方法的对比实验, 渲染结果如图 4 所示。在 bicycle 和 flowers 场景中, 植被纹理复杂, PGSR 保留了大量冗余高斯, 导致伪影明显; 3DGS 在纹理还原方面略显模糊, 而 GOF 在高反光表面仍存在亮斑失真。相比之下, GVS-Gaussian 通过剔除低贡献度高斯更好地恢复了细节纹理。在 garden 场景的桌面与桌腿连接处 (红框区域), 由于该区域属于几何高频结构, PGSR 与 3DGS 均出现了明显空洞, 而 GVS-Gaussian 能够保持几何连续性; 在 counter 场景中, 因为传统光栅化渲染方法在高反光区域容易出现失真, PGSR 与 GOF 均未能有效处理该问题, 而 GVS-Gaussian 能够准确还原反射区域的几何特征。



图4 MipNeRF360 数据集的渲染结果可视化对比

Fig.4 Visualization comparison of rendering results on the MipNeRF360 dataset

表2 MipNeRF360 数据集的渲染质量与高斯数量对比

Table 2 Comparison of the result of different methods on the MipNeRF360 dataset

Method	Indoor			Outdoor			Mean				
	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	高斯数量($\times 10^6$)↓	压缩率↑
3DGS	<u>30.99</u>	0.926	0.199	24.24	0.705	0.283	27.24	0.803	0.246	3.40	1.00
GOF	30.65	0.921	0.236	<u>24.84</u>	<u>0.742</u>	0.233	27.42	<u>0.826</u>	0.234	2.93	1.16
PGSR	30.41	0.930	0.161	24.45	0.730	<u>0.224</u>	<u>27.43</u>	0.830	0.193	4.42	0.77
LP-3DGS	31.03	<u>0.929</u>	<u>0.173</u>	24.57	0.717	0.269	27.44	0.812	0.226	1.48	2.30
Compact 3DGS	30.34	0.911	0.204	24.26	0.705	0.276	26.96	0.797	0.244	1.42	15.29
LightGaussian	30.54	0.917	0.204	24.63	0.726	0.250	27.13	0.806	0.237	<u>1.17</u>	<u>16.31</u>
EAGLES	30.49	0.923	0.180	24.54	0.716	0.268	27.23	0.809	0.241	1.33	10.34
RDO-Gaussian	28.74	0.879	0.253	23.87	0.672	0.337	26.03	0.764	0.299	0.48	31.71
Ours	30.40	0.921	0.189	24.86	0.749	0.207	27.32	<u>0.826</u>	<u>0.198</u>	1.92	10.27

注：加粗数据为最优值，下划线数据为次优值。

2.2.3 TnT 数据集

在 TnT 数据集上，本文方法与 3DGS-MCMC、Revising 3DGS、SUNDAE、LightGaussian、EAGLES 和 RDO-Gaussian 进行了对比分析，以 3DGS 作为基线。实验结果如表 3 所示：(1) 从整体压缩效果来看，3DGS 在该数据集上的高斯数量达到 1.83M，存在明显冗余；GVS-Gaussian 将高斯数量压缩至 0.91M，减少约 50.3%，模型容量由 439.6MB 降至 37.7MB，整体压缩率达到 11.66 倍，在保证较高渲染质量的同时

实现了有效压缩。(2) 在渲染质量方面，GVS-Gaussian 在 PSNR、SSIM 和 LPIPS 指标上分别达到 23.18、0.849 和 0.173，整体性能与当前主流方法保持在同一水平，且在结构一致性与感知质量方面表现更为稳定。(3) 部分方法（如 LightGaussian、EAGLES 以及 RDO-Gaussian）通过更为激进的剪枝或参数压缩策略获得了更高的压缩率，其中 RDO-Gaussian 的压缩率达到 35.92 倍，但其 PSNR、SSIM 与 LPIPS 均显著下降，表明在极端压缩条件下几何结构与外观信息易发生明显损失。(4) 相比之下，GVS-Gaussian 通过几何可见

性感知的体渲染显著性建模，在多视角条件下综合考虑遮挡关系与透射累积效应，使高斯筛选能够更稳健地保留对结构与视觉质量具有关键贡献的基元。因此，在包含复杂遮挡、多层几何结构与高频边界区域的TnT数据集中，GVS-Gaussian在压缩率、渲染质量与几何一致性之间实现了更好的平衡性。

图5展示了TnT数据集六个典型场景的渲染结果，包括渲染图像、深度图、法线图以及由本文提出的显著性函数计算得到的热力图，可以观察到，显著性较高的区域通常集中在遮挡边界、细节纹理或几何突变位置，而在平坦区域显著性较低，这说明基于几何可见性感知的体渲染显著性建模能够有效反映几何贡献的重要性。同时，深度与法线均与真实场景的几何分布高度一致，验证了体渲染显著性建模的机制在复

杂场景下保持多视角一致性和细节建模能力。四种可视化结果对应于图1(e)部分，直观反映各输出模块在整体架构中的作用。

表3 TnT数据集上的实验结果对比

Table 3 Comparison of the result of different methods on the TnT dataset

Method	PSNR↑	SSIM↑	LPIPS↓	高斯数量($\times 10^6$)↓	压缩率↑
3DGS	23.14	<u>0.841</u>	<u>0.183</u>	1.83	1.00
3DGS-MCMC	22.55	0.817	0.204	0.96	1.91
Revising 3DGS	22.34	0.811	0.216	0.96	1.91
SUNDAE	23.70	0.830	0.219	1.01	1.81
LightGaussian	<u>23.44</u>	0.832	0.202	0.71	<u>16.44</u>
EAGLES	23.02	0.830	0.200	<u>0.65</u>	10.82
RDOGaussian	21.86	0.805	0.251	0.14	35.92
Ours	23.18	0.849	0.173	0.91	11.66

注：加粗数据为最优值，下划线数据为次优值。




图5 TnT数据集的渲染结果的可视化

Fig.5 Visualization of rendering results on the TnT dataset

2.2.4 无人机低空摄影稀疏视角数据集

除了以上典型公开数据集实验之外，我们在Drone2Map-Building无人机数据集上与3DGS、GOF和PGSR进行了对比实验，结果如表4所示。3DGS的高斯数量为1.65M，存在明显冗余；而本文方法将其压缩至0.46M，减少比例达72%，同时模型存储空间从356.4 MB降至17.7 MB，实现20.08倍压缩，并在PSNR、SSIM和LPIPS上分别达到26.847、0.895和

0.133，优于基线及对比方法。该结果表明，本文方法在稀疏视角条件下同样保持了较高的渲染精度与结构一致性，具有良好的通用性与鲁棒性。

表4 无人机低空 Drone2Map-Building 数据集上的实验结果对比

Table 4 Comparison of the result of different methods on the UAV Building dataset

Method	PSNR↑	SSIM↑	LPIPS↓	高斯数量($\times 10^6$)↓	压缩率↑
3DGS	26.283	0.887	0.167	1.65	1.00
PGSR	25.706	0.866	0.191	0.94	<u>1.76</u>
GOF	25.596	0.864	0.175	1.51	1.09
Ours	26.847	0.895	0.133	0.46	20.08

注：加粗数据为最优值，下划线数据为次优值。




图6 Drone2Map-Building 数据集上的渲染与高斯数量可视化对比

Fig.6 Comparison of rendering and Gaussians numbers results on the Drone2Map-Building dataset

图6展示了各方法的渲染结果与点云分布情况。对比可见，本文方法更逼真完整，细节清晰，且冗余点被显著抑制。分析其原因，无人机数据为低空倾斜拍摄视角，覆盖范围大、场景复杂，存在遮挡和阴影等干扰因素，3DGS方法易生成冗余高斯和渲染伪影，而本文方法通过几何可见性感知的体渲染显著性和自适应剪枝，更好地聚焦关键结构，如高频纹理区域，从而在实现高效压缩的同时，表现出更优的渲染质量。

2.3 消融实验

考虑到MipNeRF360户外数据集遮挡较多、纹理复杂且具有代表性，能够充分体现本文方法的优势。为验证各模块对重建质量与推理效率的影响，本文以3DGS为基线，分别评估了多视角一致性损失(+L)、自适应剪枝策略(+P)和体渲染显著性建模(+V)，以及其组合形式(+P+V、+L+V、+L+P)和完整模型(Full model)，为验证VQ对剪枝模块的影响，我们在仅采用剪枝策略时分别报告了不使用量化(+P w/o

VQ)与使用量化(+P)两种结果；在后续组合实验中，所有包含+P的实验均默认集成VQ，以模拟完整流程的实际部署方式，实验结果如表5所示。

单模块实验表明：(1) +L模块提升了跨视点几何一致性，使SSIM从0.705提升至0.746；(2) +P(w/o VQ)表明仅依赖自适应剪枝即可有效降低高斯数量(2.96M)，且渲染速度显著提升(148 FPS)，但由于未进行参数量化，其压缩率仅为1.51倍；(3) 在集成VQ后(+P)，压缩率进一步提升至8.78倍，同时保持较高的PSNR(24.253 dB)和渲染效率(151 FPS)，说明量化策略能够在不显著影响渲染质量的前提下显著降低存储开销；(4) +V模块增强了细节与遮挡建模能力，SSIM提升至0.749，LPIPS降至0.208。

表5 MipNeRF360 户外数据集上的消融实验

Table 5 Ablation on MipNeRF360 outdoor dataset

Method	PSNR↑	SSIM↑	LPIPS↓	高斯数量($\times 10^6$)↓	压缩率↑	FPS↑
3DGS	24.242	0.705	0.283	4.48	1.00	134
+L	24.747	0.746	0.211	5.02	0.89	122

+P(w/o VQ)	24.422	0.737	0.224	2.96	1.51	148
+P(+VQ)	24.253	0.729	0.243	2.96	8.78	151
+V	24.815	0.749	0.208	4.86	0.92	96
+P+V	24.739	0.744	0.215	2.96	8.78	105
+L+V	24.764	0.747	0.211	4.97	0.90	110
+L+P	24.541	0.727	0.237	2.97	8.75	144
Full model	24.855	0.749	0.207	2.96	8.78	120

注：加粗数据为最优值。

组合实验结果进一步表明，各模块在功能上具有明确分工并呈现出良好的协同关系：(1) 在高斯大幅裁剪条件下，引入体渲染显著性建模的+P+V 配置在保持较高压缩率（8.78 倍）的同时，渲染质量得到明显改善（PSNR 24.739，FPS 105），说明体渲染显著性建模能够有效缓解剪枝带来的细节与遮挡信息损失。(2)+L+V 组合在未进行强剪枝的情况下进一步增强了跨视角几何一致性与细节保真性，在 PSNR、SSIM 与 LPIPS 指标上均取得稳定提升（PSNR 24.764 dB，SSIM 0.747，LPIPS 0.211），表明多视角一致性约束与体渲染建模在质量提升方面具有互补作用。(3) 值得注意的是，+L+P 在所有配置中取得了最高的推理速度（144 FPS），体现出多视角一致性约束与自适应剪枝在减少高斯冗余、提升渲染效率方面的显著优势；但其渲染质量并未达到最优，说明仅依赖几何一致性约束与结构剪枝，仍难以充分表示复杂场景中的遮挡关系与透射效应。(4) 相比之下，引入体渲染显著性建模（+V）后，尽管推理速度有所下降，但在 PSNR、SSIM 与 LPIPS 等指标上均取得更优表现，验证了体渲染建模在表示高频几何细节与遮挡边界方面的关键作用。完整模型在各项指标上均达到最优（PSNR 24.855 dB，SSIM 0.749，LPIPS 0.207），表明在高压压缩条件下，通过引入针对质量退化的补偿建模，可以有效恢复并提升渲染质量。(5) 从推理效率角度进一步分析，体渲染模块（+V）会引入一定计算开销（FPS 由 134 降至 96），而自适应剪枝策略（+P）则对效率具有显著提升作用（151 FPS），使完整模型在实现高保真压缩的同时，仍保持实时渲染性能（120 FPS）。因此，本方法在引入体渲染增强几何表达的同时，通过剪枝机制有效抵消性能开销，从整体上实现了精度、压缩与效率之间的综合平衡。

表 6 不同显著性分位阈值 p 的敏感性分析

Table 6 Sensitivity analysis of saliency percentile threshold p

p 值	PSNR↑	SSIM↑	LPIPS↓	高斯数量($\times 10^5$)↓	压缩率↑
0.10	24.45	0.792	0.244	5.1	13.45
0.15	24.72	0.817	0.225	5.4	12.70
0.25	26.16	0.887	0.164	5.5	12.47
0.40	25.75	0.862	0.192	5.7	12.03

注：加粗数据为最优值。

鉴于 Barn 场景属于典型的室外无边界复杂场景，包含大量植被、细密结构以及显著的遮挡关系，其显著性分布形态具有较强代表性，本文选取该场景对显著性阈值进行敏感性分析。在 Barn 场景上，本文基于归一化显著性统计分布，对四个典型分位数（0.10、0.15、0.25、0.40）进行了敏感性测试（表 6）。结果表明，虽然不同 p 值带来轻微的压缩率变化，但过小的阈值会过度排除关键高斯，而过大的阈值则易保留冗余结构，均会导致渲染质量下降。基于质量与压缩性的平衡考虑，本文最终采用 $p = 0.25$ 作为显著性筛选阈值。需要指出的是，所采用的阈值定义基于显著性分布的分位数而非固定绝对尺度，因此在不同场景中无需单独调参。在其余数据集的实验中均统一采用该阈值设置，结果表明该选择在多种场景条件下均表现出稳定的重建质量。

3 结语

本文提出了一种基于几何可见性感知体渲染显著性的紧凑 3DGS 方法（GVS-Gaussian）。该方法通过几何可见性感知的体渲染显著性建模，增强了对遮挡与细节区域的建模能力，并结合多视角一致性约束，实现了压缩率与重建质量的平衡。在室内合成场景、室外大规模环境及低空无人机航拍场景上的实验表明，方法具有良好的泛化性。此外，GVS-Gaussian 与现有 3DGS 管线兼容，便于实际系统集成与应用。然而，方法仍依赖输入位姿精度与稀疏点云质量。未来可探索前馈式姿态估计与参数初始化策略，实现无需 COLMAP 预处理的 3DGS 训练框架，并进一步提升极端场景下的鲁棒性与渲染精度。同时，本文聚焦静态场景的新视角合成，动态场景涉及运动估计与时空一致性，同时，针对当前模型仅聚焦于静态场景的局限性，未来可结合运动估计与时空一致性建模机制，将该紧凑化思想拓展至动态时变场景。

参考文献:

- [1]马汉声,祝玉华,李智慧,等.神经辐射场多视图合成技术综述[J].计算机工程与应用,2024,60(04):21-38.
- MA H S, ZHU Y H, LI Z H, et al. A survey of multi-view synthesis techniques based on neural radiance fields [J]. Computer Engineering and Applications, 2024, 60(04): 21-38.
- [2]王文举,唐邦,顾泽骅,等.深度学习的多视角三维重建技术综述[J].计算机工程与应用,2025,61(06):22-35.
- WANG W J, TANG B, GU Z H, et al. A survey of multi-view 3D reconstruction techniques based on deep learning [J]. Computer Engineering and Applications, 2025, 61(06): 22-35.
- [3]MILDENHALL B, SRINIVASAN P P, TANIĆ M, et al. Nerf: Representing scenes as neural radiance fields for view synthesis[J]. Communications of the ACM, 2021, 65(1): 99-106.
- [4]YARIV L, GU J, KASTEN Y, et al. Volume rendering of neural implicit surfaces[J]. Advances in Neural Information Processing Systems, 2021, 34: 4805-4815.
- [5]高建, 陈林卓, 沈秋, et al. 基于三维高斯溅射技术的可微分渲染研究进展[J]. 激光与光电子学进展, 2024, 61(16): 163-75.
- GAO J, CHEN L Z, SHEN Q, et al. Research progress of differentiable rendering based on 3D Gaussian Splatting technology [J]. Laser & Optoelectronics Progress, 2024, 61(16): 163-75.
- [6]KERBL B, KOPANAS G, LEIMKUEHLER T, et al. 3D Gaussian Splatting for Real-Time Radiance Field Rendering [J]. ACM Transactions on Graphics (TOG), 2023, 42: 1-14.
- [7]YANG R, ZHU Z, JIANG Z, et al. Spectrally pruned gaussian fields with neural compensation [EB/OL]. (2025-5-25) [2024-5-1]. <https://arxiv.org/pdf/2405.00676>.
- [8]ZHANG Z, SONG T, LEE Y, et al. LP-3DGS: Learning to Prune 3D Gaussian Splatting [EB/OL]. (2025-5-25)[2024-5-29]. <https://arxiv.org/pdf/2405.18784>.
- [9]KHERADMAND S, REBAIN D, SHARMA G, et al. 3d gaussian splatting as markov chain monte carlo [J]. Advances in Neural Information Processing Systems, 2024, 37: 80965-86.
- [10]ROTA BULÒ S, PORZI L, KONTSCIEDER P. Revising densification in gaussian splatting[C]// European Conference on Computer Vision. Cham: Springer, 2024: 347-362.
- [11]FAN Z W, WANG KEVIN, WEN K R, et al. Lightgaussian: Unbounded 3d gaussian compression with 15x reduction and 200+ fps[C]// Advances in neural information processing systems. Vancouver: MIT Press, 2024: 347-362.
- [12]M. SALMAN ALI, M. QAMAR, S.-H. BAE, et al. Trimming the fat: Efficient compression of 3d gaussian splats through pruning [EB/OL]. (2025-5-25)[2024-7-29]. <https://arxiv.org/pdf/2406.18214>.
- [13]Y. LEE, Z. ZHANG, D. FAN. Safeguardgs: 3d gaussian primitive pruning while avoiding catastrophic scene destruction [EB/OL]. (2025-5-25)[2024-11-22]. <https://arxiv.org/pdf/2405.17793>.
- [14]GIRISH S, GUPTA K, SHRIVASTAVA A. EAGLES: Efficient accelerated 3D Gaussians with lightweight encodings[EB/OL]. (2025-12-20)[2024-9-26]. <https://arxiv.org/pdf/2312.04564>.
- [15]WANG H, ZHU H, HE T, et al. End-to-End Rate-Distortion Optimized 3D Gaussian Representation [C]// European Conference on Computer Vision. Cham: Springer, 2024: 76-92.
- [16]LEE JOO CHAN, RHO DANIEL, SUN XIANGYU, et al. Compact 3D Gaussian Representation for Radiance Field[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 21719-21728.
- [17]HANSON A, TU A, LIN G, et al. Speedy-Splat: Fast 3D Gaussian Splatting with Sparse Pixels and Sparse Primitives[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2025: 21537-21546.
- [18]XIANG L, CHEN X, LAI J, et al. Distilled-3DGS: Distilled 3D Gaussian Splatting[EB/OL]. (2025-08-19)[2025-12-09]. <https://arxiv.org/pdf/2508.14037>.
- [19]LIU L, CHEN Z, XU D. 3D Gaussian Splatting Data Compression with Mixture of Priors[EB/OL]. (2025-08-11)[2025-12-09]. <https://arxiv.org/pdf/2505.03310>
- [20]YU Z, SATTTLER T, GEIGER A. Gaussian opacity fields:

- Efficient adaptive surface reconstruction in unbounded scenes[J]. *ACM Transactions on Graphics (TOG)*, 2024, 43(6): 1-13.
- [21]SONG R, ZHANG W, ZHAO Y, et al. 3D visual saliency: An independent perceptual measure or a derivative of 2D image saliency?[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023, 45(11): 13083-13099.
- [22]HUANG B, YU Z, CHEN A, et al. 2d gaussian splatting for geometrically accurate radiance fields[C]//*ACM SIGGRAPH 2024 conference papers*. Colorado: ACM, 2024: 1-11.
- [23]KNAPITSCH A, PARK J, ZHOU Q-Y, et al. Tanks and temples: benchmarking large-scale scene reconstruction [J]. *ACM Trans Graph*, 2017, 36(4).
- [24]BARRON J T, MILDENHALL B, VERBIN D, et al. Mip-nerf 360: Unbounded anti-aliased neural radiance fields[C]// *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. New Orleans: IEEE Press, 2022: 5470-5479.
- [25]YE Z, LI W, LIU S, et al. Absgs: Recovering fine details in 3d gaussian splatting[C]//*Proceedings of the 32nd ACM International Conference on Multimedia*. Melbourne: ACM, 2024: 1053-1061.
- [26]HORÉ A, ZIOU D. Image Quality Metrics: PSNR vs. SSIM[C]//*proceedings of the 2010 20th International Conference on Pattern Recognition*. Istanbul: IEEE Press, 2010: 2366-2369.
- [27]BAKUROV I, BUZZELLI M, SCHETTINI R, et al. Structural similarity index (SSIM) revisited: A data-driven approach [J]. *Expert Systems with Applications*, 2022, 189: 116087.
- [28]SNELL J, RIDGEWAY K, LIAO R, et al. Learning to generate images with perceptual similarity metrics[C]//*proceedings of the 2017 IEEE international conference on image processing (ICIP)*. Beijing: IEEE Press, 2017: 4277-4281.
- [29]CHEN D, LI H, YE W, et al. PGSR: Planar-based Gaussian Splatting for Efficient and High-Fidelity Surface Reconstruction [J]. *IEEE Transactions on Visualization and Computer Graphics*, 2024, 1-12.