



计算机工程

Computer Engineering

ISSN 1000-3428, CN 31-1289/TP

《计算机工程》网络首发论文

题目: 改进的三维高斯溅射模型压缩方法
作者: 伍清波, 武友新, 于程远
DOI: 10.19678/j.issn.1000-3428.0252795
网络首发日期: 2025-12-11
引用格式: 伍清波, 武友新, 于程远. 改进的三维高斯溅射模型压缩方法[J/OL]. 计算机工程. <https://doi.org/10.19678/j.issn.1000-3428.0252795>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

改进的三维高斯溅射模型压缩方法

伍清波¹, 武友新^{1*}, 于程远²

(1. 南昌大学数学与计算机学院, 江西 南昌 330031; 2. 江西农业大学计算机与信息工程学院, 江西 南昌 330045)

摘 要: 三维高斯溅射 (3DGS) 在新视图合成与高精度场景重建中表现卓越, 然而, 其过高的模型存储开销严重限制了实际应用。为此, 提出了一种轻量化压缩方法, 以降低 3DGS 模型存储开销并提升渲染效率。首先, 引入基于局部颜色差异与冗余度的重要性评分度量方法, 以识别并剔除冗余高斯基元; 此外, 提出一种融合高斯滤波与下采样的抗混叠渐进式训练策略, 以提高训练的稳定性与效率; 在此基础上, 针对高斯基元的不同属性, 采用混合量化方案以进一步提高压缩比; 最后, 结合 Morton 编码与残差编码对高斯基元的坐标属性进行压缩, 进一步减少模型体积。为验证方法有效性, 模型在多个真实数据集上与多种现有压缩模型进行了对比实验, 结果表明, 所提方法在保持与 Reduced-3DGS 相当渲染质量的同时, 模型体积相较于原始 3DGS 降低 97.8%, 相较于 Reduced-3DGS 进一步压缩 38.8%, 同时提升了训练与渲染效率, 相较于现有的其他压缩模型均具有显著优势。模型实现了压缩率与渲染质量之间的良好平衡, 为推进 3DGS 在三维场景重建中的实际应用提供了有效解决方案。

关键词: 新视图合成; 三维高斯溅射; 模型压缩; 混合量化; 渐进式训练

中图分类号: TP391.41

文献标志码: A

DOI: 10.19678/j.issn.1000-3428.0252795

An Improved Compression Method for 3D Gaussian Splatting Models

Wu Qingbo¹, Wu Youxin^{1*}, Yu Chengyuan²

(1. School of Mathematics and Computer Sciences, Nanchang University, Jiangxi, Nanchang 330031, China;

2. School of Computer Science & Engineering, Jiangxi Agricultural University, Jiangxi, Nanchang 330045, China)

【Abstract】 3D Gaussian Splatting (3DGS) has shown remarkable performance in novel view synthesis and high-precision scene reconstruction. However, its excessively high model storage overhead significantly limits its practical applications. To address this issue, a lightweight compression method is proposed to reduce the storage cost of 3DGS models and enhance rendering efficiency. First, an importance score metric based on local color differences and redundancy is introduced to identify and eliminate redundant Gaussian primitives. Furthermore, a progressive training strategy that combines Gaussian filtering and downsampling is proposed to improve the stability and efficiency of training. On this basis, a hybrid quantization scheme is applied to different properties of the Gaussian primitives to further improve the compression ratio. Finally, Morton encoding and residual encoding are utilized to compress the coordinate attributes of the Gaussian primitives, further reducing the model size. To validate the effectiveness of the proposed method, experiments were conducted on multiple real-world datasets and compared with various existing compression models. The results show that the proposed method reduces the model size by 97.8% compared to the original 3DGS, and by an additional 38.8% compared to Reduced-3DGS, while maintaining comparable rendering quality to Reduced-3DGS. It also enhances both training and rendering efficiency, demonstrating significant advantages over other existing compression models. The model achieves a good balance between compression ratio and rendering quality, providing an effective solution for advancing the practical application of 3DGS in 3D scene reconstruction.

【Key words】 novel view synthesis; 3D Gaussian Splatting; model compression; hybrid quantization; progressive training

0 引言

随着三维重建技术的持续发展, 新视图合成 (Novel View Synthesis) 作为一种基于已知视角图像生成任意新视角场景图像的技术, 已成为三维重建领域的研究热点, 并在虚拟现实、数字内容生成及智能交互等应用场景中得到了广泛关注和应用。

在早期的研究中, 神经辐射场 (Neural Radiance Fields, NeRF) ^[1] 作为一种典型的隐式建模方法, 在新视图合成任务中取得了显著成果。其通过将三维空间坐标与视角方向输入神经网络以预测体积密度与视角依赖的颜色, 并结合可微分体渲染生成目标图像, 实现了高质量的新视图渲染效果。然而, 该方法在训练和推理阶段涉及大量神经网络前向计算与积分运算, 计算开销巨

大, 难以满足高效重建与实时渲染的实际需求。

针对 NeRF 在训练和推理阶段计算与显存开销巨大的问题, 后续研究在其隐式神经场框架中引入显式数据结构, 以实现训练加速和模型压缩。例如, Plenoxels^[2]与 DVGO^[3]将场景表示为可优化的稀疏体素网格, 结合体素剪枝与量化策略, 显著加快了训练收敛速度。然而, 由于体素数量随场景复杂度线性增长, 该类方法在大规模场景中仍面临显存与内存压力。在此基础上, VQRF^[4]引入余弦相似度剪枝与向量量化策略, 并辅以后处理微调, 将模型压缩至约 1MB, 显著减小了模型冗余。与此同时, 部分研究通过空间编码或张量分解方式降低推理开销, 如 Instant-NGP^[5]利用多分辨率哈希表对空间位置进行编码, 在实现秒级训练的同时保持较高渲染质量, 但也显著增加了存储空间占用; TensoRF^[6]则通过对四维场景张量进行低秩分解, 实现模型轻量化与分钟级训练, 但其在复杂几何与纹理区域的表现仍然有限; KiloNeRF^[7]将场景划分为数千个局部子区域, 每个子区域分别由轻量 MLP 并行建模, 有效提升了渲染速度, 但也显著增加了模型复杂度。此外, NeRFCodec^[8]提出结合神经图像压缩与体渲染的一体化端到端框架, 通过冻结预训练主干网络并微调编码解码模块, 实现特征压缩与渲染解耦, 有效降低特征存储开销, 但其方法需对每个场景单独训练, 泛化能力受限。总体来看, 尽管上述方法在训练速度、渲染效率和显存占用等方面取得了一定进展, 但由于依赖密集的体积采样这一根本限制, 这些方法在实时渲染中仍面临挑战。相比之下, Li S 等人^[9]提出的三维高斯溅射技术 (3D Gaussian Splatting, 3DGS) 以显式高斯分布替代隐式表示, 在保持渲染质量的同时显著提升了模型训练与渲染效率, 已成为近年来新视图合成领域的重要进展。

尽管 3DGS 在新视图合成的训练与渲染效率方面表现出色, 但其模型体积仍较为庞大。该方法通常需使用数百万至数千万个高斯基元来表征三维场景, 每个基元包含多达 59 个参数, 这显著增加了存储与传输开销, 在大规模场景中这一问题尤为突出。

为降低 3DGS 的存储成本, 现有研究主要可分为两大类。第一类方法通过结合神经网络学习紧凑的隐式表示实现模型压缩。例如, ScaffoldGS^[10]利用可学习锚点描述场景, 并预测神经高斯基元属性;

Octree-GS^[11]在此基础上引入八叉树多精度 (LOD) 结构以实现渐进式存储优化; HAC^[12]采用哈希网格捕捉空间一致性, 从而获得更高的压缩比与重建保真度; ContextGS^[13]则结合锚点自回归模型及分级策略实现进一步精简模型。尽管此类方法在压缩效率方面表现优异, 但其依赖多层感知机 (MLP) 进行属性预测, 导致渲染速度下降, 在对实时性要求较高的应用场景中存在一定局限。

另一类方法则通过直接减少高斯基元数量以及对其属性进行精简、量化与编码等方式实现模型的显式压缩。针对基元数量的压缩, 现有方法主要通过从不同角度评估高斯基元的重要性以剔除冗余基元。例如, Reduced-3DGS^[14]基于高斯基元在最近视角下的投影范围计算基元间的重叠率, 从而移除重叠度高的冗余基元; EAGLES^[15]通过不透明度权重评估各高斯对渲染结果的累积贡献度, 以识别低重要性基元; LightGaussian^[16]在此基础上引入高斯体积信息, 以增强重要性评估的准确性; MiniSplatting^[17]在处理室外场景时额外引入高斯投影面积加权, 并结合加权随机抽样剔除低贡献基元; PUP 3D-GS^[18]采用空间参数重建误差的二阶近似作为重要性度量, 尽管精度较高但其计算复杂度较大; Speedy-Splat^[19]则将其简化为基于二维投影梯度的轻量化评分机制, 在保证质量的同时显著降低了计算开销。此外, 部分工作通过引入可学习掩码^[20-22]或不透明度正则化^[23-24]以实现高斯基元的动态裁剪, 如 LP-3DGS^[20]通过可学习的掩码自动确定修剪比例; CompGS^[24]则通过添加正则化鼓励高斯基元的不透明度趋零, 促使不透明度较低的高斯基元在训练过程中被自然淘汰。尽管这些方法从多个角度实现了高斯基元的有效裁剪, 但对基元与其邻域之间局部相似性的利用仍较为有限。在属性精简与量化编码方面, 已有研究通过属性量化与熵编码, 以及动态调整球谐函数阶数等方式, 压缩属性表示所需的数据量, 从而降低整体模型体积。例如, Reduced-3DGS^[14]对除三维坐标外的所有属性进行标量量化, 并以半精度浮点格式存储属性码本与坐标, 同时根据高斯基元在不同视角下的颜色变化自适应调整球谐函数阶数, 从而降低了存储与渲染计算负担; TinyGS^[26]引入光照探针替代高阶球谐函数表征视角相关光泽, 仅保留基元的零阶球谐函数表征漫反

射颜色,实现参数的精简;SOG^[27]提出空间分块动态量化,通过局部坐标系变换与自适应范围分配,实现了高效压缩;C3DGS^[28]则结合敏感度导向的聚类与量化感知训练,对高斯属性进行分组离散,并使用分层熵编码进一步压缩。值得注意的是,现有矢量量化策略多基于欧氏距离进行聚类,在处理结构敏感属性(如旋转四元数)时效果受限,难以充分保留其几何一致性。

为降低模型训练的计算开销并提升重建精度,一些研究提出了渐进式训练策略。例如,EAGLES^[15]在训练初期对输入图像进行下采样,并随着训练迭代次数逐步恢复其分辨率;Umar Farooq 等人^[28]则通过引入均值滤波来引导模型由粗到细的逐步学习场景特征。尽管上述方法在一定程度上减轻了训练负担,但单纯的下采样方法可能导致高频信息混叠甚至丢失;而简单的均值滤波虽能对图像进行有效的平滑,但也可能引起高频细节的过度损失,从而影响最终的渲染质量。

针对上述不足,本文在 Reduced-3DGS^[14]的基础上提出一种高效的轻量化压缩方法。首先,引入高斯基元与邻域之间的颜色差异性作为冗余度指标补充,

提升冗余基元剔除的准确性;其次,设计抗混叠的渐进式训练策略,从低分辨率全局结构开始,逐步引导至高频细节的学习,兼顾效率与质量;第三,提出混合量化方案,针对旋转四元数与球谐函数直流分量采用基于敏感度与测地距离的矢量量化,其余属性则采用标量量化,实现差异化压缩;最后,引入基于 Morton 编码的三维坐标残差压缩模块,有效提升坐标压缩效率。实验结果表明,本文方法在保持渲染质量的前提下,显著降低了模型体积,并提升了训练与渲染速度。

1 方法

本文方法整体框架如图 1 所示,包括融合局部颜色差异与冗余度的重要性评分、抗混叠渐进式训练、高斯属性的混合量化,以及坐标残差压缩等关键模块。其中 SH-DC 与 SH-AC 分别表示球谐函数的直流分量(0 阶系数)与高阶分量(1 阶及以上),用于描述高斯基元的颜色属性。球谐函数阶数的动态调整基于 Reduced-3DGS 的已有实现。上述各模块在训练过程中协同工作,共同提升模型的紧凑性与渲染效率。下文将依次对各模块进行详细介绍。




图 1 本文方法整体框架图

Figure 1 Overall framework of the proposed method

1.1 融合局部颜色差异与冗余度的重要性评分

原始 3DGS 依赖大量高斯基元表征场景,其中存在大量冗余基元。为解决这一问题,Reduced-3DGS^[14]提出了一种分辨率感知的冗余基元剪枝策略,通过动态评估高斯基元在空间中的冗余度实现高斯剔除。首先计算每个高斯基元在最近可见视角下的最小像素

覆盖面积 $a_{\min}$,随后以基元位置 μ_i 为中心定义球形邻域,其半径计算公式为公式(1)。

$$r = \sqrt{a_{\min} \times \frac{\sqrt{2}}{3}} \quad (1)$$

在该邻域中统计包含的高斯基元数量以估算局部冗余度,并将该区域内所有基元的最小冗余度作为

当前基元的冗余评分 h_i 。基于该评分, 低冗余基元将被保留, 其余则被剔除。

然而, 该策略未充分考虑高斯基元间的颜色差异。在细节丰富或纹理变化剧烈的区域, 空间上接近的基元可能承载不同的颜色信息, 单纯依赖空间冗余评分容易导致误删。而颜色冗余但评分较低的基元则可能被错误保留, 影响压缩效率与渲染质量。因此, 冗余性评估应同时考虑空间重叠程度与颜色一致性。但若直接基于所有训练视角逐一计算每个基元邻域内的颜色相似性, 不仅计算开销巨大, 且难以涵盖未观测方向的颜色变化。为此, 本文基于高斯基元的球谐函数系数进行颜色差异性度量。

设两个分别定义在不同高斯基元方向域(即单位球面 S^2) 上的球谐函数分别为 $f(\Omega)$ 与 $g(\Omega)$, 其中 Ω 表示单位方向。它们在球谐基函数下的展开系数分别记作 $f_{\ell m}$ 与 $g_{\ell m}$, 其中 $\ell \geq 0$ 表示球谐函数的阶数, m 为对应方位阶, 满足 $|m| \leq \ell$ 。根据球谐函数的正交归一性和 Parseval 恒等式^[30], 球面方向域上的 L^2 距离可转化为球谐系数空间的平方差和, 在 3DGS 中, 通常采用截断阶数 $L=3$, 此时 L^2 距离的近似计算形式如公式(2)所示。

$$\begin{aligned} & \frac{1}{4\pi} \int_{\Omega} |f(\Omega) - g(\Omega)|^2 d\Omega \\ & \approx \sum_{\ell=0}^L \sum_{m=-\ell}^{\ell} |f_{\ell m} - g_{\ell m}|^2 \end{aligned} \quad (2)$$

考虑到高阶系数的数量随阶数 ℓ 增大而线性增加, 若直接对所有系数求和将会放大高频分量的影响。为实现不同阶数之间的平衡, 本文引入加权平均策略, 最终颜色差异度量定义如公式(3)所示。

$$D(f, g) = \sqrt{\sum_{\ell=0}^L \frac{1}{2\ell+1} \sum_{m=-\ell}^{\ell} (f_{\ell m} - g_{\ell m})^2} \quad (3)$$

在剪枝阶段, 对于每个高斯基元, 基于公式(3)计算其与球形邻域内其他基元的平均颜色差异 d_i , 随后, 依据公式(4)对其进行对数变换与归一化, 得到颜色差异分数 ρ_i 。

$$\rho_i = \frac{\ln(d_i + 1) - \min(\ln(d + 1))}{\max(\ln(d + 1)) - \min(\ln(d + 1))} \quad (4)$$

同时, 对冗余评分 h_i 施加幂律归一化, 以抑制极端值影响, 得到归一化冗余度 $\tilde{h}_i$, 计算公式如公式(5)所示。

$$\tilde{h}_i = \text{clamp} \left(\left(\frac{h_i}{\mu + 3\sigma} \right)^2, 0, 1 \right) \quad (5)$$

其中 μ 和 σ 分别为所有冗余评分的均值与标准差。并使用 clamp 函数¹将数值限制在 $[0, 1]$ 区间内。

综合考虑局部颜色差异性、空间冗余度和不透明度因素, 定义最终重要性评分 I_i 如公式(6)所示。

$$I_i = \lambda \alpha_i + (1 - \lambda) [1 - \rho_i (1 - \tilde{s}_i)] \quad (6)$$

其中, $\lambda \in [0, 1]$ 为加权系数。最后, 剔除所有重要性评分低于阈值 τ 的高斯基元。

1.2 抗混叠渐进式训练策略

原始 3DGS 中, 模型自始至终使用全分辨率图像进行训练。这种策略在训练初期由于椭球数量有限, 模型被迫拟合场景中的高频细节, 容易引发伪影并增加训练复杂度。为缓解上述问题, EAGLES^[15]提出了一种基于余弦退火的分辨率调度策略, 即通过如公式(7)所示的余弦函数确定第 t 次迭代时所使用的图像缩放因子 $s_t \in [0, 1]$, 其中, s_{start} 为初始缩放因子, s_{end} 为最终缩放因子(本文设为 1)。然后基于缩放因子对图像进行下采样训练, 在 T 次迭代后恢复至全分辨率, 以实现模型先学习低频特征, 再逐步适应高频细节, 从而提升训练效率并减少椭球数量。然而, 若直接进行图像下采样, 则在缩放比例较小时会引发明显的混叠效应, 即图像出现伪轮廓、频率折叠等失真现象, 这将阻碍模型对真实场景结构的准确拟合, 并容易产生多余的高斯基元。

$$s_t = s_{\text{end}} + \frac{1}{2} (s_{\text{start}} - s_{\text{end}}) \cdot \left(1 + \cos \left(\pi \cdot \frac{t}{T} \right) \right) \quad (7)$$

为有效抑制混叠影响, 本文在下采样前引入高斯平滑滤波, 以削弱图像中的高频成分。滤波核的标准差 σ 会根据当前缩放因子 s 动态调整, 其计算方式基于奈奎斯特采样定理, 具体公式如公式(8)所示。

$$\sigma = \frac{1}{2} \sqrt{\frac{1}{s^2} - 1} \quad (8)$$

该策略能确保在缩放比例较小时施加足够的平滑, 降低混叠对训练过程的负面影响。通过结合渐进式分辨率调整与抗混叠滤波, 模型能够在训练初期专

¹ clamp(x, min, max) 是 PyTorch 中的张量操作函数, 用于将输入值限制在区间 [min, max] 内。

注捕捉低频结构信息,逐步过渡至高频细节,从而实现更高效稳健的优化。

1.3 基于敏感度与测地距离的混合量化策略

在 Reduced-3DGS 中,模型训练完成后将对每个高斯基元除空间坐标外的所有属性进行码本大小为 255 的标量量化,以实现模型压缩。尽管该方法实现简单,但对高维属性进行量化后需要为其每个维度存储对应的索引,导致索引存储开销随维度线性增长,从而限制了压缩率。为此,本文借鉴 C3DGS^[28]的设计思想,针对旋转四元数与球谐函数直流分量,引入基于敏感度的矢量量化策略,以提升压缩效率并实现更合理的精度分配。

在模型训练的第 k 次训练迭代时,首先基于 C3DGS^[28]中的敏感度计算公式计算待量化参数 θ (旋转四元数或球谐函数直流分量) 的敏感度,具体计算过程如公式(9)所示。

$$\Phi(\theta) = \frac{1}{\sum_{i=1}^V P_i} \sum_{i=1}^V \left| \frac{\partial E_i}{\partial \theta} \right| \quad (9)$$

其中, V 为视图总数, P_i 表示第 i 个视图的像素数量, E_i 为该视图的图像能量,即所有像素 RGB 值之和。

随后,基于敏感度计算结果,在高维属性空间中对所有 θ 向量执行聚类,以获取最优量化中心。由于旋转四元数本质上定义在超球面流形上,使用欧氏距离进行聚类难以准确度量其几何关系,容易导致语义扭曲。为更真实地刻画四元数之间的差异,本文采用测地距离 d_{geo} 作为相似性度量,计算公式如公式(10)所示。

$$d_{\text{geo}}(q_i, q_j) = \arccos(|\langle q_i, q_j \rangle|) \quad (10)$$

其中, $|\langle q_i, q_j \rangle|$ 表示单位四元数 q_i 与 q_j 的内积,取绝对值保证表示同一旋转时距离相同。聚类完成后,本文在后续模型训练过程中进入量化微调阶段,对码本中心进行有限步的梯度优化,使其更贴近真实参数分布,进一步降低量化误差,提升最终重建质量。

1.4 基于 Morton 编码的三维坐标残差压缩

在 Reduced-3DGS 中,三维坐标因对渲染精度高度敏感,因此仅采用半精度量化,而其余属性则通过标量量化和自适应球谐函数阶数进行压缩。在该策略

下,坐标数据约占模型文件体积的 30%;在本文提出的混合量化方案中,这一比例提升至约 38%,成为模型中占比最高的单一属性,其压缩性能对模型整体体积具有决定性影响。

为评估其压缩潜力,本文对各属性的数据分布特性进行了统计分析。结果表明,坐标数据在空间上具有明显的局部连续性,相邻基元的坐标变化平缓。而其他属性在量化后呈现近似最大熵的分布特征,随机性较强,难以进一步压缩。因此,本文提出一种结合 Morton 编码与残差压缩的坐标无损压缩方案。

首先,对高斯坐标进行 Morton 编码,以确保相邻坐标在三维空间中尽可能接近。随后将坐标通过二进制映射转为整数类型,以避免小数部分在残差编码中导致的精度损失,并基于公式(11)构建残差序列。

$$\Delta\mu_{(1)} = \mu_{(1)}, \quad \Delta\mu_{(i)} = \mu_{(i)} - \mu_{(i-1)}, \quad i = 2, \dots, N \quad (11)$$

其中, $\mu_{(i)}$ 表示经 Morton 编码后的第 i 个高斯坐标。最后,采用 LZMA 算法^[31]对残差序列进行无损编码,以进一步压缩其中的冗余信息。

2 实验

2.1 实验细节设置

为验证所提方法在多种环境中的有效性,本文选取多个涵盖室内与室外的真实场景进行实验评估。实验所用数据集包括 Mip-NeRF360^[32]中的九个场景、Deep Blending^[33]中的两个场景以及 Tanks&Temples^[34]中的两个场景。所有实验均基于 Reduced-3DGS 的开源实现,采用与其原论文一致的超参数设置。服务器操作系统为 Ubuntu 20.04,配备 128GB DDR5 内存,Intel i7-13700F 处理器,并搭载 NVIDIA RTX 4090 GPU。软件环境方面,Python 版本为 3.7.13,Pytorch 版本为 1.12.1+cu116, CUDA 版本为 12.6。

模型训练共迭代 30000 步,其中前 10000 步采用抗混叠渐进式训练策略。训练初始时图像分辨率缩放因子设为 0.3,并在前 10000 步内通过余弦退火函数平滑提升至原始分辨率,随后保持全分辨率至训练结束。在训练至 15000 步之前,基于融合局部相似性的重要性评分(权重系数 $\lambda=0.43$, 阈值 $\tau=0.35$) 每 1000 步对高斯基元进行剪枝,至第 15000 步时,停止致密化操作,并根据 Reduced-3DGS 的默认设置执行球谐函数阶数动态裁剪。由于裁剪后颜色信息大幅简

化,剪枝策略切换为 Reduced-3DGS 的冗余基元剔除方法,并沿用该方法的参数设置,剪枝频率为每 1000 步执行一次,持续至第 27000 步时停止剪枝。同时在 27000 步对旋转四元数及球谐函数直流分量实施基于敏感度的向量聚类量化,其中旋转四元数的量化使用测地距离,码本大小为 8092,球谐函数直流分量的量化则采用欧式距离,码本大小为 4096。然后在 27000 步到 30000 步之间完成量化微调。模型训练结束后,对不透明度和缩放向量进行标量量化,码本大小均为 256。量化结束后,启动三维坐标残差编码模块,对高斯基元的坐标信息进行无损压缩并保存模型。

2.2 对比实验

2.2.1 定量分析

为验证在旋转四元数聚类量化中采用测地距离替代欧式距离的有效性,我们选取 Tanks&Temples 数据集^[34]设计对比实验。实验中保持其余量化流程一致,仅在聚类阶段将距离度量由欧式距离替换为测地距离。表 1 给出了两种距离度量方式下的重建质量指标对比结果。

表 1 不同距离度量的量化效果对比

Table 1 Comparison of quantization performance using different

distance metrics

Distance Metric	PSNR↑	SSIM↑	LPIPS↓
Euclidean Distance	23.58	0.842	0.191
Geodesic Distance	23.61	0.843	0.189

从表中可见,引入测地距离后,PSNR 较欧式距离提升 0.03 dB,SSIM 提升 0.001,LPIPS 降低 0.002。该结果表明,测地距离更贴合四元数所在流形的几何结构,能够更精准地衡量旋转差异,从而在量化聚类中获得更优的重建质量。

为验证抗混叠渐进式训练相较于纯下采样策略的优势,我们仍以 Tanks&Temple 数据集^[34]为例,并以 Reduced-3DGS 为基线,比较其在纯下采样与高斯平滑后下采样两种训练策略下的表现。结果如表 2 所示,纯下采样可在不影响收敛稳定性的前提下,将 PSNR 提升 0.1 dB,并将峰值与最终椭球数分别减少 5%和 3%,同时训练时间缩短近 9%。在此基础上

引入高斯预滤波后再下采样,PSNR 再次提升 0.04dB,椭球数减少 5%,训练时长缩短 3%。上述对比充分证明,高斯平滑有效抑制了下采样引入的混叠伪影,使模型能在低分辨率下更准确的学习场景低频结构。

表 2 不同采样方式的训练效果对比

Table 2 Comparison of training performance under different sampling

strategies

Sampling Method	PSNR↑	Max Primitives↓	Final Primitives↓	time↓
Reduced-3DGS	23.52	1.50M	0.65M	6m52s
Downsampling	23.62	1.43M	0.63M	6m01s
Gaussian Smoothing +Downsampling	23.66	1.36M	0.60M	5m50s

为全面评估本文方法的性能,我们围绕渲染质量、模型体积、渲染帧率与运行时间四个方面,与最近具有代表性的 3DGS 压缩方法进行了系统性对比。其中,渲染帧率的测量方法基于 Reduced-3DGS^[14]所提供的开源代码。所选对比模型包括:原始 3DGS^[9],本文的基线模型 Reduced-3DGS^[14]、近年来具有代表性的显式压缩方法 EAGLES^[15]、LightGaussian^[16]、SOG^[27]、Compact-3DGS^[22]、C3DGS^[28],以及最近引入神经网络实现隐式压缩的 HAC^[12]。所有方法均基于其原论文中设定的超参数,并使用对应的开源代码进行训练与评估。对比结果如表 3 和表 4 所示,表中对不同压缩方法的各项指标最优值以粗体显示,次优值前加星号标注。

在 Mip-NeRF360 数据集中,本文方法取得了综合指标的最优表现,模型体积仅比 HAC 大 1.82 MB,但渲染帧率达到 HAC 的 1.96 倍,表现出良好的压缩与渲染性能平衡。

在 Deep Blending 数据集中,HAC 虽以 4.32 MB 的模型体积实现了最高压缩比,但其渲染速度仅 398 FPS。相比之下,本文方法在模型体积显著优于大多数方案的同时,实现了 754 FPS 的最高帧率。

在 Tanks&Temples 数据集中,本文方法在模型体积更小的条件下实现了与 HAC 相近的重建质量,同时渲染帧率相比 HAC 提升 2.92 倍,综合表现优于其他压缩方法。

总体来看,本文方法相比原始 3DGS 模型体积平均缩减 97.8%,渲染帧率提升近两倍;相较基线模型 Reduced-3DGS,在保持渲染质量的情况下,模型体积进一步减少 38.8%。与 LightGaussian 等显式压缩方法相比,本文方法在压缩率、视觉质量及渲染速度方面实现了更优的表现,这得益于本文的重要性评分方法能够更加精准的去冗余高斯基元,同时抗混叠渐进式训练减少了训练过程中无用高斯基元的生成,此外,混合量化相比于其他模型的单一量化方案也更加灵活精确。与引入神经网络的隐式压缩方案 HAC 相比,尽管综合压缩率略有差距,但在渲染效率与训练速度方面具有明显优势,这是由于 HAC 虽然通过神经网络和哈希网格更有效的利用了上下文信息,但每次渲染时都需通过 MLP 计算生成基元参数,导致渲染时间较长。

2.2.2 算法运行效率分析

本文方法在各个数据集上的运行时间如表 3 和表 4 所示。与基线方法 Reduced-3DGS 相比,本文方法的训练时间略有下降,主要得益于渐进式训练减少了前期计算量,并且通过重要性评分抑制了高斯基元数量的增长。相比其他方法,本文方法在训练时间上的优势更加明显。这是因为 LightGaussian 和 C3DGS 需要在模型训练完成后才进行裁剪与量化,而 Compact-3DGS 等方法虽将压缩过程融入训练,但通常仅在训练后期进行有限次数高斯基元剔除,前期基元数量增长未受到影响。相比之下,本文方法在整个训练过程中动态裁剪高斯基元,显著减少了无用基元的训练。此外,HAC 虽通过锚点减少了参数量,但由于每次迭代都需动态生成基元参数,导致训练时间较长。

表 3 在 Mip-NeRF360 和 Deep Blending 数据集上的对比实验结果
Table 3 Comparative results on the Mip-NeRF360 and Deep Blending datasets

Dataset	Mip-NeRF360						Deep Blending					
Method/Metric	PSNR↑	SSIM↑	LPIPS↓	size/MB↓	FPS↑	time↓	PSNR↑	SSIM↑	LPIPS↓	size/MB↓	FPS↑	time↓
3DGS (TOG 2023)	27.34	0.815	0.217	756.4	320	20m06s	29.52	0.902	0.242	675.76	363	23m07s
Reduced-3DGS (I3D 2024)	27.16	0.811	0.223	29.38	556	*12m22s	29.65	0.904	0.246	18.30	*720	*14m37s
EAGLES (ECCV 2024)	27.17	0.808	0.233	55.15	421	16m47s	29.79	0.906	0.247	52.73	346	17m27s
LightGaussian (NeurIPS 2024)	27.03	0.802	0.236	51.30	592	29m53s	29.17	0.895	0.260	44.22	694	28m47s
Compact-3DGS (CVPR 2024)	26.98	0.799	0.242	25.28	377	25m20s	*29.82	0.904	0.255	20.86	548	21m10s
C3DGS (CVPR 2024)	27.03	0.802	0.234	28.80	374	23m21s	29.45	0.901	0.249	25.30	465	25m31s
SOG (ECCV 2024)	26.90	0.796	0.231	38.42	336	25m31s	29.26	0.894	0.267	16.92	565	22m43s
HAC (ECCV 2024)	27.55	0.809	0.233	16.28	297	20m43s	29.96	0.904	0.265	4.32	398	15m57s
Proposed Method	*27.21	0.812	*0.225	*18.10	*583	11m04s	29.74	0.906	0.245	*11.12	754	13m25s

注：表中粗体为各指标最优值；*表示次优值。

表 4 在 Tanks&Temple 数据集上的对比实验结果

Table 4 Comparative results on the Tanks&Temple datasets

Method/Metric	PSNR↑	SSIM↑	LPIPS↓	size/MB↓	FPS↑	time↓
3DGS (TOG 2023)	23.39	0.842	0.182	421.90	383	14m24s
Reduced-3DGS (I3D 2024)	23.52	0.842	0.188	13.94	*839	*6m52s
EAGLES (ECCV 2024)	23.34	0.837	0.205	24.73	535	9m18s
LightGaussian (NeurIPS 2024)	23.28	0.835	0.203	28.87	801	19m42s
Compact-3DGS (CVPR 2024)	23.30	0.834	0.200	18.18	447	13m49s
C3DGS (CVPR 2024)	23.37	0.835	0.191	17.29	507	16m21s
SOG (ECCV 2024)	23.56	0.837	0.186	21.73	483	16m11s
HAC (ECCV 2024)	24.06	0.845	*0.187	*8.12	316	18m45s
Proposed Method	*23.62	*0.843	0.189	8.02	925	5m51s

注：表中粗体为各指标最优值；*表示次优值。

2.2.3 定性分析

模型可视化效果如图 2 所示。可以看出，本文方法在高频与颜色丰富区域具有较好的可视化效果，这得益于本文的重要性评分机制能够有效识别高斯基元的局部颜色差异性，相比 Reduced-3DGS，在颜色

变化较大区域能够更好地保留表征不同颜色的高斯基元。同时，通过抗混叠渐进式训练策略，使模型能更好的拟合高频细节区域，从而提升整体视觉效果。




图 2 模型可视化效果对比

Figure 2 Comparison of Model Visualization Results



图 2 模型可视化效果对比 (续图)

Figure 2 Comparison of Model Visualization Results (Continued)

2.3 消融实验

为探究矢量量化启动时机对模型最终训练结果的影响,我们基于 Tanks&Temple 数据集^[34],分别在训练的最后 5000 轮、4000 轮、3000 轮和 2000 轮进行旋转四元数与球谐函数直流分量的矢量量化与量化微调。实验结果如表 5 所示。结果表明,模型在最后 3000 轮进行量化微调时,各项指标综合表现最佳,

这是由于在 27000 步之前,模型仍在进行冗余高斯基元的裁剪,模型参数变化较大。而若在 28000 步时启动微调,则微调训练不充分,导致结果质量受限。

表 5 矢量量化启用时机对模型效果的影响对比

Table 5 Comparison of the Impact of Vector Quantization Activation Timing on Model Performance

Activation Iteration	PSNR↑	SSIM↑	LPIPS↓
25k	23.59	0.843	0.190
26k	23.57	0.841	0.189
27k	23.62	0.843	0.189
28k	23.60	0.842	0.190

为研究抗混叠渐进式训练的最佳训练时机,我们在 6000 至 16000 次迭代的范围内,选择每隔 2000 次迭代作为渐进式训练的结束时机(具体为在 6000、8000、10000、12000、14000 和 16000 次迭代时结束),并使用 Tanks&Temple 数据集^[34]进行实验。实验结果如图 3 和图 4 所示。结果表明,当训练在 10000 次迭代时结束时,模型能够获得最高的 PSNR 值,并且椭球数量的变化趋于稳定。




图 3 渐进式训练结束时机对 PSNR 的影响

Figure 3 Impact of the Progressive Training Termination Timing on




图 4 渐进式训练结束时机对高斯基元数量的影响

Figure 4 Impact of the Progressive Training Termination Timing on the
Number of Gaussian Primitives

为系统评估本文所提出各模块的有效性,我们以 Reduced-3DGS 为基准模型构建消融实验,并在 Mip-NeRF360 与 Tanks&Temples 两个数据集上进行

测试。实验采用逐步累加模块的方式展开:首先,将原始冗余剪枝策略替换为融合局部颜色差异与冗余度的重要评分机制;其次,引入抗混叠的渐进式训练策略;进一步,针对旋转四元数与球谐函数直流分量,设计基于敏感度的矢量量化方法,并与原有标量量化方式结合形成混合量化机制;最后,在三维坐标压缩中引入基于 Morton 编码的残差编码模块。

实验结果如表 6 和表 7 所示,基线模型在两个数据集上的平均 PSNR 为 26.50dB,平均模型大小为 26.59MB。引入本文的重要性评分机制后,尽管由于颜色差异度计算的引入使得单个基元重要性评估的计算复杂度增加,导致训练时间小幅增长,但该方法将平均 PSNR 提升至 26.54 dB,模型大小缩减至 25.26 MB,且训练阶段的最大高斯基元数减少了 6%。这一结果表明,融合局部相似性评分机制能有效识别颜色冗余,并在致密化阶段更精准地剔除冗余基元,从而在不损失渲染质量的情况下减少模型规模。

进一步加入抗混叠渐进式训练后,最大高斯基元数再次减少 7%,训练时间平均缩短 15%,而模型体积降至 23.5MB,说明低分辨率过渡训练与高斯滤波机制有助于场景细节还原以及减少无效的高斯基元的生成,同时由于前期图像分辨率降低,模型计算量减少,有效缩短了整体训练时长。

在此基础上应用混合量化策略后,尽管参数精度有所降低,PSNR 与 SSIM 出现微幅波动,但与标量量化相比,矢量量化通过聚类向量有效减少了参数量,使得模型大小显著压缩至 19.0MB,相较前一步减少近 20%,大幅降低了存储开销。同时,虽然在迭代后期需要对聚类结果进行量化微调,增加了计算复杂度,但由于剪枝后高斯基元数量大幅下降,同时量化后的数据存储更紧凑,减少了全局内存访问的冗余,最终训练时间基本保持不变。

最后,应用三维坐标残差编码对基元坐标位置进行编码压缩,实现在保持渲染质量基本不变的情况下,平均模型大小进一步降至 16.3 MB,压缩幅度达 15%,这一结果表明,残差压缩能够有效利用高斯基元的空间局部性,实现无损压缩。

整体来看,四项改进在性能与压缩之间实现了良好平衡。最终模型在两个数据集上的平均 PSNR 提升

至 26.55 dB, 累计压缩率达到 39%, 同时渲染帧率由 607FPS 提升至 645FPS。

表 6 在 Mip-NeRF360 数据集上的消融实验结果

Table 6 Ablation study results on the Mip-NeRF360 dataset

Method/Metric	PSNR↑	SSIM↑	LPIPS↓	Max Primitives↓	Time↓	FPS↑	Size /MB↓
Reduced-3DGS	27.16	0.811	0.223	2.73M	12m22s	556	29.4
+ Importance Score	27.19	0.811	0.224	2.59M	12m43s	560	28.1
+ Progressive Training	27.20	0.813	0.224	2.41M	10m49s	571	26.2
+ Hybrid Quantization	27.21	0.812	0.225	2.41M	10m52s	583	21.2
+ Residual Encoding	27.21	0.812	0.225	2.41M	11m04s	583	18.1

表 7 在 Tanks&Temple 数据集上的消融实验结果

Table 7 Ablation study results on the Tanks&Temple dataset

Method/Metric	PSNR↑	SSIM↑	LPIPS↓	Max Primitives↓	time↓	FPS↑	Size /MB↓
Reduced-3DGS	23.52	0.842	0.188	1.50M	6m52s	839	13.94
+ Importance Score	23.61	0.843	0.187	1.34M	7m00s	882	12.47
+ Progressive Training	23.64	0.844	0.188	1.25M	5m48s	921	11.39
+ Hybrid Quantization	23.62	0.843	0.189	1.25M	5m46s	925	9.23
+ Residual Encoding	23.62	0.843	0.189	1.25M	5m51s	925	8.02

3 结束语

本文针对 3DGS 模型存在的存储开销较大的问题, 基于 Reduced-3DGS 框架提出了一套涵盖冗余基元剔除、渐进式训练、属性压缩与坐标编码的综合优化策略。通过引入融合局部颜色差异与冗余度的重要性评分、抗混叠渐进式训练流程、基于属性敏感度的混合量化方案以及基于空间局部性的坐标残差压缩方法, 显著提升了模型的紧凑性并有效降低了模型体积。在多个真实场景数据集上的实验结果表明, 本文方法在保持重建质量的前提下, 相较原始 3DGS 模型和基准模型 Reduced-3DGS, 其模型体积平均分别减少 97.8% 和 38.8%。同时, 与最近的引入神经网络的隐式压缩方法 HAC 相比, 本文方法在实现相近压缩率的基础上获得了更高的渲染帧率与更短的训练时长。

尽管本文方法在静态场景中实现了显著的压缩效果, 但尚未适配动态场景中的结构变化, 存在一定局限性。未来的研究将重点探讨如何将本文方法扩展至动态场景, 以提升模型对复杂环境的适应能力及其实际应用价值。

参考文献

- [1] Mildenhall B, Srinivasan P P, Tancik M, et al. Nerf: Representing scenes as neural radiance fields for view synthesis[J]. Communications of the ACM, 2021, 65(1): 99-106.
- [2] Fridovich-Keil S, Yu A, Tancik M, et al. Plenoxels: Radiance fields without neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 5501-5510.
- [3] Sun C, Sun M, Chen H T. Direct voxel grid optimization: Super-fast convergence for radiance fields reconstruction[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 5459-5469.
- [4] Li L, Shen Z, Wang Z, et al. Compressing volumetric radiance fields to 1 mb[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 4222-4231.
- [5] Müller T, Evans A, Schied C, et al. Instant neural graphics primitives with a multiresolution hash encoding[J]. ACM transactions on graphics (TOG), 2022, 41(4): 1-15.
- [6] Chen A, Xu Z, Geiger A, et al. Tensorf: Tensorial radiance fields[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 333-350.
- [7] Reiser C, Peng S, Liao Y, et al. Kilonerf: Speeding up neural radiance fields with thousands of tiny mlps[C]//Proceedings of the

- IEEE/CVF international conference on computer vision. 2021: 14335-14345.
- [8] Li S, Li H, Liao Y, et al. NeRFCodec: Neural feature compression meets neural radiance fields for memory-efficient scene representation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 21274-21283.
- [9] Kerbl B, Kopanas G, Leimkühler T, et al. 3d gaussian splatting for real-time radiance field rendering[J]. ACM Trans. Graph., 2023, 42(4): 139:1-139:14.
- [10] Lu T, Yu M, Xu L, et al. Scaffold-gs: Structured 3d gaussians for view-adaptive rendering[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 20654-20664.
- [11] Ren K, Jiang L, Lu T, et al. Octree-gs: Towards consistent real-time rendering with lod-structured 3d gaussians[J]. arXiv preprint arXiv:2403.17898, 2024.
- [12] Chen Y, Wu Q, Lin W, et al. Hac: Hash-grid assisted context for 3d gaussian splatting compression[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 422-438.
- [13] Wang Y, Li Z, Guo L, et al. Contextgs: Compact 3d gaussian splatting with anchor level context model[J]. Advances in neural information processing systems, 2024, 37: 51532-51551.
- [14] Papantonakis P, Kopanas G, Kerbl B, et al. Reducing the memory footprint of 3d gaussian splatting[J]. Proceedings of the ACM on Computer Graphics and Interactive Techniques, 2024, 7(1): 1-17.
- [15] Girish S, Gupta K, Shrivastava A. Eagles: Efficient accelerated 3d gaussians with lightweight encodings[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 54-71.
- [16] Fan Z, Wang K, Wen K, et al. Lightgaussian: Unbounded 3d gaussian compression with 15x reduction and 200+ fps[J]. Advances in neural information processing systems, 2024, 37: 140138-140158.
- [17] Fang G, Wang B. Mini-splatting: Representing scenes with a constrained number of gaussians[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 165-181.
- [18] Hanson A, Tu A, Singla V, et al. Pup 3d-gs: Principled uncertainty pruning for 3d gaussian splatting[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 5949-5958.
- [19] Hanson A, Tu A, Lin G, et al. Speedy-splat: Fast 3d gaussian splatting with sparse pixels and sparse primitives[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 21537-21546.
- [20] Zhang Z, Song T, Lee Y, et al. LP-3DGS: Learning to Prune 3D Gaussian Splatting[J]. arXiv preprint arXiv:2405.18784, 2024.
- [21] Wang H, Zhu H, He T, et al. End-to-end rate-distortion optimized 3d gaussian representation[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 76-92.
- [22] Lee J C, Rho D, Sun X, et al. Compact 3d gaussian representation for radiance field[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 21719-21728.
- [23] Li X, Li K, Zhang G, et al. LFGVS: lightweight Gaussian splatting method for few-shot view synthesis[J]. The Journal of Supercomputing, 2025, 81(4): 1-26.
- [24] Navaneet K L, Pourahmadi Meibodi K, Abbasi Koohpayegani S, et al. Compgs: Smaller and faster gaussian splatting with vector quantization[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 330-349.
- [25] Kou Y, Ye Q, Zhang Y, et al. AMQGaussian: Efficient 3D Gaussian Representation with Asymmetric Mixed-precision Quantization[C]//2024 IEEE International Symposium on Parallel and Distributed Processing with Applications (ISPA). IEEE, 2024: 1563-1570.
- [26] 宋明清,郭尧,李晓峰,等.基于光照探针的三维高斯辐射场压缩算法[J/OL]. 计算机应用研究,2025,42(9):2840-2846.
- Song Mingqing, Guo Yao, Li Xiaofeng, et al. Compression algorithm for 3d Gaussian radiance fields based on light probes[J]. Application Research of Computers, 2025,42(9):2840-2846.
- [27] Morgenstern W, Barthel F, Hilsmann A, et al. Compact 3d scene representation via self-organizing gaussian grids[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 18-34.
- [28] Niedermayr S, Stumpfegger J, Westermann R. Compressed 3d gaussian splatting for accelerated novel view synthesis[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 10349-10358.
- [29] Farooq U, Guillemaut J Y, Hilton A, et al. Optimized 3D Gaussian Splatting using Coarse-to-Fine Image Frequency Modulation[J]. arXiv preprint arXiv:2503.14475, 2025.
- [30] Müller C. Spherical harmonics[M]. Springer, 2006.
- [31] P Pavlov I. 7-Zip LZMA SDK Technical Reference[EB/OL]. <2015-6-14> [2025-07-19]. <https://www.7-zip.org/sdk.html>.

- [32] Barron J T, Mildenhall B, Verbin D, et al. Mip-nerf 360: Unbounded anti-aliased neural radiance fields[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 5470-5479.
- [33] Hedman P, Philip J, Price T, et al. Deep blending for free-viewpoint image-based rendering[J]. ACM Transactions on Graphics (ToG), 2018, 37(6): 1-15.
- [34] Knapitsch A, Park J, Zhou Q Y, et al. Tanks and temples: Benchmarking large-scale scene reconstruction[J]. ACM Transactions on Graphics (ToG), 2017, 36(4): 1-13.

