

分类号：_____

密级：_____

UDC：_____

编号：_____

专业学位硕士学位论文

面向三维环境的类脑同步定位与 3DGS 建图 方法研究

硕士研究生：田鑫雨

指导教师：陈广 副研究员

校外导师：周会军 高级工程师

学位类别：工程硕士

哈尔滨工程大学

2025 年 4 月

分类号：_____

密级：_____

UDC：_____

编号：_____

专业学位硕士学位论文

面向三维环境的类脑同步定位与 3DGS 建图 方法研究

(☐产品研发☐工程规划☐工程设计☒应用研究)

硕士研究生：田鑫雨

指导教师：陈广 副研究员

校外导师：周会军 高级工程师

专业类别：电子信息

所在学院：智能科学与工程学院

论文提交日期：2025 年 4 月

论文答辩日期：2025 年 5 月

学位授予单位：哈尔滨工程大学

Classified Index:

U.D.C:

A Thesis for the Degree of Master of Engineering

Research on Brain like Synchronous Localization
and 3DGS Mapping Method for
3D Environment

Candidate: Tian Xinyu

Supervisor: Chen Guang Associate Researcher

Associate Supervisor: Zhou Huijun Senior Engineer

Professional category: Electronic Information

College: College of Intelligent Systems Science and Engineering

Date of Submission: April. 2025

Date of Oral Examination: May. 2025

University: Harbin Engineering University

摘要

随着人工智能和机器人技术的快速发展,三维环境感知和自主导航已成为智能系统的重要研究方向。同步定位与建图(SLAM)技术作为实现自主导航的核心方法,在机器人、自动驾驶、增强现实和虚拟现实等领域发挥着关键作用。然而,传统 SLAM 方法在复杂动态环境中面临光照变化、传感器噪声和计算复杂度等挑战,限制了其在高精度、高实时性应用中的表现。受生物导航机制的启发,类脑计算为 SLAM 系统提供了一种新的解决方案。生物学研究表明,哺乳动物大脑中的位置细胞、头朝向细胞和网格细胞共同构成了大脑的空间认知系统,使其能够在复杂环境中进行精确导航和定位。三维场景重建是 SLAM 系统的重要任务,三维高斯溅射(3DGS)利用显式的高斯分布和球谐函数进行建模与渲染,具有更高质量的三维重建效果。

首先,深入研究了类脑导航机制,探讨了三维位置细胞、多层头朝向细胞和三维网格细胞的生物学特性,并基于连续吸引子神经网络(CANN)构建类脑导航计算模型。这一模型能够有效模拟生物导航系统的空间认知特性,为机器人提供高效的定位能力。同时,在 NeuroSLAM 框架的基础上,提出了一种基于 SuperPoint 改进视觉里程计的方法。SuperPoint 是一种基于深度学习的特征提取方法,相较于传统 ORB、SIFT 等特征点检测方法,具备更强的光照鲁棒性、尺度不变性和视角适应能力。通过特征点匹配和位姿估计算法,提升了 SLAM 系统的定位精度和环境适应性。方法与传统 SLAM 相比大幅减少了计算性能的需求,更好的适用于计算性能不足的小型机器人和无人机等。

其次,研究了基于 3DGS 的三维重建技术,3DGS 采用椭球状三维高斯分布对场景进行建模,并使用球谐函数进行颜色编码,以实现高质量的视角合成。此外,提出了 3DGS 的优化方法,通过对初始点云集进行离散点的去除和去除过于密集的点来优化初始点云,并且在训练过程中通过自适应密度控制算法,动态的调整高斯点的分布,实现欠拟合区域的克隆和过拟合区域的分裂,以优化重建质量并减少计算开销。实验结果表明,该方法能够在实时场景下实现高质量的三维重建,本文方法与传统三维重建方法相比,大幅提升了三维重建地图的质量。

最后,通过仿真实验对所提出的方法进行验证。实验结果表明,类脑 SLAM 系统能够在复杂环境中实现高效定位,并结合 3DGS 方法进行高质量的三维建图。相比于传统基于优化或滤波的 SLAM 方法,本方法在计算开销、渲染速度和场景细节保留方

面均具有明显优势，为未来智能机器人导航和三维环境重建提供了新的研究方向和技术支持。

关键词：类脑导航；同步定位与建图（SLAM）；三维高斯溅射（3DGS）；三维重建

Abstract

As artificial intelligence and robotics technology continue to advance rapidly, 3D environment perception and autonomous navigation have become important research directions for intelligent systems. Synchronous Localization and Mapping (SLAM) technology, as the core method for achieving autonomous navigation, plays a crucial role in fields such as robotics, autonomous driving, augmented reality, and virtual reality. However, traditional SLAM methods face challenges such as lighting changes, sensor noise, and computational complexity in complex dynamic environments, which limit their performance in high-precision and high real-time applications. Inspired by the biological navigation mechanism, neuromorphic computing provides a new solution for SLAM systems. Biological research has shown that the position cells, head facing cells, and grid cells in the mammalian brain together form the spatial cognitive system of the brain, enabling precise navigation and positioning in complex environments. 3D scene reconstruction is an important task of SLAM systems, and 3D Gaussian splatting (3DGS) utilizes explicit Gaussian distribution and spherical harmonics for modeling and rendering, resulting in higher quality 3D reconstruction effects.

Firstly, This study explores the principles of brain-like navigation, examining the biological features of 3D spatial cells, multi-layer head facing cells, and three-dimensional grid cells, and developing a brain-inspired navigation computational model using a continuous attractor neural network (CANN). This model can effectively simulate the spatial cognitive characteristics of the biological navigation system, and provide efficient positioning capability for robots. Meanwhile, based on the NeuroSLAM framework, this article proposes a method for improving visual odometry using SuperPoint. SuperPoint is a feature extraction method based on deep learning, which has stronger illumination robustness, scale invariance, and viewpoint adaptability compared to traditional feature point detection methods such as ORB and SIFT. By using feature point matching and pose estimation algorithms, the localization accuracy and environmental adaptability of the SLAM system have been improved. Compared with traditional SLAM, this method significantly reduces the computational performance requirements and is better suited for small robots and drones with

insufficient computational performance.

Secondly, this article investigates the 3D reconstruction technology based on 3DGS. 3DGS models the scene using an ellipsoidal 3D Gaussian distribution and uses spherical harmonics for color coding to achieve high-quality perspective synthesis. In addition, this article proposes an optimization method for 3DGS, which optimizes the initial point cloud by removing discrete points and excessively dense points from the initial point cloud. During the training process, an adaptive density control algorithm is used to dynamically adjust the distribution of Gaussian points, achieving cloning of underfitting regions and splitting of overfitting regions to optimize reconstruction quality and reduce computational costs. The experimental results show that this method can achieve high-quality 3D reconstruction in real-time scenes. Compared with traditional 3D reconstruction methods, this method significantly improves the quality of 3D reconstruction maps.

Finally, this article validated the proposed method through simulation experiments. The experimental results show that the brain like SLAM system can achieve efficient localization in complex environments and combine with the 3DGS method for high-quality 3D mapping. Compared with traditional SLAM methods based on optimization or filtering, this method has significant advantages in computational cost, rendering speed, and scene detail preservation, providing new research directions and technical support for future intelligent robot navigation and 3D environment reconstruction.

Key words:Brain like navigation; Simultaneous Localization and Mapping (SLAM); Three dimensional Gaussian sputtering (3DGS); three-dimensional reconstruction

目 录

第 1 章 绪论	1
1.1 课题研究背景及意义	1
1.2 国内外研究现状与分析	3
1.2.1 国内外类脑导航研究现状	3
1.2.2 国内外三维重建研究现状	7
1.3 论文研究内容与结构安排	10
第 2 章 类脑导航细胞的机理及建模方法	13
2.1 引言	13
2.2 位置细胞机理及建模	14
2.2.1 位置细胞机理	14
2.2.1 位置细胞建模	14
2.3 头朝向细胞机理及建模	17
2.3.1 头朝向细胞机理	17
2.3.2 头朝向细胞建模	18
2.4 网格细胞机理及建模	20
2.4.1 网格细胞机理	20
2.4.2 网格细胞建模	21
2.5 本章小结	23
第 3 章 基于 SuperPoint 改进的 NeuroSLAM 算法	25
3.1 引言	25
3.2 NeuroSLAM 类脑导航算法框架	25
3.3 基于 SuperPoint 的视觉里程计改进算法	26
3.3.1 SuperPoint 特征提取算法	27
3.3.2 特征点匹配算法	33
3.3.3 三维位姿解算	34
3.4 类脑导航轨迹地图	36
3.5 回环检测	37
3.6 仿真分析	38
3.7 本章小结	41
第 4 章 基于三维高斯溅射的三维重建	43
4.1 引言	43

4.2 三维高斯重建框架	43
4.3 三维高斯分布和球谐函数	44
4.3.1 三维高斯分布	44
4.3.2 球谐函数	46
4.4 自适应密度控制	46
4.5 可微分的快速光栅化	48
4.6 仿真实验分析	49
4.7 本章小结	51
第 5 章 类脑同步定位与三维重建实验分析	53
5.1 引言	53
5.2 改进的类脑导航算法实验	53
5.2.1 仿真实验介绍	53
5.2.2 仿真实验结果	57
5.3 三维高斯重建结果	60
5.4 本章小结	62
结 论	63
参考文献	65
攻读硕士学位期间发表的论文和取得的科研成果	71
致 谢	73

第1章 绪论

1.1 课题研究背景及意义

随着机器人技术、人工智能和神经科学的快速发展，海、陆、空各领域的机器人越来越广泛地用于辅助我们的日常生活中。然而，随着机器人应用范围和领域的不断扩大，机器人在自主性、适应性、智能性等方面将面临新的巨大挑战。如何让机器人真正实现自主，成为一个重大问题。此外，我们生活在一个复杂、不可预测、3D 化的环境中，作为机器人的基本能力之一，智能和自主定位、导航和定时（PNT）在这些环境中也面临着许多困难^[1]。例如，在动态火灾场景、黑暗洞穴、未知空间等具有挑战性的环境中，机器人自主执行一些任务（例如救援、交付和探索）时，可能会出现故障，如图 1.1 所示。



(a) 火灾无人机



(b) 山洞无人机



(c) 管道机器人



(d) 扫地机器人

图 1.1 应用于各种领域的机器人

在过去的几十年里，机器人专家已经开发了很多方法，使机器人能够在未知的三维环境中导航。传统的三维 SLAM 方法通常是基于滤波器或优化实现的，例如 ORB-SLAM^[2]和 LDSO^[3]，它们假设状态转移和测量函数是线性的，噪声是高斯的。当地标数量增加时，基于优化或基于滤波器（如卡尔曼滤波器、扩展卡尔曼滤波器和粒子滤波器）的 3D SLAM 系统的性能也会受到影响。每增加一个新的地标，之前所有的地标

估计都会受到影响。对于大型复杂环境中的长期任务来说，这可能是困难的，甚至是不可行的，因为机器人面临着大量的地标。此外，随着脑科学和脑启发人工智能的发展，脑启发芯片或神经形态硬件得到迅速发展，如 Tianjic 芯片^[4]，它具有低功耗和高计算效率的一些优势。然而，传统的基于滤波器或优化的三维 SLAM 方法不能应用于新的神经形态硬件。此外，传统方法生成的三维空间地图的创建和更新在长期导航中也遇到了一些具有挑战性的问题。例如，无论机器人是首先访问还是重新访问一个 3D 空间，这些方法总是会生成大量的空间数据，无法像哺乳动物那样高效地表示和编码 3D 空间。

从实际三维 SLAM 应用的系统角度来看，我们必须考虑很多影响因素，特别是环境的约束、机器人资源的限制、系统性能和智能的要求。首先，机器人必须在未知的、动态的、不可预测的、大规模的 3D 环境中进行导航，环境的变化，如光线的变化、外观的变化、物体的运动等，会导致感知、定位和映射的失败^[5]。其次，SLAM 系统的可用性也取决于机器人资源的限制。例如，为了使自动驾驶汽车能够自主导航^[6]，汽车上部署了包括雷达、摄像头、激光、超声波、GNSS 在内的许多传感器，如图 1.2 所示：




图 1.2 Kitti 数据集采集平台

这些传感器和计算设备的功耗非常高。然而，这种基于许多昂贵传感器和高功耗的解决方案无法应用于微型机器人。最后，对性能和智能的要求也给三维 SLAM 和导航的实际应用带来了诸多挑战。一方面，要求 SLAM 和导航系统具有更高的精度、精度、可靠性，能够在大尺度环境下在线、长期、稳健地运行。另一方面，还必须满足低成本、高能效、低计算复杂度、小体积、轻重量等要求。

综上所述，从系统角度考虑环境、机器人资源、性能和智能的限制，三维 SLAM 和导航仍然存在许多具有挑战性的问题。现有的三维 SLAM 和导航方法也存在能耗高、计算成本高、环境适应性差、智能水平低等问题。尤其是军用自主机器人，如作

战无人机、超声速飞行器、水下机器人、空间机器人等，往往在尺寸、重量、能耗、可靠性、环境适应性、智能等方面要求更为严格。此外，它们往往容易受到干扰，不能依赖 GNSS 等外部导航信号^[7]。因此，如何解决机器人在低能耗、低计算成本、高智能等严峻约束条件下的智能三维 SLAM 和导航等重大问题，成为未来机器人前沿技术的研究重点。本研究聚焦于类脑导航中的定位与地图构建问题，深入探讨了导航细胞的运行机制，并在此基础上设计了一个导航细胞模型，该模型可有效地表达机器人的位置信息和航向状态。此外，还深入探讨了 3DGS 的工作原理，实现了对三维环境的高质量重建。

1.2 国内外研究现状与分析

1.2.1 国内外类脑导航研究现状

在过去的几十年里，科学家在哺乳动物大脑中发现了一些与导航功能密切相关的神经元。海马体是大脑中负责学习和记忆的关键区域，一直是研究的热点^[8]。1971 年，美国学者 John O' Keffe 在研究小鼠活动时发现，海马体中某些神经元的激活情况会随着小鼠所处位置的不同而发生变化^[9]。这类与空间位置有关的神经元被命名为“位置细胞”（Place Cells）。它们在多数时间内保持沉默，只有当小鼠移动到某一特定区域时，这些细胞才会被激活并发放神经信号。1984 年，Ranck 在海马体中首次发现了一种与动物朝向有关的神经元，被命名为“头朝向细胞”（Head Direction Cell）^[10]。随后在 1990 年，他的学生 Taube 对该细胞进行了进一步研究并发表了相关成果。研究显示，当动物的头部指向某个特定方向时，相关的头朝向细胞会被激活，并持续发放信号，直到头部转向其他方向为止。2005 年，瑞典科学家 Edvard Moser 与 May-Britt Moser 夫妇又在海马区域发现了另一种关键的定位神经元——“网格细胞”（Grid Cell）^[11]。这类细胞在空间中激活的位置构成规则的六边形网格图案，具有高度规律性和对称性。其独特的多尺度、重叠和离散编码特性，使得大脑能够在无外部提示的情况下构建环境的内部地图，实现精确定位与路径导航功能。由于在位置细胞和网格细胞研究方面的杰出贡献，John O'Keffe 和 Moser 夫妇共同获得了 2014 年诺贝尔生理学或医学奖^[12]。

随着对大脑中由位置细胞和头朝向细胞编码的二维空间神经机制的初步发现和理解，一些导航神经模型已经被开发出来并应用于机器人导航。例如，开发了基于头朝向细胞和位置细胞的导航模型，并将其部署在 2D 区域内操作的 Khepera 机器人上^[13]。

此外，为了支持大规模持久导航和制图，2004 年，澳大利亚昆士兰科技大学的 Milford 等人提出了一种利用抽象位姿细胞表示二维平面中位置与朝向的计算模型——RatSLAM，该方法受到啮齿类动物大脑导航机制的启发，被认为是一种类脑 SLAM 算法^[14]。该系统借鉴导航神经元的功能特点，构建了一个融合局部激励与全局抑制机制的连续吸引子神经网络（CANN）模型，用于模拟位置细胞和头朝向细胞的激活行为。同时，RatSLAM 还整合了视觉图像信息，以辅助推理出运动过程中的旋转和速度数据，进而重现小鼠在探索环境中识别位置与方向的能力^[15-17]。2005 年，研究人员对 RatSLAM 系统进行了改进，提出了一种基于拓扑关系的经验地图构建方法，使系统能够在仿真和真实环境中形成连续的空间拓扑表示。该方法通过扫描线强度分布对位移信息进行估计，并构建相应的局部视觉模板，同时借助图优化算法纠正因误差积累导致的定位偏差。实验结果显示，该系统在一次总里程为 66 公里的车载测试中表现出良好的稳定性和长距离导航能力^[18]。




图 1.3 RatSLAM 模型框架

随后，研究人员在 RatSLAM 模型基础上提出了多种扩展方案。例如，Steckel 等人受到蝙蝠回声定位原理的启发，开发了一种基于声呐传感器的导航系统——BatSLAM。该系统采用连续吸引子神经网络来模拟位姿细胞的动态行为，从而实现对室内环境的感知与认知地图的构建^[19-20]。Gao 等人提出了一种新型的网格细胞编码模型，并将其应用范围拓展至三维空间，实验证明该模型在路径积分与路径规划任务中具有良好的适应性与表现。此类研究不仅拓宽了类脑导航在感知层面的应用方式，也为其在大规模、复杂环境中的部署奠定了基础。同时，Milford 等人通过优化视觉感知模块，在不对 RatSLAM 核心结构进行修改的前提下，成功应对了 2.5D 环境下的 SLAM 挑战^[21]。此外，Silveira 等人将三维位置细胞机制引入 RatSLAM 框架，开发出

面向三维水下场景的 SLAM 系统，进一步拓展了该模型的应用领域。

自 2012 年 Milford 提出 SeqSLAM 模型以来，类脑导航系统在视觉识别与地图构建方面取得了显著进展。SeqSLAM 通过引入图像序列匹配机制，有效提升了环境识别的准确性^[22]。随后，2016 年 Kazmi 等人对自生长神经网络（GNG）进行了优化，以模拟导航细胞在建图过程中的作用。该方法在提升建图效率的同时，显著加快了模型收敛速度，并降低了内存资源的消耗，从而增强了类脑导航系统在实际应用中的部署能力^[23]。2017 年，Zhou 等人进一步引入 ORB（Oriented Fast and Rotated Brief）特征来优化视觉信息处理模块。ORB 作为一种高效的局部特征描述子，在保持对图像旋转与尺度变化鲁棒性的同时实现了快速特征提取。然而，该方法在提升视觉识别性能的同时也带来了较大的处理时延，导致视觉处理与地图构建之间出现不同步，影响了系统的整体实时响应能力^[24]。2020 年，Marvin 等人提出融合 FlyNet 与 CANN 的混合神经结构模型，将 FlyNet 在目标识别方面的优势与 CANN 的时序滤波能力有机结合，显著提升了系统在感知与定位任务中的整体性能与运行稳定性^[25]。

尽管我国在类脑导航技术领域的研究起步相对较晚，但近年来取得了显著进展。早在 2007 年，唐华锦团队便构建了一个集成内嗅皮层、海马体与运动输出皮层的建图系统，充分利用这些脑区的空间映射特性对任务目标位置进行编码，为国内类脑导航研究奠定了坚实基础。此后，曾太平团队基于海马体-内嗅皮层回路的实验研究，提出了一种网格细胞神经网络架构，并成功将视觉感知信息融合其中，实现了在室外环境下的导航验证。2018 年，吴德伟等人^[26]开发了一种融合鼠脑认知机制的无人化导航系统，构建出三维经验地图，为复杂环境中的空间认知提供了新路径。2019 年，于乃功等人^[27]依据鼠脑的空间认知原理，提出了网格细胞与位置细胞的建模方法，并据此生成适用于室内导航的拓扑地图。同年，陈孟元等人将姿态测量单元与实时外观（RTAB）算法结合，成功缓解了视觉里程计中的误差累积问题。此外，陈孟元在其博士论文中提出的 BVGSP-SLAM 模型（边界细胞-视图细胞-网格细胞-速度细胞-姿态细胞-同时定位与建图）虽然尚未得到全面验证，但已展现出多细胞协同机制在类脑导航系统中的广泛应用潜力。




图 1.4 BVGSP-SLAM 模型

近年来，国内在类脑导航系统的研究持续深化，并在三维感知、场景识别与认知地图构建等方面取得了重要成果。2020 年，余芳文等人^[28]提出了一种基于多维连续吸引子网络的三维类脑导航系统（NeuroSLAM），通过引入三维位置细胞与头朝向细胞模型，有效实现了在动态三维环境中的自主导航。该系统通过模拟生物大脑的多维感知机制，显著提升了机器人在复杂场景中的导航能力。

表 1.1 类脑导航国内外研究现状

分类	内容	年份	主要贡献
神经细胞发现	位置细胞	1971	John O’Keffe 发现与位置相关的细胞，在进入特定位置时放电。
	头朝向细胞	1984	由 Ranck 发现，Taube 进一步研究，与头部朝向相关的细胞。
	网格细胞	2005	Moser 夫妇发现，具有六边形网格状结构细胞，用于精确定位和路径搜索。
早期导航模型开发	RatSLAM 模型	2004	Milford 等人受啮齿动物大脑启发，结合视觉信息，构建拓扑经验地图。
	RatSLAM 扩展	2005	引入拓扑度量经验地图，结合扫描线强度分布算法和图校正算法。
模型扩展与优化	SeqSLAM 模型	2012	Milford 提出，通过序列图像检测提高识别准确度。
	ORB 特征视觉处理	2017	Zhou 等人提出，提升视觉信息处理性能，但增加处理所需时间。
国内研究进展	无人化导航系统	2018	吴德伟等人提出，结合鼠脑认知机理，构建三维经验地图。
	BVGSP-SLAM 模型	2019	陈孟元等人提出，基于多细胞的导航机制。
	NeuroSLAM 系统	2020	余芳文等人提出，三维类脑导航系统，适用于复杂动态环境。

2020 年，赵菁等人提出了一种基于卷积神经网络的位置识别算法，借鉴动物学习

策略，实现了较高的场景识别精度和良好的环境适应性。在经验地图的构建与优化方面，2021 年 Zeng 等人^[29]设计了一种受大脑启发的紧凑型认知地图系统，采用稀疏化处理技术解决了地图规模随时间增长所带来的负担，提升了系统在大规模环境下的应用能力。2022 年，边雪提出了一种基于多感知位置细胞的贝叶斯估计网络^[30]，将定位任务转化为对位置细胞概率分布的估计问题，并通过引入动态更新机制，有效校正了建图过程中产生的误差，为提升导航精度提供了新路径。

总体来看，类脑仿生的地图构建方法在研究上已取得了较大进展。现有大多数方法通过数学建模手段模拟大脑神经元的放电行为，用于实现环境的地图表达，这类技术多应用于模拟环境或结构较为简单的小型二维实验区域。但在面对复杂环境时，三维认知地图的生成能力以及定位同步的准确性仍存在明显的局限，同时对生物大脑认知机制的深层次运用尚不充分。

1.2.2 国内外三维重建研究现状

三维重建技术是计算机视觉和图形学中的重要研究领域，其主要目标是通过图像、点云等数据恢复物体或场景的三维结构^[31-32]。近年来，随着计算机硬件性能的不断增强、深度学习技术的飞速发展以及传感器技术的持续创新，三维重建技术在精度提升、效率改进和应用扩展方面取得了显著进展。将从基于视觉的三维重建技术入手，系统回顾国内外在该领域的研究动态。

国外在三维重建领域的发展较为成熟，尤其在基于图像的三维重建技术方面取得了显著成就。早期的三维重建主要依赖人工绘制，效率低下且精度有限。随着计算机技术的发展，激光扫描仪和深度摄像头等设备的应用极大地提升了三维重建的精度和效率。早在 1963 年，Roberts^[33]就提出了利用计算机视觉从二维图像中获取三维信息的可能性，奠定了基于视觉的三维重建基础。20 世纪 90 年代，Debevec 等人^[34]提出了利用参数几何体表示初始模型的方法。随后，国际学者围绕激光扫描、结构光、阴影成像、TOF 技术、雷达探测以及 Kinect 等多种感知技术展开了广泛的研究^[35-36]。例如，1995 年，日本东京大学的 Kiyasu 等人^[37]通过 M-array 编码光源图像，实现了物体表面的三维重建。到了 2006 年，Snavely 等人^[38]发布了 Photosynth 与 Photo Tourism 两个系统，能够自动推算图像的视角，从而构建稀疏的三维模型。2008 年，Pollefeys 等人^[39]通过多视图几何关系对物体周围拍摄的图像进行标定和重建，进一步提高了重建精度。2013 年，微软研究院的 Kinect Fusion 项目通过连续扫描和实时重建，显著提升了三维重建的精度。

国外学者对单目视觉、双目视觉和多目视觉技术进行了广泛研究。例如，20 世纪 60 年代，麻省理工学院的 Roberts 将二维图像扩展到三维图像，奠定了双目视觉的研究基础^[40]。随后，基于双目和多目视觉的三维重建技术逐渐发展并成熟，广泛应用于机器人视觉、无人驾驶等实际场景。近年来，随着深度学习的迅猛发展，国际学者将深度学习与传统几何计算相结合，显著提高了三维重建的精度和效率。例如，2015 年，Savinov 等人^[41]提出了一种语义三维重建方法；2016 年，Blóha 等学者^[42]提出了一种具有自适应多分辨率特性的语义三维重建方法；2017 年，Sünderhauf 等人^[43]提出了面向对象的语义建图方法；2018 年，Yao 等人^[44]提出了 MVSNet，一种端到端的深度神经网络架构，可以利用多视角图像生成相应的深度图；2019 年，Chen 等人^[45]提出了 PointMVSNet，该方法将场景作为点云处理，显著提高了重建效率。这些研究不仅提升了三维重建的精度，还降低了对硬件设备的依赖，使得三维重建技术在更多领域得到应用。

2020 年，Ben Mildenhall 等人^[46-48]首次提出神经辐射场（NeRF），其通过神经网络学习场景的光线辐射场，能够在低内存下渲染高保真度的新视角图像，为三维重建领域带来了重大变革。随后，国外研究团队对 NeRF 进行了多方面的优化和拓展。例如，提出了学习权重对 NeRF 捕捉几何结构正确性的影响，以及前景分离的采样方式，提高了其在无界场景上的表现。还有团队通过引入多级感知的方式，优化了 NeRF 在不同距离下的渲染效果。2023 年三维 Gaussian Splatting（3DGS）的出现，大大加快了新视图合成的渲染速度^[49-51]。与 NeRF 等神经隐式表示表示具有位置和视点条件神经网络的三维场景不同，3DGS 利用一组高斯椭球来建模场景，从而通过将高斯椭球栅格化成图像来实现有效的渲染。除了快速的渲染速度外，3DGS 的显式表示促进了下游任务，如动态重建、几何编辑和物理模拟。




图 1.5 Nerf 三维重建模型

尽管我国在三维重建技术领域起步相对较晚，但近年来发展迅猛，取得了一系列具有代表性的研究成果。早在 1996 年，中国科学院的李利等人^[52]便提出了一种面向室

内场景的三维建模方法。随后在 2002 年, Zhong 等人提出了半稠密匹配策略, 成功实现了稀疏与稠密匹配之间的平衡。2003 年, Lei 等人^[53]基于 Kruppa 方程开展了相机自标定研究, 并开发了 CVSuite 软件, 实现了多视角图像的三维建模功能。到 2014 年, 西安电子科技大学的张涛^[54]提出了一种基于单目视觉的重建方法, 利用空间中的稀疏点云进行建模; 同年, 张文明等则深入研究了双目视觉中的特征提取与匹配技术, 为该领域的发展注入了新动力。此外, 国内研究者还在运动恢复结构、多视图几何等方向开展了广泛探索, 并在结构光、阴影分析以及 TOF (飞行时间) 技术等方面取得了显著成效。

国内学者在特征点检测与匹配、稀疏点云重建 (SFM) 和稠密点云重建 (MVS) 等方面也进行了深入研究^[55-56]。例如, 崔振兴等人提出了改进的 SURF 匹配算法, 李红波等人提出了基于距离约束的改进 SURF 算法, 进一步提升了特征点匹配的精度和效率。此外, 国内学者在深度学习与几何计算相结合的三维重建方法上也进行了探索。例如, 2018 年, 张彦雯等人^[57]对稀疏点云重建和稠密点云重建的研究现状进行了系统综述, 指出国内学者在特征点检测与匹配、SFM 重构和 MVS 等方面进行了大量研究。

我国在深度学习与三维重建技术结合的研究中也取得了显著的突破。研究人员深入探索了 NeRF, 并针对其在实际应用中的局限性提出了改进措施。例如, 为了解决 NeRF 在处理动态光源和大规模场景重建时的问题, 研究者们提出了时间适应型神经辐射场和基于采样优化的边缘辐射优化算法^[58], 从而显著提升了 NeRF 在复杂现实环境中的表现。此外, 国内研究还注重将深度学习与其他技术结合, 发挥各自优势以提高三维重建的精度与效率。例如, 在单目视觉深度估计中引入深度学习方法, 有效增强了从单张图像中提取深度信息的能力。同时, 在数据采集、预处理和模型训练等环节也进行了优化, 更好地适应国内的应用需求和场景。

中科院自动化所的研究团队在 2025 年提出了 CityGaussianV2 算法^[59], 用于高效重建大规模复杂三维场景。该算法通过优化高斯分布椭球建模和深度回归监督, 显著提升了几何精度和训练效率。实验表明, 该算法在大规模场景 (如 1.97 平方千米) 的重建中, 显存需求减少了 47.5%, 训练时间缩短了 63%, 并且在几何精度和渲染质量上表现出色。




图 1.6 CityGaussianV2 重建结果

表 1.2 三维重建国内外研究现状

分类	内容	年份	主要贡献
国外研究进展	结构光三维重建	1995	Kiyasu 等学者通过采用 M-array 编码的光源图像，实现了对物体表面进行三维形貌重建的技术。
	多视图几何标定和重建	2008	Pollefeys 等人通过多视图几何关系提高重建精度。
	神经辐射场（NeRF）	2020	Mildenhall 等人通过神经网络隐式表示三维场景的几何结构和外观信息。
	三维 Gaussian Splatting（3DGS）	2023	是一种基于高斯分布的三维场景表示与渲染技术，主要用于高效建模和渲染复杂的三维场景。
国内研究进展	半稠密匹配法	2002	中科院 Zhong 等人解决稀疏匹配和稠密匹配的平衡问题。
	单目视觉三维重建	2014	西安电子科技大学的张涛提出了利用空间中稀疏点云进行三维建模的方法。
	特征点检测与匹配改进	2014	崔振兴、李红波等人改进 SURF 算法，提升匹配精度和效率。
	CityGaussianV2 算法	2025	中科院自动化所提出，高效重建大规模复杂场景，优化几何精度和训练效率。

综上所述，国内外在三维重建技术的研究中均展现出从传统方法向深度学习与几何计算相结合的趋势，同时注重提升重建的精度、效率和适应性。未来，随着计算机硬件性能的进一步提升、深度学习技术的不断发展以及传感器技术的进步，三维重建技术有望在更多领域实现突破和应用，为相关产业的发展提供有力支持。

1.3 论文研究内容与结构安排

本论文主要围绕类脑同步定位与三维高斯溅射技术在三维环境中的应用展开研究，旨在解决传统 SLAM 在复杂环境中的鲁棒性问题，并提升三维场景重建的质量。

本论文共分为六章内容，在第一章绪论中介绍类脑导航和三维重建的研究现状以及本文的研究内容，第二章主要介绍类脑导航细胞的机理及数学建模，第三、四、五章主要针对类脑同步定位与三维重建进行算法研究和结果分析，第六章对全文进行总结，章节内容之间的关系如图 1.7 所示。




图 1.7 本文研究内容框架

第 1 章 绪论

介绍研究背景、问题定义及研究意义，分析国内外研究现状，并阐述本文的主要研究内容和结构安排。

第 2 章 类脑导航细胞的机理及建模方法

探讨三维位置细胞、多层头朝向细胞和三维网格细胞的生物学机制，并基于连续吸引子神经网络构建数学模型，从而实现类脑导航系统的空间认知功能。

第 3 章 基于 SuperPoint 改进的 NeuroSLAM 算法

提出一种改进的 NeuroSLAM 算法，结合 SuperPoint 特征提取方法，提高视觉里程计精度，并通过基于视觉模板的回环检测来优化轨迹地图。

第 4 章 基于三维高斯溅射的三维重建

研究三维高斯分布与球谐函数在三维场景建模中的应用、自适应密度控制算法和快速光栅化技术，并通过实验结果展示高质量的三维重建效果。

第 5 章 类脑同步定位与三维重建实验分析

设计实验方案，分析所提出方法的定位精度、重建质量，并与改进前的算法进行

对比，验证其在复杂环境中的适用性。

结论与展望

总结论文的研究成果，讨论方法的优势与不足，并对未来研究方向进行展望。

第2章 类脑导航细胞的机理及建模方法

2.1 引言

同步定位是智能机器人和无人驾驶技术的核心挑战之一。在复杂的城市环境或未知环境中,传统的导航方法依赖于惯性导航系统、卫星导航系统和多种传感器(如激光雷达、摄像头等)进行定位。然而,这些方法在高楼密集区域、隧道、地下空间等特殊场景中往往精度受限,甚至可能出现定位丢失的问题。此外,部分高精度传感器成本昂贵,增加了应用的经济负担。因此,发展更加自主、稳健、高效的定位系统成为亟待解决的问题。

为了使机器人在复杂的三维环境中实现自主导航,其必须能够实时掌握当前以及即将到达的姿态信息,该姿态包括三维的位置和朝向。如何高效地表示和持续维护这些三维姿态状态,是导航系统面临的重要挑战。类似地,人类与动物在日常活动中也需要准确感知自身在三维空间中的位置和方向,例如在觅食过程中保持方向感。研究发现,大脑依赖复杂的神经网络来完成这一任务,能够快速处理并更新位置信息与朝向感。自然界中的一些动物,如老鼠和蝙蝠,展示了其在陌生环境中自主定位和建立认知地图的能力,它们通过外部感知与内部修正机制,准确判断自身位置,进而实现有效的导航。类脑导航技术正是借鉴这些生物的导航原理,模拟哺乳动物大脑中的导航系统,用于环境识别、路径规划和目标导引等功能。在这一过程中,网格细胞、头向细胞和位置细胞之间的协同作用,是实现动物自主定位和认知地图构建的关键。特别是在三维环境中进行类脑同步定位时,这些导航细胞的数学建模起着核心作用。

当机器人探索3D空间时,其姿态可以根据运动方式分为四自由度(4DoF)、5DoF和6DoF三种类型。例如,在多层建筑环境中移动时,机器人可以表示其4DoF姿态,其中 (x,y,z) 表示其在3D空间中的位置,偏航角(yaw)表示其在特定楼层中的运动方向。这种自适应的3D姿态表示方法能够根据机器人的运动模式灵活调整,从而更好地适应复杂环境。本文的主要研究内容聚焦于4DoF姿态的建模与应用,机器人通常主要沿水平面移动,同时具备有限的垂直方向移动能力(如电梯、楼梯等)。因此,4DoF的表示方式能够有效平衡姿态描述的精确性和计算效率,为自主导航系统提供更加稳健的解决方案。

本章主要研究类脑导航细胞的工作原理及其建模方法。首先,分析位置细胞、网格细胞和头朝向细胞的生物学特性,并探讨它们在导航过程中所发挥的重要作用;随

后，基于连续吸引子神经网络，构建类脑导航细胞的数学模型。

2.2 位置细胞机理及建模

2.2.1 位置细胞机理

位置细胞是位于海马体中的一类特殊神经元，由 O'Keefe 于 1971 年首次在大鼠实验中发现^[9]。这些细胞在动物位于特定环境区域时会表现出高度选择性的放电活动，即某个位置细胞仅在动物到达其“首选位置”时产生高频神经信号，而在其他区域的放电频率较低或无放电。位置细胞具有空间特异性，即不同细胞的放电区域覆盖整个环境，每个细胞对应特定的位置；具有环境依赖性，同一细胞在不同环境中可能呈现不同的放电模式；同时，它们具备自发重构能力，能够在新的环境中迅速形成新的放电模式，构建“认知地图”；此外，位置细胞的放电具有路径无关性，无论动物从哪个方向进入其“首选位置”，该细胞都会产生相应的放电。其放电机制受外部环境信息例如视觉、嗅觉、触觉等和内部自运动信号的共同调控，例如，视觉和地标信息有助于位置细胞的空间编码，而自运动信息可在缺乏视觉线索的情况下维持稳定放电。此外，位置细胞与其他导航细胞协同作用，其中网格细胞提供连续的空间坐标信息，头朝向细胞编码动物的方向信息，共同支持精确定位。位置细胞在空间认知、导航决策和记忆形成中发挥重要作用，使动物能够建立环境认知地图，并高效完成目标导向的路径规划。




图 2.1 位置细胞模型

2.2.2 位置细胞建模

本文采用三维立方体连续吸引子神经网络（Cube-CAN）来对三维位置细胞进行建模^[60]。Cube-CAN 是一种神经网络模型，它通过引入带有权重的兴奋与抑制连接，并构建多个闭环结构，实现了无需外部输入即可逐步趋于稳定的动态特性。与依赖权重

调整的传统神经网络不同, Cube-CAN 侧重于对神经元激活水平的持续更新。网络中的每个神经元都拥有一个介于 0 到 1 之间的连续激活数值, 当机器人接近某个位置时, 对应区域的神经元激活度会随之上升。该方法跳脱了传统 SLAM 系统基于概率分布的表达框架, 展现出不同的建模思路。凭借其出色的稳定性、处理效率和连续性, Cube-CAN 能够有效模仿哺乳类动物大脑中与空间定位和导航相关的神经活动模式。

Cube-CAN 可以在三维空间中保持机器人的三维位置, 每个神经元负责映射一个特定的三维位置。细胞活动矩阵 P^{PC} 描述了三维位置细胞的活动, Cube-CAN 中的活动由吸引子网络的初始三维位置进行初始化, 当输入一个新的三维位置估计时, Cube-CAN 中的三维位置细胞的活动通过吸引子网络来更新。在没有外界刺激输入的情况下, Cube-CAN 的活性趋于稳定, 当前的三维位置可以从稳定的 Cube-CAN 解码。

三维位置细胞网络的神经动力学是基于局部激励、全局抑制和归一化的机制实现的。首先, 局部激励过程会激发部分三维位置细胞。然后, 所有三维位置细胞都被全局抑制过程所抑制。最后, 对 Cube-CAN 中的活动进行归一化。

1) 三维位置细胞的局部激励

使用三维高斯分布来构建出兴奋性权值矩阵 $\varepsilon_{u,v,w}^{PC}$, 单元之间的距离指标用 u , v 和 w 表示。权值矩阵的计算公式如下:

$$\varepsilon_{u,v,w}^{PC} = \frac{1}{(\sigma_x \sqrt{2\pi})} e^{-u^2/(2\sigma_x^2)} \cdot \frac{1}{(\sigma_y \sqrt{2\pi})} e^{-v^2/(2\sigma_y^2)} \cdot \frac{1}{(\sigma_z \sqrt{2\pi})} e^{-w^2/(2\sigma_z^2)} \quad (2-1)$$

其中 $\varepsilon_{u,v,w}^{PC}$ ——表示位置细胞网络中的兴奋性权重矩阵;

u , v , w ——分别表示 (x,y,z) 矩阵中单元之间的空间偏移量;

σ_x , σ_y , σ_z ——分别表示三个维度的高斯分布标准差;

定义了三维位置细胞之间的高斯加权连接, 即距离越近, 权重越大, 距离越远, 权重越小。三维位置细胞的活动变化计算公式如下:

$$\Delta P_{x,y,z}^{PC} = \sum_i^{n_x} \sum_j^{n_y} \sum_k^{n_z} P_{i,j,k}^{PC} \varepsilon_{u,v,w}^{PC}, \forall i, j, k \in u, v, w \quad (2-2)$$

表达了三维位置细胞的活动变化是由其邻域内所有位置细胞的加权求和决定的, 权重由高斯分布确定。 n_x , n_y , n_z 为细胞维度, 距离指数的计算方法如下:

$$\begin{aligned} u &= (x - i) \pmod{n_x} \\ v &= (y - j) \pmod{n_y} \\ w &= (z - k) \pmod{n_z} \end{aligned} \quad (2-3)$$

2) 三维位置细胞的全局抑制

在生理学上，每个三维位置细胞通过局部抑制作用抑制邻近的细胞，同时，所有三维位置细胞还受到一个恒定的全局抑制常数 ϕ 平均抑制，公式如下：

$$\psi_{u,v,w}^{\text{pc}} = \frac{1}{(\delta_x \sqrt{2\pi})} e^{-u^2/(2\delta_x^2)} \cdot \frac{1}{(\delta_y \sqrt{2\pi})} e^{-v^2/(2\delta_y^2)} \cdot \frac{1}{(\delta_z \sqrt{2\pi})} e^{-w^2/(2\delta_z^2)} \quad (2-4)$$

$$\Delta \mathbf{P}_{x,y,z}^{\text{pc}} = \sum_{i=1}^{n_x} \sum_{j=1}^{n_y} \sum_{k=1}^{n_z} \psi_{u,v,w}^{\text{pc}} \mathbf{P}_{i,j,k}^{\text{pc}} - \phi \quad (2-5)$$

其中 $\psi_{u,v,w}^{\text{pc}}$ 为局部抑制的权重矩阵， δ_x 、 δ_y 、 δ_z 为高斯分布标准差， $\mathbf{P}^{\text{pc}}$ 中的所有值都被限制为非负值。

3) 三维位置细胞的归一化

为确保定位精度，需要使位置细胞的激活状态维持在一个相对稳定的水平。在吸引子神经网络的演化过程中，通过对网络活动进行归一化操作，保证三维位置单元（Cube-CAN）的整体激活总量恒定为 1，从而维持系统的稳定性与准确性。归一化之后，细胞活性矩阵 $\mathbf{P}_{x,y,z}^{\text{pc}}$ 的计算公式如下：

$$\mathbf{P}_{x,y,z}^{\text{pc}} = \frac{\mathbf{P}_{x,y,z}^{\text{pc}}}{\sum_{i=1}^{n_x} \sum_{j=1}^{n_y} \sum_{k=1}^{n_z} \mathbf{P}_{i,j,k}^{\text{pc}}} \quad (2-6)$$

4) 三维位置细胞的更新

基于三维位置的变化信息来更新 Cube-CAN 中的 3D 位置单元活动的位置，当前激活的细胞的活动被投影到附近的细胞中。活动根据位置变化 σ_x 、 σ_y 、 σ_z 分别在 x 、 y 和 z 矩阵中移动，活动由两个输入决定：一个是发送单元 U^{pc} 的活动，另一个是残差 η ，它通过偏移量的分数分量 σ_{x_f} 、 σ_{y_f} 、 σ_{z_f} 计算得出， $\Delta U_{l,m,n}^{\text{pc}}$ 的计算公式如下：

$$\Delta U_{l,m,n}^{\text{pc}} = \sum_{x=\sigma_{x_0}}^{\sigma_{x_0}+1} \sum_{y=\sigma_{y_0}}^{\sigma_{y_0}+1} \sum_{z=\sigma_{z_0}}^{\sigma_{z_0}+1} \eta U_{(l+x)(m+y)(n+z)}^{\text{pc}} \quad (2-7)$$

$$\begin{bmatrix} \sigma_{x_0} \\ \sigma_{y_0} \\ \sigma_{z_0} \end{bmatrix} = \begin{bmatrix} k_x \sigma_x \\ k_y \sigma_y \\ k_z \sigma_z \end{bmatrix} \quad (2-8)$$

$$\begin{bmatrix} \sigma_{x_f} \\ \sigma_{y_f} \\ \sigma_{z_f} \end{bmatrix} = \begin{bmatrix} k_x \sigma_x - \sigma_{x_0} \\ k_y \sigma_y - \sigma_{y_0} \\ k_z \sigma_z - \sigma_{z_0} \end{bmatrix} \quad (2-9)$$

其中 k_x ， k_y 和 k_z 为三维位置的更新常量，残差矩阵的计算如公式（2-10）所示。

$$\eta = f(\sigma_{x_f}, x - \sigma_{x_0}) f(\sigma_{y_f}, y - \sigma_{y_0}) f(\sigma_{z_f}, z - \sigma_{z_0})$$

$$f(a, b) = \begin{cases} a, & \text{if } b = 1 \\ 1 - a, & \text{if } b = 0 \end{cases} \quad (2-10)$$

本章节所建立的三维位置细胞模型，建模结果如下图 2.2 所示：




图 2.2 位置细胞建模结果图

2.3 头朝向细胞机理及建模

2.3.1 头朝向细胞机理

头朝向细胞是哺乳动物大脑中一种对头部朝向角度变化极为敏感的神经元类型，最早由 Ranck 等人在 1984 年发现于大鼠的背内侧丘脑^[10]，后续研究发现这类细胞广泛分布于前庭系统、丘脑、海马旁皮层、内嗅皮层和中脑等。当动物被定向到一个特定的方向时，表现出高频放电，而在其他方向放电极低或无放电；不同于位置细胞，头朝向细胞的放电仅取决于动物的朝向，而与其当前位置无关；头朝向细胞的活动在角度空间上连续变化，相邻细胞的首选方向覆盖整个 360°方位角。每个头朝向细胞都是独立的个体，彼此之间互不依赖。它们之间的连接强度与距离呈反比关系，距离越小，连接越强；而当距离增大时，连接的强度则减弱。

三维头朝向细胞可以在三维空间中通过偏航、俯仰、翻滚或它们的组合来代表动物的方向。本文主要的涉及内容为小车运动，小车的运动主要为水平位置和高度变化，同时依赖偏航角来调整行进方向。然而，由于小车通常保持轮子与地面接触，横滚角和俯仰角的变化极小，基本不影响其导航能力。因此，为了简化模型，本文选择四个自由度即只使用偏航角，以确保既能准确描述小车的空间位置，又能有效降低计算复杂度，提高导航系统的实时性和稳定性。




图 2.3 头朝向细胞模型

2.3.2 头朝向细胞建模

本文采用二维连续吸引子神经网络（2D-CAN）来构建头朝向细胞的模型，并仅关注 4 个自由度（DoF）的头部朝向信息，具体包括空间位置的 x 、 y 、 z 坐标以及偏航角（yaw）。该模型采用环状柱状结构，能够周期性地表示机器人在不同高度平面上的头部朝向，同时保持其航向信息的稳定。该模型的神经元在局部和全局参考框架中分别编码绝对航向角，每个神经元对应一个特定的方向范围。同时，头朝向细胞能够与局部场景细胞结合，修正由里程计误差引起的偏航误差，从而增强航向的稳定性。

利用 2D-CAN 构建的头朝向细胞模型，可以在三维空间中持续编码和维持机器人的头部朝向。每个神经元在特定的平面高度内表示一个特定的方向。头朝向细胞的活性矩阵 P^{hdc} 反映了细胞的活跃程度。头朝向细胞的活性更新过程与位置细胞类似，首先多层头朝向细胞会根据初始的头部方向（偏航角和高度）进行初始化，然后根据新的方向估计来更新这些细胞的活性矩阵。初始化和更新过程由多层头朝向细胞的神经动力学驱动，其工作原理与位置细胞的机制相似，包括局部激励、全局抑制和归一化处理。首先，一部分多层头朝向细胞会在局部激励的作用下被激活；接着，所有的多层头朝向细胞会经历全局抑制过程；最后，进行归一化处理以调整 2D-CAN 中多层头朝向细胞的活动水平。

1) 多层头朝向细胞的局部激励

采用二维高斯分布生成多层头朝向细胞的兴奋权重矩阵 $\varepsilon_{u,v}^{hdc}$ ，该矩阵使用二维高斯分布来创建。 (θ, h) 矩阵中各单元之间的距离指标用 u 和 v 来表示，兴奋权重矩阵的计算公式如下：

$$\varepsilon_{u,v}^{hdc} = \frac{1}{(\sigma_{\theta}\sqrt{2\pi})} e^{-u^2/(2\sigma_{\theta}^2)} \cdot \frac{1}{(\sigma_h\sqrt{2\pi})} e^{-v^2/(2\sigma_h^2)} \quad (2-11)$$

其中 u , v ——分别表示航向角和高度的偏移量；

σ_{θ} , σ_h ——分别二维高斯分布的标准差；

多层头朝向细胞的活动变化计算公式如下：

$$\Delta \mathbf{P}_{\theta,h}^{\text{hdc}} = \sum_i^{n_\theta} \sum_j^{n_h} \mathbf{P}_{i,j}^{\text{hdc}}, \forall i, j \in u, v \quad (2-12)$$

其中， n_θ 、 n_h 为多层头朝向细胞的矩阵大小，距离指标 u 和 v 的计算方法如下：

$$\begin{aligned} u &= (\theta - i) \pmod{n_\theta} \\ v &= (h - j) \pmod{n_h} \end{aligned} \quad (2-13)$$

2) 多层头朝向细胞的全局抑制

在生理学上所有的头朝向细胞都通过局部抑制过程抑制邻近细胞。为了保证方向的精确性，需要确保每个头朝向细胞的放电具有唯一性，因此在所有头朝向细胞上施加一个全局抑制常数。局部抑制和全局抑制的计算公式如下：

$$\Delta \mathbf{P}_{\theta,h}^{\text{hdc}} = \sum_{i=1}^{n_\theta} \sum_{j=1}^{n_h} \mathbf{P}_{i,j}^{\text{hdc}} \psi_{u,v}^{\text{hdc}} - \varphi \quad (2-14)$$

其中 $\psi_{u,v}^{\text{hdc}}$ 是局部抑制的权重矩阵， $\mathbf{P}_{i,j}^{\text{hdc}}$ 中的所有值均限于非负值。

3) 多层头朝向细胞的归一化

为了确保航向角的准确性，头朝向细胞的激活状态必须维持在稳定的水平。为此，采用归一化操作来保持多层头朝向细胞的总激活值恒定为 1。归一化过程的计算公式如下：

$$\mathbf{P}_{\theta,h}^{\text{hdc}} = \frac{\mathbf{P}_{\theta,h}^{\text{hdc}}}{\sum_{i=1}^{n_\theta} \sum_{j=1}^{n_h} \mathbf{P}_{i,j}^{\text{hdc}}} \quad (2-15)$$

4) 多层头朝向细胞的更新

多层头朝向细胞通过吸引子网络的动态驱动进行头部方向的更新。基于对头部方向的新估计，当前激活的细胞的活性矩阵会投射到周围的细胞上。该活动过程分别根据旋转和高度 ω_θ 、 v_h 来在偏航和高度矩阵中进行移位。该过程由两个输入决定，一个是发送单元的活动 U^{hdc} ，另一个是残差 η ，它是由偏移的分数分量 ω_{θ_f} 、 v_{h_f} 来计算，活动变化 $\Delta U_{l,m}^{\text{hdc}}$ 的计算公式如下：

$$\Delta U_{l,m}^{\text{hdc}} = \sum_{\theta=\sigma_{\theta_0}}^{\sigma_{\theta_0}+1} \sum_{h=\sigma_{h_0}}^{\sigma_{h_0}+1} \eta U_{(l+\theta)(m+h)}^{\text{hdc}} \quad (2-16)$$

$$\begin{aligned} \begin{bmatrix} \sigma_{\theta_0} \\ \sigma_{h_0} \end{bmatrix} &= \begin{bmatrix} \lfloor k_\theta \omega_\theta \rfloor \\ \lfloor k_h v_h \rfloor \end{bmatrix} \\ \begin{bmatrix} \sigma_{\theta_f} \\ \sigma_{h_f} \end{bmatrix} &= \begin{bmatrix} k_\theta \omega_\theta - \sigma_{\theta_0} \\ k_h v_h - \sigma_{h_0} \end{bmatrix} \end{aligned} \quad (2-17)$$

其中 k_θ 、 k_h 是头朝向细胞的更新常数，残差 η 的计算公式如下：

$$\eta = f(\sigma_{\theta_f}, \theta - \sigma_{\theta_0}) f(\sigma_{h_f}, h - \sigma_{h_0})$$

$$f(a, b) = \begin{cases} a, & \text{if } b = 1 \\ 1 - a, & \text{if } b = 0 \end{cases} \quad (2-18)$$

本章节所建立的多层头朝向细胞模型，建模结果如下图 2.4 所示：




图 2.4 头朝向细胞建模结果图

2.4 网络细胞机理及建模

2.4.1 网络细胞机理

网络细胞是一类位于内嗅皮层的神经元，首次于 2005 年被发现。与位置细胞只在特定位置激活不同，网络细胞在整个环境中呈现周期性放电模式，激活位置形成六边形的网格状图案^[11]。这种放电模式与动物的运动速度和方向无关，提供了一个内在的坐标系统，使得动物能够通过路径积分来推算自己的位置，即使在没有外部标志物的情况下，仍能维持其定位精度。多个网络细胞协同工作，每个网络细胞会在不同的位置激活，因此，单独一个网络细胞无法精确定位大鼠的位置。然而，由于不同网络细胞的激活点会随着空间位置的变化而变化，且它们的网格大小各不相同，通过多个网络细胞的重叠区域可以精确确定大鼠的位置。在空间导航过程中，路径整合或航位推算是至关重要的。在已知起点的情况下，基于估算的航向和速度，内部的空间位置表示将不断更新，以确保精确的导航和定位。

所以路径整合可以基于哺乳动物大脑中的三维网络细胞来实现，网络细胞可以利用来自运动系统的信息来计算行进距离和方向，实现路径积分；而且虽然网络细胞的活动主要由自运动信息驱动，但外部视觉、地标等线索可对其进行校正，以防止误差积累；此外，网络细胞与位置细胞可以协同工作，网络细胞提供连续的空间坐标，而位置细胞负责特定地点的识别。网络细胞与头朝向细胞也可以协同工作，头朝向细胞提供方向信息，帮助网络细胞调整坐标系统的方向。

由于是在 4DoF 的前提下对头朝向细胞进行的建模，因此网格细胞的建模也选择在 4DoF 的环境下，即能准确描述小车的空间位置，又能有效降低计算复杂度，提高导航系统的实时性和稳定性。




图 2.5 网格细胞模型

2.4.2 网格细胞建模

由于 4DoF 下的姿态可以在矢量空间中表示，所以采用立体三维的连续吸引子神经网络来构建网格细胞模型，并在全局参考框架中表示距离、方向等度量信息。每个单元格代表一个特定的三维位置，附近的细胞通过连通性进行关联。连接包含了每对细胞之间的距离和方向，神经单元的连接可以周期性地表示三维空间当机器人在大尺度空间中移动时，每个三维网格单元都会被激活，可以基于这个模型进行三维路径整合。

网格细胞网络的神经动态过程依赖于局部激励、全局抑制和归一化机制。首先，部分三维网格细胞会在局部激励作用下被激活。然后，所有三维网格细胞会经历全局抑制阶段，从而减弱它们的活动。最后，网格细胞的活动值会通过归一化处理进行调整，以确保网络的稳定性。

1) 三维网格细胞的局部激励

使用三维高斯分布来构建出兴奋性权值矩阵 $\varepsilon_{u,v,w}^{gc}$ ，单元之间的距离指标用 u ， v 和 w 表示。权值矩阵的计算公式如下：

$$\varepsilon_{u,v,w}^{gc} = \frac{1}{(\sigma_x \sqrt{2\pi})} e^{-u^2/(2\sigma_x^2)} \cdot \frac{1}{(\sigma_y \sqrt{2\pi})} e^{-v^2/(2\sigma_y^2)} \cdot \frac{1}{(\sigma_z \sqrt{2\pi})} e^{-w^2/(2\sigma_z^2)} \quad (2-19)$$

其中 σ_x ， σ_y ， σ_z 分别表示三维空间分布的方差常数，三维网格细胞活动变化的计算公式如下：

$$\Delta \mathbf{P}_{x,y,z}^{gc} = \sum_i^{n_x} \sum_j^{n_y} \sum_k^{n_z} \mathbf{P}_{i,j,k}^{gc} \varepsilon_{u,v,w}^{gc}, \forall i, j, k \in u, v, w \quad (2-20)$$

三维网格单元的矩阵维度是 n_x 、 n_y 和 n_z ，距离指数的计算方法如下：

$$\begin{aligned} u &= (x - i) \pmod{n_x} \\ v &= (y - j) \pmod{n_y} \\ w &= (z - k) \pmod{n_z} \end{aligned} \quad (2-21)$$

2) 三维网格细胞的全局抑制

每个三维网格细胞会通过局部抑制作用来减弱周围细胞的活动。此外，所有网格细胞还会受到一个固定的全局抑制常数的平均抑制作用。具体的抑制机制可通过以下公式表示：

$$\Delta \mathbf{P}_{x,y,z}^{\text{gc}} = \sum_{i=1}^{n_x} \sum_{j=1}^{n_y} \sum_{k=1}^{n_z} \psi_{u,v,w}^{\text{gc}} \mathbf{P}_{i,j,k}^{\text{gc}} - \varphi \quad (2-22)$$

其中 $\psi_{u,v,w}^{\text{gc}}$ 为局部抑制的权重矩阵， $\mathbf{P}^{\text{gc}}$ 中的所有值都被限制为非负值。

3) 三维网格细胞的归一化

归一化之后，细胞活性矩阵 $\mathbf{P}_{x,y,z}^{\text{pc}}$ 的计算公式如下：

$$\mathbf{P}_{x,y,z}^{\text{pc}} = \frac{\mathbf{P}_{x,y,z}^{\text{gc}}}{\sum_{i=1}^{n_x} \sum_{j=1}^{n_y} \sum_{k=1}^{n_z} \mathbf{P}_{i,j,k}^{\text{gc}}} \quad (2-23)$$

4) 三维网格细胞的更新

三维路径积分也可以通过将当前的三维网格细胞活性投射到附近的细胞中来执行。该过程涉及将当前网格细胞的活动投射到相邻细胞，细胞的活动在三维空间中根据全局坐标 (d_x, d_y, d_z) 进行平移和旋转信息进行位置更新。活动更新公式如下：

$$\Delta U_{lmn}^{\text{gc}} = \sum_{x=\sigma_{x_0}}^{\sigma_{x_0}+1} \sum_{y=\sigma_{y_0}}^{\sigma_{y_0}+1} \sum_{z=\sigma_{z_0}}^{\sigma_{z_0}+1} \gamma \mathcal{U}_{(l+x)(m+y)(n+z)}^{\text{gc}} \quad (2-24)$$

$$\begin{bmatrix} \sigma_{x_0} \\ \sigma_{y_0} \\ \sigma_{z_0} \end{bmatrix} = \begin{bmatrix} k_x d_x \\ k_y d_y \\ k_z d_z \end{bmatrix} \quad (2-25)$$

$$\begin{bmatrix} \sigma_{x_f} \\ \sigma_{y_f} \\ \sigma_{z_f} \end{bmatrix} = \begin{bmatrix} k_x d_x - \sigma_{x_0} \\ k_y d_y - \sigma_{y_0} \\ k_z d_z - \sigma_{z_0} \end{bmatrix} \quad (2-26)$$

其中 k_x ， k_y 和 k_z 为三维平移积分的更新常量。残差 γ 的计算公式为：

$$\begin{aligned} \gamma &= f(\sigma_{x_f}, x - \sigma_{x_0}) f(\sigma_{y_f}, y - \sigma_{y_0}) f(\sigma_{z_f}, z - \sigma_{z_0}) \\ f(a, b) &= \begin{cases} a, & \text{if } b = 1 \\ 1 - a, & \text{if } b = 0 \end{cases} \end{aligned} \quad (2-27)$$

2.5 本章小结

本章围绕类脑导航细胞的机理及建模方法展开研究，深入分析了位置细胞、网格细胞和头朝向细胞的生物学特性及其在类脑导航中的作用。首先，探讨了位置细胞的空间编码机制，并分析其在认知地图构建中的关键作用。随后，介绍了头朝向细胞的生物学特性，并探讨其在方向感知和姿态估计中的应用。最后，研究了网格细胞的六边形放电特性，阐述其在路径积分和空间定位中的贡献。

在此基础上，本章进一步基于各种连续吸引子神经网络建立了类脑导航细胞的计算模型，并详细研究了各种导航细胞的初始化和活动更新机制。实验和分析表明，该模型能够有效模拟生物导航系统的特性，为机器人自主导航和空间认知提供了新的思路。本章的研究为后续类脑导航系统的实现和优化奠定了理论基础，并为自主机器人在复杂环境中的高效定位和导航提供了参考。

第3章 基于 SuperPoint 改进的 NeuroSLAM 算法

3.1 引言

在自主机器人导航和空间认知研究中，视觉 SLAM（Simultaneous Localization and Mapping, 同时定位与建图）技术起着至关重要的作用。NeuroSLAM 作为一种基于生物机制的 SLAM 方法，模拟了大脑中的网格细胞、头朝向细胞和位置细胞的协同工作方式，使机器人能够通过神经计算进行环境感知与自定位。然而，传统的 NeuroSLAM 在特征提取和匹配方面存在一定局限性，例如对光照变化、视角变换及动态环境的适应能力较弱，影响了系统的定位精度和稳定性。

为了解决上述问题，提出了一种基于 SuperPoint 特征提取方法来进行改进的 NeuroSLAM 算法。SuperPoint 作为一种高效的深度学习特征提取方法，能够在端到端框架下提取鲁棒的特征点，并具备较强的尺度不变性、旋转不变性和光照适应性。相比传统的 ORB、SIFT 等手工设计特征，SuperPoint 通过卷积神经网络（CNN）学习特征描述子，在复杂场景下仍能保持高精度的匹配性能。因此，在 NeuroSLAM 中引入 SuperPoint 以提升系统的特征提取能力，从而优化机器人在不同环境中的定位精度和在复杂环境中的定位鲁棒性。

本章将详细介绍基于 SuperPoint 改进的 NeuroSLAM 算法，包括其整体架构、核心模块改进以及实验验证结果。

3.2 NeuroSLAM 类脑导航算法框架

NeuroSLAM 系统^[28]框架如图 3.1 所示。该系统由几个模块组成，包括局部视图线索、三维自运动线索、三维位置细胞网络、多层头朝向细胞网络、三维网格细胞网络和三维空间地图。

该系统的输入来自低成本相机获得的连续图像，并提取两类关键线索：1、局部视图线索：通过视觉模板匹配来提取环境特征，这些特征被存储在局部视图细胞中，以辅助位置感知。2、三维自运动线索：通过连续图像计算三维位姿变化，该信息用于路径积分帮助机器人在无外部标记的环境中进行自主导航。这两类输入信息分别作用于位置细胞、头朝向细胞和网格细胞三大神经网络，并最终构建三维经验地图，以支持机器人自主导航。

NeuroSLAM 算法的核心是三大类神经网络，分别用于位置感知、方向感知和路径积分。三维位置细胞网络主要负责存储机器人在不同位置的记忆，该网络用于位置编码，通过局部视图线索激活。多层头朝向细胞主要负责机器人头部方向的编码，相当于航向角感知，网络的主要作用是结合视觉信息与自运动信息，形成稳定的方向感知，防止方向漂移。三维网络细胞主要负责路径积分，计算机器人在空间中的连续位移，该网络结合了自运动线索，提供精确的位姿估计和地图更新。

该系统最终的导航决策基于三维经验地图，其核心思想是模拟生物体在探索环境时形成的认知地图。系统通过多个神经网络的协同作用，将机器人在不同位置、方向和路径上的信息编码到多层次经验地图（Multilayered ExpMap）中，使其能够在未来任务中利用记忆进行高效导航。这一机制类似于生物海马体的空间认知功能，结合神经元网络的自适应性，使机器人能够在复杂环境中保持稳定的空间感知、方向校准和路径优化能力。




图 3.1 NeuroSLAM 系统框架

3.3 基于 SuperPoint 的视觉里程计改进算法

NeuroSLAM 导航算法利用直接法来推算相机的运动状态，其核心步骤如下：首先，将原始图像转换为灰度图形式，接着根据不同区域进行图像裁剪。随后，算法分别估算平移速度、垂直位移速度和航向角的变化速度。该方法依赖于像素级别的运动估计，基于灰度不变假设——即假定同一位置的像素值在不同图像中保持一致。然而，在实际应用中，这一假设常常无法成立。例如，光照变化可能导致图像的整体亮

度发生变化，从而改变灰度值，这会影响运动估计的精度，甚至使得算法出现错误。

为了提升视觉里程计的鲁棒性，引入基于 SuperPoint 的视觉里程计算法^[61]进行改进。SuperPoint 是一种自监督的深度学习方法，用于检测和描述图像中的特征点。它是一种端到端的全卷积神经网络，可以在一次前向传播中同时提取特征点及其描述符。使用 SuperPoint 网络的视觉里程计主要包括三个核心步骤：特征提取、特征匹配和位姿估计，其整体工作流程如图 3.2 所示。




图 3.2 SuperPoint 工作流程

SuperPoint 作为一种基于深度学习的特征点检测与描述算法，相较于传统的直接法，其优势在于以下几点：

- 1、与直接法依赖灰度信息不同，SuperPoint 提取的特征点更加稳定，即使在复杂环境（如光照变化或运动模糊）下仍能保持较高的匹配精度。
- 2、传统方法（如 ORB）采用先检测特征点、再计算描述子的流水线式处理，而 SuperPoint 一次前向传播同时完成检测和描述，大幅提升计算效率。
- 3、SuperPoint 采用自监督学习，避免了手工标注的成本，同时通过同态自适应扩展数据，提高泛化能力。

3.3.1 SuperPoint 特征提取算法

SuperPoint 采用自监督学习来检测特征点并提取描述子，而不是直接进行位姿的端到端学习。其核心思想是：特征点与位姿之间存在明确的几何关系，可以通过数学模型直接求解，从而避免了使用神经网络来计算位姿。与传统的手工设计特征点提取方

法相比，神经网络能够更有效地替代人工特征提取，从而提高算法的鲁棒性和泛化能力，减少不确定性；SuperPoint 结合了 MagicPoint 的特征点检测能力，并通过自监督学习方法优化，使其在真实图像上具有更强的适应性。与端到端的位姿解算学习不同，SuperPoint 仅关注特征点检测和描述子提取，这既能保证特征点计算位姿时的精确数学建模，又能通过神经网络提高特征提取的稳定性和鲁棒性。接下来，将从 SuperPoint 的网络结构和综合预训练两个方面进行详细介绍。

3.3.1.1 网络结构

SuperPoint 采用了全卷积神经网络架构，能够在完整图像上进行处理，并通过编码-解码方式实现特征点检测和描述子计算。该方法的设计思路是，首先利用共享编码器对输入图像进行处理和维度压缩。随后，网络被划分为两个解码器，分别用于检测特征点和计算其描述子。与传统方法不同，SuperPoint 在这两个任务之间共享大部分参数。传统方法通常先检测特征点，再独立计算描述子，而 SuperPoint 通过共享编码器，同时执行特征点检测和描述子计算，从而提高了计算效率并优化了模型性能。接下来，将详细介绍共享编码器、特征点提取解码器、描述子计算解码器及损失函数的设计细节。




图 3.3 SuperPoint 工作原理

1) 共享编码器

SuperPoint 的共享编码器采用了类似 VGG 架构的设计，旨在减少图像的维度。该编码器包含多个卷积和池化层，进行空间下采样，并通过非线性激活函数来处理特征，如图 3.4 所示。共享编码器包括四个块（每个块由两层卷积和一层最大池化层组成，最后一个块没有池化层），并包含三个最大池化层。假设输入图像的大小为 $H \times W$ ，经过三次最大池化后，每次图像尺寸都缩小一倍，最终输出的图像尺寸为 $H/8 \times W/8$ 。共享编码器将输入图像 $I \in \mathbb{R}^{H \times W}$ 转换为一个中间张量 $B \in \mathbb{R}^{H_c \times W_c \times F}$ ，该张量具有较小的空间维度和更大的通道深度。（ $H_c = H/8, W_c = W/8, F = 128$ ）




图 3.4 共享编码器

2) 特征点提取解码器

特征点提取解码器网络的主要结构如下图 3.5 所示。在 SuperPoint 的特征点检测任务中，每个输出像素表示该像素在输入图像中作为特征点的概率。该概率反映了该位置作为特征点的可能性。通常，图像会通过上采样恢复到全分辨率，但上采样操作往往需要较大的计算资源，并且可能引入棋盘效应，影响检测结果的稳定性。




图 3.5 特征点提取解码器

输入为共享编码器的输出 $B \in \mathbb{R}^{H_c \times W_c \times F}$ ，经过卷积层后变为 $(H/8, W/8, 65)$ 的特征响应图 χ ，该图在平面 (H_c, W_c) 上的特征向量 x_{hw} 映射回原图正好对应一个 8×8 的区域。因此特征向量 x_{hw} 对应 64 维的特征响应值（进行 Softmax 过程中会舍去一层），每个输出像素与输入图像中的 64 个像素位置一一对应，特征响应值越高，表示该位置的像素点更可能是特征点，即该像素被检测为特征点的概率越大。

Softmax 函数的计算公式如下：

$$S_r^{(i,j)} = \frac{\exp(X_r^{(i,j)})}{\sum_{k=1}^{65} \exp(X_k^{(i,j)})} \quad (3-1)$$

其中 $S_r^{(i,j)}$ 为 Softmax 层输出的特征图的第 r 个通道在 (i,j) 位置的值， $X_r^{(i,j)}$ 为输入特征图的第 r 个通道在 (i,j) 位置的值。子像素卷积通过将 $H/8 \times W/8$ 的特征图通过 reshape 恢复成 $H \times W$ 原始大小的图像。相比插值和反卷积，子像素卷积不仅计算量更小而且能提供更高的精度，符合需求即更准确地提取每个像素点的特征点概率。

3) 描述子计算解码器

描述子解码网络的作用是将共享编码器得到的特征图进行进一步处理，以生成每个像素的描述子。该过程的目的是生成每个像素点的 256 维描述子，并进行 L2 归一化，以便用于后续的特征匹配或其他任务。




图 3.6 描述子解码器

共享编码器的输出 $(H_c, W_c, 128)$ 包含了图像中每个像素的高维特征，这些特征将作为描述子解码器的输入。首先，将特征图进一步处理，使得每个像素位置的描述子维度从 128 变为 256，增加的 128 个通道提升了特征的表达能力，使得每个像素点的描述子可以包含更多的信息。然后，为了将特征图恢复到原始图像的尺寸，采用了双线性插值操作，通过对临近像素的值进行插值计算平滑地将低分辨率特征图扩展到高分辨率，从而生成 $(H, W, 256)$ 大小的描述子图。使得原本较小尺寸的特征图被扩展回原始图像的尺寸，同时保持了高维描述子（256 维）。最后，通过对每个像素位置的描述子进行 L2 归一化处理，这一步骤的目的是将描述子缩放到单位范数，L2 归一化能够使得每个描述子的尺度保持一致，便于后续进行相似度计算和匹配。归一化后的描述子具有较好的稳定性和鲁棒性，能够更好地应对图像变形、光照变化等影响。

$$\mathbf{d}_{\text{normalized}} = \frac{\mathbf{d}}{\|\mathbf{d}\|_2} \quad (3-2)$$

其中 $\mathbf{d}$ 是某个像素的描述子， $\|\mathbf{d}\|_2$ 是该描述子的 L2 范数。

4) 损失函数

最终损失由两个部分组成，分别是特征点检测损失 $\mathcal{L}_p$ 和描述子损失 $\mathcal{L}_d$ ，两者之和构成整体优化目标。训练时，我们使用合成的扭曲图像对，这些图像对具有真实的特征点位置用于优化特征点检测损失和随机生成的单应性变换矩阵 $\mathbf{H}$ ，该矩阵用于建立两个图像之间的真实对应关系从而优化描述子损失。这样可以在给定一对图像的情况下，同时优化特征点检测器和描述子检测器，确保模型既能准确检测特征点，又能学

习稳定的特征描述子。最终损失通过一个平衡系数 λ 进行调节，以确保训练过程中的合理权衡。

$$\mathcal{L}(\mathcal{X}, \mathcal{X}', \mathcal{D}, \mathcal{D}'; Y, Y', S) = \mathcal{L}_p(\mathcal{X}, Y) + \mathcal{L}_p(\mathcal{X}', Y') + \lambda \mathcal{L}_d(\mathcal{D}, \mathcal{D}', S) \quad (3-3)$$

对于特征点提取部分的损失函数 $\mathcal{L}_p$ ，计算公式如下：

$$\mathcal{L}_p(\mathcal{X}, Y) = \frac{1}{H_c W_c} \sum_{h=1}^{H_c} \sum_{w=1}^{W_c} l_p(\mathbf{x}_{hw}; y_{hw}) \quad (3-4)$$

$$l_p(\mathbf{x}_{hw}; y) = -\log \left(\frac{\exp(\mathbf{x}_{hwy})}{\sum_{k=1}^{65} \exp(\mathbf{x}_{hwk})} \right)$$

对于描述子提取部分的损失函数 $\mathcal{L}_d$ ，还添加了一个平衡系数 λ_d ，计算公式如下：

$$\mathcal{L}_d(\mathcal{D}, \mathcal{D}', S) = \frac{1}{(H_c W_c)^2} \sum_{h=1}^{H_c} \sum_{w=1}^{W_c} \sum_{h'=1}^{H_c} \sum_{w'=1}^{W_c} l_d(\mathbf{d}_{hw}, \mathbf{d}'_{h'w'}; s_{hwh'w'}) \quad (3-5)$$

$$l_d(\mathbf{d}, \mathbf{d}'; s) = \lambda_d * s * \max(0, m_p - \mathbf{d}^T \mathbf{d}') + (1-s) * \max(0, \mathbf{d}^T \mathbf{d}' - m_n)$$

3.3.1.2 综合预训练

目前的神经网络模型在提取语义信息方面存在一定的局限性，而且训练深度学习模型通常依赖于大量手动标注的数据，这增加了数据准备的成本和难度。为了解决这些问题，采用自监督学习模式来减少对人工标注数据的依赖，整个训练过程主要包括以下三个步骤：

1) 训练 MagicPoint 网络

由于现实场景中的特征点难以人工标注，每个人对特征点的理解不同，导致标注结果可能存在较大偏差。为此，首先在一个基础的几何图形数据集上训练一个初步的特征点检测器，该数据集由点和线构成，包含了 9 种不同的几何形状，如三角形、平行四边形、立方体、椭圆等。每个特征点的实际坐标被用作标签，辅助神经网络的训练，从而使其能够掌握基本的特征点检测技能。使用 SuperPoint 的特征点检测架构在该合形状数据集上进行训练，得到的模型被命名为 MagicPoint。虽然它具有一定的特征点提取能力，但仍未能有效地泛化到实际场景中^[62]。




图 3.7 合成图像数据集

2) 自监督学习

尽管 MagicPoint 具备初步的特征点检测能力，但在复杂的纹理和真实场景中仍会遗漏许多潜在的兴趣点，且其多视角重复性较差，导致迁移能力不足。为了解决这一问题，采用自监督学习方法，通过多尺度、多变换的 Homographic Adaptation 技术提升 MagicPoint 的泛化能力。




图 3.8 Homographic Adaptation 流程图

采用 MagicPoint 对 MSCOCO2017 数据集进行特征点预测，得到伪特征点标签。使用 Homographic Adaptation 进行数据增强，对每张 COCO 数据集中的图像，随机进行 N 种变换（如缩放、仿射变换等）。使用 MagicPoint 依次对这 N 张变换后的图像进行推理，得到 N 张 heatmap，然后将 N 张 heatmap 进行累加，最终得到的全局 heatmap。通过阈值截取这张 heatmap 上的高概率区域，提取最终的特征点伪标签。

通过使用生成的伪标签作为监督信号，进一步对 MagicPoint 进行训练，以提升其在真实场景中的特征点检测能力。通过反复迭代训练，逐步优化模型，直到其特征点检测表现接近官方模型的评估结果。优化后的 MagicPoint 网络便构成了 SuperPoint 的特征点检测模块。

3) 联合训练

经过前两个阶段之后，已获得 SuperPoint 的特征点检测部分，能够在不同图像中提取鲁棒、可重复的特征点。接下来，我们需要训练 SuperPoint 的描述子部分，使其

能够学习特征点的对应关系。使用 SuperPoint 提取一张图像的特征点真实位置，对该图像施加不同的变换，生成变换后的图像。通过已知的变换矩阵，计算变换前后两张图像中特征点的真实对应关系，并作为标签用于训练 SuperPoint 的描述子。最终，经过自监督学习训练的 SuperPoint 网络便可以同时完成特征点检测和特征点描述子表示，大幅减少人工标注的需求，并提升模型的鲁棒性与泛化能力。

3.3.2 特征点匹配算法

SuperGlue 是一种基于图神经网络（GNN）的强大特征匹配算法^[63]，能够同时匹配特征点并滤除外点，提升匹配的鲁棒性和准确性，其模型主要由两部分组成：1、注意力图神经网络 2、最佳匹配层。模型结构如下图 3.9 所示：




图 3.9 SuperGlue 原理图

SuperGlue 的注意力机制通过图神经网络进行特征点匹配描述子的优化。它采用自注意力和跨注意力机制，在单张图像内部以及不同图像之间传播信息，从而增强特征点的匹配能力。首先，每个特征点由坐标和描述子组成，SuperGlue 使用多层感知机对这些信息进行编码，使其兼具空间和视觉信息。随后，通过多层迭代计算，每一层都包含自注意力和跨注意力计算。自注意力作用于单张图像，使特征点能够与同一图像中的其他关键点进行信息交互。跨注意力作用于两张图像之间，使每个特征点能够参考另一张图像中的可能匹配点，减少误匹配问题。经过多层迭代，每个特征点的匹配描述子逐步优化，并最终输入到最优匹配层进行匹配计算。

SuperGlue 的最优匹配层用于计算特征点的最优匹配关系，并有效处理部分特征点可能无法找到对应点的问题。SuperGlue 引入了 Dustbin 机制，在匹配矩阵中增加“无匹配点”行列，以解决无匹配点问题。此外，SuperGlue 使用 Sinkhorn 迭代算法进行优化，该算法通过交替进行行归一化和列归一化，使匹配矩阵满足概率分布约束，进一步提高匹配精度。最终，经过 Sinkhorn 优化，SuperGlue 生成部分匹配矩阵，提供最优特征点匹配并自动排除无法匹配的点。与传统的最近邻匹配+RANSAC 方法相比，

SuperGlue 在光照变化、视角变换和复杂几何结构等挑战性场景下，展现出更高的准确性和鲁棒性。

3.3.3 三维位姿解算

1) 对极几何变换

在使用单目相机时，如果已获得匹配的特征点，可以通过对极几何来估计相机的运动。具体来说，可以利用前后两帧图像中的匹配点，计算出相机的相对运动，包括旋转和平移^[24]。如图 3.10 所示，设前后两帧图像分别为 I_1 和 I_2 ，对应的相机中心分别为 O_1 和 O_2 。假设三维空间中存在一个特征点 P ，其在第一帧图像 I_1 中的投影点为 p_1 ，在第二帧图像 I_2 中的投影点为 p_2 。这三个点 O_1 、 O_2 和 P 共同构成一个极平面。相机中心 O_1 和 O_2 在像素平面上的投影点分别为 e_1 和 e_2 ，称为极点，极平面与两幅图像的成像平面相交，分别形成极线 l_1 和 l_2 ，它们构成了匹配点搜索的约束。根据对极几何原理，特征点 p_1 在 I_2 中的对应点 p_2 必须位于对应的极线上。利用这一约束，可以通过计算基础矩阵或本质矩阵，从而推导出相机在两帧之间的运动信息，即旋转矩阵 R 和平移向量 t 。




图 3.10 对极几何变化

假设 P 的空间位置位于第一帧的坐标系中，表示为 $\mathbf{P}=[X,Y,Z]^T$ ，根据图像之间的转换关系，可以得到两帧图像中的匹配特征点 p_1 和 p_2 的像素坐标为：

$$\begin{aligned} s_1 p_1 &= KP \\ s_2 p_2 &= K(RP + t) \end{aligned} \quad (3-6)$$

这里 K 表示相机的内参矩阵，而 R, t 则表示两个坐标系之间的相机运动。使用齐次坐标的情况下，可以将上述公式表示为乘以非零常数下的等式：

$$\begin{aligned} p_1 &= KP \\ p_2 &= K(RP + t) \end{aligned} \quad (3-7)$$

假设有两个像素点在归一化平面上的坐标为 $x_1 = K^{-1}p_1$ ， $x_2 = K^{-1}p_2$ 代入上式得：

$$x_2 = Rx_1 + t \quad (3-8)$$

两边同时左乘 $t^\wedge$ 和 x_2^T ，得到下式：

$$x_2^T t^\wedge x_2 = x_2^T t^\wedge R x_1 \quad (3-9)$$

左乘 $t^\wedge$ 相当于两侧同时与 t 做外积， $t^\wedge x_2$ 是一个与 t, x_2 都垂直的向量，因此它与 x_2 做内积时，将得到 0。所以，得到一个简洁的式子：

$$x_2^T t^\wedge R x_1 = 0 \quad (3-10)$$

重新代入 p_1 和 p_2 ，得到：

$$p_2^T K^{-T} t^\wedge R K^{-1} p_1 = 0 \quad (3-11)$$

这两个方程被称为对极约束，它们同时包含了旋转和平移信息。可以使用经典的八点法来求解，得到本质矩阵或基础矩阵。在通过分解本质矩阵后，会出现四种可能的解，因为只有其中一个解确保所有的点在两个相机视图中都有正的深度。为了确定正确的解，我们可以将任意匹配点代入四个解，检查该点在两相机中的深度。只有当一个解使得所有点的深度为正时，那个解才是正确的。

2) PnP 位姿求解

PnP 是用于求解从 3D 空间点到 2D 图像点运动中相机的位姿估计^[54]。与对极几何方法不同，PnP 方法并不依赖于对极约束，也不需要像对极几何那样至少需要八个或更多的匹配点才能进行估计。同时，对极几何方法还面临初始化、纯旋转以及尺度问题。在 PnP 中，如果某些特征点的 3D 位置已知，它们的投影位置在图像中就能提供足够的信息进行位姿计算。3D 位置可以通过三角化技术得到，或者通过 RGB-D 相机的深度图直接获取。

假设某个空间点 P ，它的齐次坐标为 $P = (X, Y, Z, 1)^T$ 。在图像 I_1 中，投影到齐次坐标下的特征点 $x_1 = (u_1, v_1, 1)^T$ 。定义一个包含了旋转和平移信息的增广矩阵 $[R|t]$ 为一个 3×4 的矩阵，得到下式：

$$s \begin{pmatrix} u_1 \\ v_1 \\ 1 \end{pmatrix} = \begin{pmatrix} t_1 & t_2 & t_3 & t_4 \\ t_5 & t_6 & t_7 & t_8 \\ t_9 & t_{10} & t_{11} & t_{12} \end{pmatrix} \begin{pmatrix} X \\ Y \\ Z \\ 1 \end{pmatrix} \quad (3-12)$$

为了简化表示，定义行向量为：

$$\begin{aligned} t_1 &= (t_1, t_2, t_3, t_4)^T \\ t_2 &= (t_5, t_6, t_7, t_8)^T \\ t_3 &= (t_9, t_{10}, t_{11}, t_{12})^T \end{aligned} \quad (3-13)$$

消去上式中的 s ，得到两个约束如公式 (3-14)。

$$\begin{aligned} t_1^T P - t_3^T P u_1 &= 0 \\ t_2^T P - t_3^T P v_1 &= 0 \end{aligned} \quad (3-14)$$

在上述方程中， t 代表未知量。每个特征点为 t 提供两个线性约束。如果有 N 个特征点，这些约束可以通过以下的线性方程组来表示：

$$\begin{bmatrix} P_1^T & 0 & -u_1 P_1^T \\ 0 & P_1^T & -v_1 P_1^T \\ \vdots & \vdots & \vdots \\ P_N^T & 0 & -u_N P_N^T \\ 0 & P_N^T & -v_N P_N^T \end{bmatrix} \begin{bmatrix} t_1 \\ t_2 \\ t_3 \end{bmatrix} = 0 \quad (3-15)$$

由于未知量 t 具有 12 个维度，因此至少需要 6 对匹配点才能进行矩阵 T 的线性求解，从而显著降低计算量。

3.4 类脑导航轨迹地图

导航轨迹地图在系统中扮演着存储机器人在环境中“经历”的重要角色，为后续的定位、回环检测以及地图校正提供依据。4DoF 位姿的编码、构建和更新导航细胞的活动调控，主要包括三个关键部分。

1) 位姿的编码

4DoF 导航轨迹地图是由许多 4DoF 位姿估计组成，位姿节点是构成轨迹地图的基本单元，每个位姿节点都由四个部分组成：局部视图单元编码 V_i^{lv} 、三维位置细胞编码 P_i^{pc} 、多层头朝向细胞编码 P_i^{hdc} 、三维网格细胞积分编码 P_i^{exp} 。一个 4DoF 位姿节点可以表示为：

$$E_i = \{V_i^{lv}, P_i^{pc}, P_i^{hdc}, P_i^{exp}\} \quad (3-16)$$

这种联合编码方式将视觉、位置信息和朝向信息融合在一起，使得每个体验节点都包含了丰富的环境和自身状态信息。

2) 位姿的创建

位姿的创建过程主要在机器人移动过程中，当机器人获得新的视觉、位置和朝向信息时，系统会计算当前的“位姿联合编码”。通过计算当前位姿经历与上个位姿经历之间的差异分数 S_i ，来确认两个位姿联合编码之间是否相似，计算公式如下：

$$S_i = \mu^{lv} |V_i^{lv} - V^{lv}| + \mu^{pc} |P_i^{pc} - P^{pc}| + \mu^{hdc} |P_i^{hdc} - P^{hdc}| \quad (3-17)$$

其中 $\mu^{lv}, \mu^{pc}, \mu^{hdc}$ 为局部视图细胞、三维位置细胞和多层头朝向细胞的加权贡献，评估 4DoF 位姿的变化。如果与当前位姿的差异超过某个阈值 S_{max} ，则会创建一个新的

4DoF 位姿经历；如果差异低于该阈值，则不会创建新的位姿经历。最终，通过整合所有位姿经历，构建三维经验地图。

3) 位姿的更新

当机器人识别到熟悉的环境时，会将视觉信号输入局部视图细胞，并与三维位置细胞和多层头朝向细胞的活动结合，从而调整 4DoF 位姿，将新的经历与已有的经历进行匹配和校准。由于视觉里程计的累积误差，新旧的位姿经历存在差异，为了降低误差根据新旧位姿经历信息对 4DoF 轨迹地图进行校正。

3.5 回环检测

视觉模板是系统中进行回环检测的关键组件，当机器人在环境中移动时，它会通过摄像头捕获连续的图像，并根据这些图像生成视觉模板^[28]。每个视觉模板与一个局部视图细胞相关联，用于在后续的场景中进行匹配和识别，当机器人观察到熟悉的场景时，与该场景匹配的局部视图细胞会被激活。

1) 视觉模板的生成

视觉模板的生成基于图像的强度轮廓，系统会对连续的图像进行处理，提取关键的视觉特征，并将其存储为模板。首先，对捕获的图像进行下采样和裁剪，以提高处理效率。然后，计算图像的强度轮廓，通过对图像的像素强度进行求和或平均操作。最后，将相机图像的当前扫描线强度曲线与存储的模板进行比较，如果当前视图与已有模板匹配，则使用已存储的模板，否则创建一个新的模板并通过设定阈值来控制模板的生成板。




图 3.11 视觉模板

2) 视觉模板匹配

每个视觉模板都是根据扫描线强度曲线来进行学习和存储的，通过扫描线强度轮廓与本地局部视图单元进行匹配以支持视觉位置识别。当机器人再次看到一个熟悉的场景时，系统会尝试将当前的视觉输入与已有的视觉模板进行匹配，匹配过程基于模板之间的相似度计算。使用平均绝对强度差进行当前轮廓和模板之间的比较，计算公式如下：

$$d(I^i, I^{i+1}, s^h) = \frac{1}{w - |s^h|} \left(\sum_{n=1}^{w - |s^h|} \left| I_{n + \max(s^h, 0)}^{i+1} - I_{n - \min(s^h, 0)}^i \right| \right) \quad (3-18)$$

其中 s^h 为偏移量， w 为是图像的宽度。比较是在很小的像素偏移量范围内进行的，设定一个最大允许差值 ψ ，当匹配误差小于该值时，视为匹配成功，否则创建新的模板。

3) 局部视图细胞活性

局部视图细胞的活性水平反映了当前视觉输入与存储模板之间的匹配程度，活性水平的计算基于视觉模板的匹配结果。局部视图由一维单元格数组组成，每个单元格对应一个特定的视觉模板。单元格的活性水平 a_i 在 0 和 1 之间变化。局部视图细胞活性计算公式如下：

$$a_i = \begin{cases} 0, & d_i > d_{\max} \\ 1/(d_i + \varepsilon) & d_i \leq d_{\max} \end{cases} \quad (3-19)$$

引入 ε 是为了避免 d_i 为零时局部视图细胞被无限激活， $d_{\max}$ 为差异阈值， d_i 为模板中像素强度值与当前图像的绝对差值之和。最后，选择活性水平最高的局部视图细胞，认为其对应的场景是当前机器人所处的环境并对经验地图轨迹进行修正。

3.6 仿真分析


在本节为了验证基于 SuperPoint 改进的 NeuroSLAM 算法在不同环境下的性能，设计了一系列仿真实验。实验环境包括室内场景和室外场景，这些场景涵盖了光照变化、视角变换以及动态物体干扰等多种复杂情况。验证数据集主要聚焦于停车场环境，提供一个具有挑战性的测试场景，以评估算法在复杂、动态且光照变化显著的室内停车环境中的性能。仿真图像选择数据集中的第一帧（图 3.12 a）和第十三帧（图 3.12 b）进行仿照对比实验。




(a) 第一帧

(b) 第十三帧


图 3.12 原始图像



(a) 直接法特征点检测



(b) ORB 特征点检测与匹配



(c) SuperPoint 特征点检测与匹配

图 3.13 实验结果

本文对 SuperPoint 特征提取和匹配算法的性能进行了详细分析，如实验结果所示 SuperPoint 算法检测到了大量特征点，而直接法和 ORB 算法检测到的特征点数量相对较少。从匹配质量上来看，直接法的特征点匹配效果最差，ORB 算法的匹配效果相比于直接法有了较大的提升，但是仍存在一定数量的错误匹配，这种情况可能是由于 ORB 算法对图像噪声较为敏感，以及在纹理较少或光照变化较大的区域难以准确匹配特征点。而 SuperPoint 算法在特征匹配上具有更高的准确性，SuperPoint 算法通过深度学习提取特征，能够更好地处理光照变化和动态场景，从而减少错误匹配。

所以 SuperPoint 算法能够在不同光照条件下稳定地提取特征点，且特征点的检测精度和匹配精度均优于传统特征提取方法 ORB 和直接法。在光照变化较大的场景中，SuperPoint 的特征点匹配成功率比传统方法更高，这主要得益于 SuperPoint 的深度学习网络结构和自监督学习策略，使其能够更好地应对光照变化等复杂情况。

表 3.1 算法结果对比

算法	总匹配对数	正确匹配对数	正确率
直接法	112	54	48%
ORB	204	130	64%
SuperPoint	359	290	81%




图 3.14 回环检测对比实验

图 3.14 展示了在同步定位与建图过程中，引入回环检测和没有引入回环检测的轨迹对比结果，左图为没有引入基于视觉模板的回环检测的 SLAM 系统生成的轨迹，轨迹中存在明显的漂移和累积误差，导致轨迹线条在空间中出现偏移和扭曲。由于缺乏回环检测，系统无法识别和利用已知环境信息来校正自身的位置和方向，从而导致随着时间的推移，误差逐渐累积，这种累积误差可能会严重影响地图的准确性和机器人的导航性能，特别是在长时间或大面积的探索任务中。右图为引入基于视觉模板的回环检测的 SLAM 系统生成的轨迹，轨迹更加平滑和准确，显示出系统能够更好地维持一致性和准确性。引入回环检测使得系统能够在识别出已访问区域时，利用这些信息

来校正和优化其位置估计，从而减少累积误差，这种校正机制显著提高了地图的精度和可靠性，使得机器人能够在复杂环境中进行更有效的导航和探索。引入回环检测的 SLAM 系统在处理长时间或大面积的探索任务时，能够提供更准确和可靠的地图，这对于机器人在未知环境中的自主导航至关重要。

3.7 本章小结

本章主要介绍了基于 SuperPoint 改进的 NeuroSLAM 算法及其关键模块的设计与实现。首先，回顾了传统 NeuroSLAM 在特征提取与匹配上的不足，并指出如何通过引入 SuperPoint 特征提取方法来提高系统在光照变化、视角变换及动态环境下的鲁棒性和定位精度。然后，详细阐述了 NeuroSLAM 系统的类脑导航框架，包括局部视图线索、三维自运动线索与由位置细胞、头朝向细胞及网格细胞构成的核心神经网络模块，以及如何通过这些模块协同构建三维经验地图。

重点解析了 SuperPoint 的网络结构设计、特征点检测与描述子计算流程，以及采用自监督学习和 Homographic Adaptation 等策略进行综合预训练，从而显著降低对人工标注数据的依赖。此外，还介绍了基于 SuperGlue 的特征匹配算法和利用对极几何及 PnP 方法进行三维位姿解算的技术细节。最后，通过类脑导航轨迹地图的编码、创建、更新以及回环检测机制，展示了系统在长期导航任务中保持准确定位和地图校正的能力。总体而言，本章为后续系统在复杂环境下的高效自主导航提供了坚实的理论和技术基础。

第4章 基于三维高斯溅射的三维重建

4.1 引言

近年来，随着计算机视觉等领域的快速发展，三维重建技术已成为研究与应用中的一个重要方向。传统的三维重建方法在场景表示、渲染效率和细节恢复等方面，通常面临较大的计算负担、存储浪费以及效果不尽如人意等问题。为了解决这些挑战，研究人员不断探索新的三维场景表示方法，其中基于三维高斯溅射的重建技术由于其高效和高质量的表现，逐渐引起了越来越多的关注。

三维高斯溅射技术利用三维高斯分布作为基本单位对场景进行建模，通过对各个高斯分布的参数（如位置、尺度、颜色及透明度）进行估计和优化，在可以保留细节信息的同时实现对复杂场景的高效渲染。与体素、点云或多边形网格方法相比，高斯溅射不仅在内存占用和计算速度上具有优势，还能够更好地处理光照、材质等问题，从而在真实感和渲染质量上取得显著提升。

本章的主要内容围绕基于三维高斯溅射的三维重建展开，旨在深入探索其核心原理和算法优化策略，通过系统性地剖析三维高斯溅射在三维重建过程中的优势与不足，针对性地提出改进方案，进一步提升重建效率。

4.2 三维高斯重建框架

三维高斯溅射（3D Gaussian Splatting, 3DGS）方法^[49-51]通过将隐式表达与显式表达相结合，实现了高效的视角合成。该方法使用大量椭球状的三维高斯分布显式地表达场景的空间结构，同时通过优化三维高斯参数和球谐系数（Spherical Harmonics, SH）隐式地优化场景的几何结构和颜色特征。它兼具明确的场景表达能力和可微分的快速渲染能力，从而实现了高效训练与实时高质量渲染，展现出极大的应用潜力。

三维高斯重建的整体流程：接收一组静态场景图像和经过结构从运动（Structure from Motion, SfM）技术校准的相机变换作为输入，这个过程会生成一个稀疏的点云。从 SfM 生成的稀疏点云开始，将每个点初始化为一个三维高斯分布，每个分布由描述其空间位置的均值、描述其形状和方向的协方差矩阵，以及控制其在场景中可见度的不透明度参数定义，而场景的颜色和外观通过球谐函数来表达。所有的这些参数都可以进行学习，并在训练过程中不断被优化以获得更加准确的表达，流程图如图 4.1 所示。




图 4.1 3DGS 流程图

为了加快训练过程 3DGS 实现了一种可微分的快速光栅化算法，通过将图像划分为 16×16 的瓦片，并确定每个三维高斯投影到哪些瓦片上。由于三维高斯的大小不同，它可能会投影到多个瓦片。为了提高并行计算效率，算法在不同瓦片上为三维高斯创建副本，并根据高斯中心点到相机位置的深度距离进行排序，从而确定渲染计算的顺序。并且 3DGS 采用了高度并行化的渲染过程，将瓦片和像素的组合类比为 CUDA 中的线程块(block)和线程(thread)，实现了图像分块和多线程并行计算。此外，由于三维高斯投影排序结果在每个 block 的每个 thread 间共享，所以每个像素可以独立并行计算其像素值，显著提升了渲染效率。

在完成前向渲染后，3DGS 通过 L_1 损失和 L_{D-SSIM} 的加权组合来评估渲染图像与参考图像之间的误差，并通过反向传播优化三维高斯分布的各项参数，逐步逼近真实的渲染结果。同时，3DGS 采用自适应密度控制算法，对场景中三维高斯分布点进行优化。通过克隆和分裂的操作，对于欠重建部分通过克隆来增加新的高斯分布，对于过度重建部分通过分裂将其分成更小的高斯分布以更好地表示细节，从而提高建模质量和细节，实现更高质量的场景建模。

4.3 三维高斯分布和球谐函数

4.3.1 三维高斯分布

将三维环境表示为一组离散的三维高斯点，以此实现可微的体渲染过程，使得渲染过程和后续的计算过程可以与机器学习相结合，来调整和优化场景的表示。这些三维高斯点云在空间中彼此独立，每个点的贡献可以通过一个高斯函数来表示，其数学

表达式:

$$G(x) = \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right) \quad (4-1)$$

其中, 每个三维高斯函数都定义了其中心位置 μ 和协方差矩阵 Σ 。此外, 每个高斯点 $\mathbf{P}$ 除了包含位置信息外, 还额外包含透明度数据 o 以及一个颜色值 c , 这些属性被用于模拟真实的三维环境。由于镜面反射和高光效应会导致颜色随视角发生变化, 因此采用球谐函数来建模这种视角依赖的颜色变化关系。为确保协方差矩阵在优化过程中始终保持半正定性质, 使用了一种更直观且具有相同表达能力的替代方法来进行参数优化:

$$\Sigma = R S S^T R^T \quad (4-2)$$

其中 R 表示旋转矩阵, S 表示缩放矩阵, 而三维高斯的协方差矩阵在物理意义上就类似于椭球体的形状。

在渲染阶段, 关键在于实现可微渲染的优化操作, 其核心思路是基于物体的前后顺序进行处理。具体而言, 首先利用相机参数将场景中的三维高斯点投影到图像平面上, 得到一组对应的二维高斯表示。接着, 通过对这些二维高斯进行叠加与融合, 最终生成渲染图像。但将三维高斯分布精准地映射到二维平面是一项复杂而具有挑战性的任务。采用椭圆加权平均 (Elliptical Weighted Average, EWA) 方法来模拟三维高斯函数在二维平面上的投影过程。这种方法可以有效地处理从三维到二维的映射问题, 使得高斯分布的投影更加精确。三维高斯分布从三维到二维的映射公式如下:

$$\Sigma' = J W \Sigma W^T J^T \quad (4-3)$$

其中, J 和 W 分别表示透视投影的仿射近似雅可比矩阵与视角变换矩阵。

在每个像素位置, 通常有 N 个二维高斯分布共同决定其颜色值。根据视觉成像的基本原理, 靠近相机的物体会遮挡距离较远的物体。在进行体积渲染时, 为了准确再现遮挡关系, 需要根据物体的深度从近到远排序这 N 个二维高斯函数, 并依此顺序计算其透明度叠加效果, 进而合成最终的像素颜色:

$$C = \sum_{i \in N} T_i \alpha_i c_i \quad \text{with} \quad \prod_{j=1}^{i-1} (1 - \alpha_j) \quad (4-4)$$

其中, α_i 是通过高斯点的不透明度 o 和其二维分布计算得到, c_i 表示三维高斯分布中由球谐系数表示的颜色。在进行反向传播时, 模型通过对比生成图像与真实观测图像之间的差异来计算误差。为了精确衡量这种偏差, 通常选用最小绝对误差 (L_1) 与结构相似性指数损失 (L_{D-SSIM}) 的加权融合方式进行计算, λ 为权重参数:

$$L = (1 - \lambda)L_1 + \lambda L_{D-SSIM} \quad (4-5)$$

接着，利用反向传播算法计算梯度信息，并基于此对三维高斯点云中每个点的相关参数进行优化更新，最终逐步完成整个三维场景的重建任务。

4.3.2 球谐函数

球谐函数是一组定义在球面上的基函数^[64]，可用于近似表示真实物体的形状，阶数决定了正交基的数量，阶数越高，拟合效果越好。球谐函数能够实现紧凑的球面坐标编码，具有旋转不变性和各向异性，可用于表达不同观察方向下的颜色特征。在 PlenOctrees 中，球谐函数首次被引入视角合成领域。3DGS 延续了这一编码方式，默认采用 4 阶球谐函数，共包含 16 个球谐系数，由于 RGB 三个通道各需一组球谐基，因此每个三维高斯共包含 48 个颜色系数。

对于场景空间中的任意点，其颜色与观察它的角度有关，假如给定相机的观察角度 $d(\theta, \varphi)$ ，那么这一组 k 阶的球谐基在该观察角度所表达的颜色值公式为：

$$\mathbf{c}(d(\theta, \varphi); k) = \text{sigmod} \left(\sum_{\ell=0}^{\ell_{\max}} \sum_{m=-\ell}^{\ell} K_{\ell}^m Y_{\ell}^m(\mathbf{d}) \right) \quad (4-6)$$

式中包括用于标准化颜色的 sigmod 函数， K_{ℓ}^m 表示阶数为 ℓ 的第 m 个球谐基的系数， Y_{ℓ}^m 表示阶数为 ℓ 的第 m 个球谐基，计算公式如下：

$$K_{\ell}^m = \sqrt{\frac{2\ell+1}{4\pi} \cdot \frac{(\ell-|m|)!}{(\ell+|m|)!}} \quad (4-7)$$

$$Y_{\ell}^m(\theta, \varphi) = \begin{cases} \sqrt{2} K_{\ell}^m \cos(m\varphi) P_{\ell}^m(\cos \theta) & (m > 0) \\ \sqrt{2} K_{\ell}^m \sin(-m\varphi) P_{\ell}^{-m}(\cos \theta) & (m < 0) \\ K_{\ell}^0 P_{\ell}^0(\cos \theta) & (m = 0) \end{cases} \quad (4-8)$$

其中 P_{ℓ}^m 表示勒让德多项式。

4.4 自适应密度控制

在 3DGS 方法中，为了初始化三维高斯点云，通常采用两种策略：一种是完全随机生成初始点集，另一种则是利用结构光或运动恢复（SfM）技术获得的稀疏点云作为基础数据。本论文对初始点云进行离散点的去除和去除过于密集的点来优化初始点云，以便提高模型的训练速度和质量。离散点指的是点云中与大多数点相距较远的孤立点。这些点会干扰模型的拟合过程，需要通过一定的规则或算法来识别和去除。本文使用 z-score 方法来检测并移除距离过远的离散点。

$$z = \frac{X - \mu}{\sigma} \quad (4-9)$$

其中, X 是点的坐标, μ 是点云的均值, σ 是点云的标准差。当 $|z| > 4$ 时, 该点被认为是离散点。

过于密集的点云可能导致模型训练时的冗余信息, 从而增加训练时间, 并影响建模的精度。对点云进行降采样可以有效减少冗余点, 同时保留整体结构。采用体素网格降采样的方法, 将点云映射到三维空间的网格中, 每个体素格子只保留一个代表点。通常, 代表点是落在该体素中的所有点的质心或均值点。

$$P_{\text{downsampled}} = \frac{1}{N} \sum_{i=1}^N p_i \quad (4-10)$$

其中, $P_{\text{downsampled}}$ 是一个体素格子的代表点, p_i 是落入该体素格子的第 i 个点, N 是体素中的点数。每个体素只保留一个这样的代表点。

三维高斯点的数量直接决定了渲染结果的质量。尽管可微渲染管道可以不断优化点云的各项参数, 但仅依赖这一方式仍难以达到现阶段对高质量渲染的要求。因此, 另一个至关重要的因素是对三维高斯点云密度的自适应调节机制如图 4.2 所示。




图 4.2 自适应密度控制

从 SfM 估计的初始稀疏点开始, 每 100 次迭代, 删除透明的高斯分布 (即三维高斯点云的透明度小于给定阈值)。当渲染图像的某些区域与实际观测图像存在较大差异时, 这些区域就会被优先考虑用于增加点云密度。具体来说, 通过分析图像平面中二维高斯点位置的平均梯度变化, 可以判断哪些高斯点需要进行密度增强处理, 从而提高重建的精度和细节表现。该方法不仅关注几何信息不足的区域 (即“欠重建”), 也会关注高斯分布覆盖范围过大的区域 (即“过度重建”)。这两类区域通常具有显著的空间位置梯度。从直观角度来看, 这是因为这些区域尚未被有效重建, 优化过程试图通过调整高斯分布的位置来修正这些问题。

对于处于重建不足区域的小尺寸高斯点, 可通过克隆的方式进行密度增强: 直接复制一个大小相同的高斯, 并沿其位置梯度方向进行平移。而在覆盖范围过大的区域, 对于较大的高斯点, 这时, 需要将原有的高斯点分解为两个更小的高斯点, 并将它们的尺度按一个因子 (1.6) 进行缩小, 以替代原先的高斯点。在第一种情形中, 系

统的总体积与高斯点的数量都会增加；而在第二种情形下，虽然高斯数量有所上升，但整体体积保持不变。与其他体积表示方式类似，优化过程可能会受到靠近摄像机的漂浮物影响，从而引发高斯密度异常增大的问题。为合理控制高斯数量增长，可采用一种有效策略：每经过 3000 次迭代，将透明度设置为接近于零。高斯分布在优化过程中可能会发生缩小或扩展，并与其他分布产生较大程度的重叠。为有效控制整体高斯数量，可定期移除体积过大的高斯分布，以及那些在空间中重叠程度较高的分布，从而维持点云结构的合理性和稀疏性。

4.5 可微分的快速光栅化

与 NeRF 的体渲染技术不同，3DGS 采用了一种基于瓦片的快速光栅化方法，以提高渲染效率^[65]。由于三维高斯数量庞大，射线采样方法难以满足实时渲染需求。因此，3DGS 设计了一种高效的渲染流程，通过对投影到瓦片上的 3D 高斯进行预排序，并将其直接分配给投影像素，从而避免了每个像素单独排序的开销如图 4.3 所示。这一过程完全可微，支持在任意数量的混合高斯中进行反向传播，同时内存消耗也较低。目标是实现快速整体渲染和高效的排序方法，以便在不牺牲渲染质量的前提下，处理各向异性的三维高斯并避免方法中对能接收梯度更新的三维高斯数量的限制。




图 4.3 三维高斯投影

在渲染流程中，首先对屏幕进行分割，将其划分为 16×16 的瓦片，这是实现高效渲染的关键第一步。接着，执行三维高斯剔除，这一步骤中，仅保留那些与视锥相交概率达到 99% 的三维高斯，确保了渲染过程中的高效率和高覆盖率。随后，对高斯进行实例化和排序。根据高斯点与图像瓦片之间的重叠数量，对高斯点进行实例化，并为每个实例分配一个包含视角空间深度与对应瓦片编号的键值。随后，采用高效的 GPU 基数排序算法对所有实例进行排序，为后续的渲染操作提供有序数据支持。

在高效渲染阶段，为了避免了每个像素排序的额外开销，转而采用基于瓦片初始排序的混合，这显著提升了渲染效率。在渲染细节处理过程中，光栅化器按深度顺序

对每个像素涉及的已排序高斯点逐一遍历，从近到远累积其颜色与透明度信息，以实现快速高效的数据访问与处理。当某一像素的不透明度达到预设的阈值时，系统便终止对该像素的后续处理操作，从而提高渲染效率。这种方法为处理具有任意深度复杂度的场景提供了可能。通过这种方法，不仅提高了渲染和训练的性能，而且避免了在渲染高质量场景时产生可见的伪影。这种高效的光栅化技术为实时渲染和训练提供了强有力的支持，并且在处理复杂场景时更加灵活和准确。

4.6 仿真实验分析

本节实验采用了 TUM 数据集进行仿真验证。TUM 数据集由德国慕尼黑工业大学（Technical University of Munich）发布，广泛用于 SLAM 领域的研究工作。该数据集整合了多种类型的传感器信息，包括摄像头图像、激光雷达数据及惯性测量单元（IMU）信息，涵盖室内外多种场景，提供了高质量的 RGB-D 图像序列以及对应的相机姿态数据。TUM 数据集在三维重建、相机运动估计等方面具有广泛应用，其下设多个子数据集以适配不同的研究任务，例如测试集、手持采集、机器人采集、低纹理与结构对比、动态场景、物体重建、验证集及标定数据等，每类数据中又细分为多个场景数据，便于对各类算法性能进行全面评估。此外，该数据集提供了相机在四种不同运动模式（xyz、rpy、halfsphere 和 static）下的轨迹记录，以及两种动态状态（sitting 和 walking）对应的场景。本研究所用实验数据来源于该数据集中的 rgbd_dataset_freiburg1_xyz 子集，图 4.4 展示了该子集在实际采集过程中的部分场景：



图 4.4 原始图像

为全面评估三维高斯重建与传统稀疏、稠密重建方法的性能和表现差异，本实验对 rgbd_dataset_freiburg1_xyz 数据分别进行了稀疏点云重建、稠密点云重建和三维高斯重建。并从可视化效果、点云密度、几何连续性、纹理保真度和重建时间多个方面进行对比实验分析，各种三维重建效果如图 4.5 实验结果所示：




图 4.5 实验结果

从实验结果上可以看出稀疏点云仅能还原关键结构轮廓，对于细节和连续表面建模效果较差；稠密点云则能较完整地恢复场景形状，但由于受限于深度图分辨率和体素大小，重建表面通常显得粗糙；而 3DGS 通过高斯参数建模连续空间结构，有效缓解了表面跳变的问题，表现出更高的几何连续性。在纹理细节方面，稠密重建虽然结合了 RGB 图像信息，但纹理细节依旧依赖深度图的精度；相比之下，3DGS 在重建过程中对颜色纹理表达部分使用了球谐函数方法，在保留纹理细节方面明显优于前两者，能够呈现出更自然的图像感。在点云密度方面，稀疏重建仅在关键帧处产生离散特征点，密度远低于其他方法；稠密重建在场景各处均生成点，但存在冗余问题；3DGS 的高斯点分布随优化自适应变化，既可实现密集覆盖，又能在保持效率的同时减少无效点。在重建时间方面，稀疏重建耗时最短，但牺牲了重建质量；稠密重建计算量较大，尤其在全体素融合时资源开销明显；3DGS 虽在训练阶段耗时相对较长，但一次训练可用于多视角渲染，适合后续可视化任务。通过对比可以看出，3DGS 在几何表达、纹理保真度与点云密度方面均优于传统方法，尤其适用于对视觉质量要求较高的场景。

表 4.1 实验结果分析

算法	可视化效果	点云密度	几何连续性	纹理保真度	重建时间
稀疏点云	特征点离散、结构不完整	低	差	差	2min
稠密点云	空间填充较完整，但表面粗糙	中	一般	中	18min
3DGS	表面连续性高、纹理精细	高	好	优	23min

4.7 本章小结

本章围绕基于三维高斯溅射的三维重建展开研究，系统介绍了 3DGS 的核心原理、建模方法、优化策略以及高效的渲染技术。首先，分析了三维高斯溅射的建模流程，包括从 SfM 生成初始点云，并基于三维高斯分布对场景进行显式建模，同时利用球谐函数优化场景的几何和颜色信息。通过可微分的光栅化技术实现高效训练和实时渲染，探讨了自适应密度控制策略，通过动态调整高斯点的数量，优化场景的表示能力。具体而言，通过克隆提高欠重建区域的高斯密度，通过分裂减少过拟合区域的高斯密度，以提升重建质量。最后，详细介绍了可微的快速光栅化技术，采用基于瓦片的排序机制来优化渲染流程，避免逐像素排序的计算负担。通过 GPU 基数排序和并行计算，提高了渲染效率，使得 3DGS 能够在保证渲染质量的同时，实现实时、高效的三维重建。

第5章 类脑同步定位与三维重建实验分析

5.1 引言

为了验证第三和第四章提出的类脑同步定位与三维高斯重建方法的有效性与优势,本章设计了多个仿真实验。实验主要通过对比分析,展示本文方法在复杂环境中的定位精度、三维重建效果及实时性等方面的优越性。本章首先进行了基于 SuperPoint 改进的 NeuroSLAM 算法的真实室内场景实验与真实户外场景实验。接下来,在两个数据集上对 IMU、传统 NeuroSLAM 算法和基于 SuperPoint 改进的 NeuroSLAM 算法进行了仿真对比,进一步验证了提出的类脑同步定位算法在定位精度上的显著提升。最后,通过在两个数据集上进行三维高斯重建实验,展示了该重建方法在复杂大场景中的应用效果与性能表现。

5.2 改进的类脑导航算法实验

5.2.1 仿真实验介绍

在本节中,通过真实场景下的履带式机器人实车实验以及相应的仿真实验,对基于 SuperPoint 改进的 NeuroSLAM 算法进行了系统且全面的验证。实验结果充分证明了在第三章中所提出算法在复杂环境下具备较高的定位精度和稳定性,体现出良好的有效性与鲁棒性。为确保实验结果的科学性、公正性和可比性,所有对比实验均在相同的仿真平台与统一的参数设置下进行,以最大限度地消除系统误差和外部干扰对算法性能评价的影响。本次实验共使用了两个数据集,其中一个来源于真实停车场场景采集,另一个来自公开的 KITTI 数据集。

第一个数据集由履带式机器人在实际停车场环境中完成采集,实验区域设定在一块长方形平面区域内,尺寸约为 8 米 $\times$ 10 米。履带式机器人如图 5.1 所示,其搭载了 Intel RealSense D435i 深度相机作为主要视觉传感器,具体设备如图 5.2 所示。该相机具备同步获取 RGB 图像与深度信息的能力,同时内置 IMU,可为后续对比试验提供对比数据。在数据采集过程中,机器人以约定轨迹在停车场内缓慢移动,相机以 30 帧/秒的频率连续采集图像数据,图像分辨率为 640 $\times$ 480,共采集图像 5610 张,部分实际采集的停车场图像如图 5.3 所示。



图 5.1 履带式机器人



图 5.2 D435i 相机



图 5.3 停车场实验场景

另一个是 KITTI 数据集，由德国卡尔斯鲁厄理工学院与丰田美国技术研究院联合发布。使用了该数据集中的 2011_09_26_drive_0009 部分，包含 447 张图像，图像分辨率为 1242×375 ，部分实验场景如图 5.4 所示。



图 5.4 2011_09_26_drive_0009 数据集

基于 SuperPoint 优化的 NeuroSLAM 系统的整体表现在很大程度上取决于多个核心

模块的参数调整,包括局部视图细胞、三维位置细胞、三维网格细胞和多层头朝向细胞等模块。同时,回环检测和修正机制对提高系统定位精度也至关重要。能量注入强度以及导航细胞连接的抑制水平,都会直接影响吸引子网络的稳定性,从而对最终的定位结果产生显著影响。因此,为了确保系统具备高精度和稳定性,需要在参数调节与网络结构设计之间实现良好的平衡与协调。

为了保证系统的稳定性,本章节的实验中,我们对三维网格细胞、多层头朝向细胞以及三维位置细胞的各项参数进行了仔细调整和配置。具体的参数设置详见表 5.1、表 5.2 和表 5.3。表中 n_x, n_y, n_z 分别表示位置和网格导航细胞在 x, y, z 三个方向的表示范围, n_θ, n_h 分别为多层头朝向细胞的航向角表示范围和高度表示范围,细胞大小定义了每个细胞单元的物理尺寸。 N_{excit} 和 N_{inhib} 分别设定了兴奋和抑制的控制范围, $E_{var}(x, y, z)$ 和 $I_{var}(x, y, z)$ 分别为兴奋和抑制连接的方差值, φ 为全局抑制的常值, δ 为回环检测所提供能量的大小。

表 5.1 三维位置细胞

参数	数值
n_x, n_y, n_z	36*36*36
细胞大小	1*1*1m
N_{excit}	8*8*8 细胞
N_{inhib}	6*6*6 细胞
$E_{var}(x, y, z)$	2, 2, 2
$I_{var}(x, y, z)$	2.5, 2.5, 2.5
φ	0.0004
δ	0.1

表 5.2 三维网格细胞

参数	数值
n_x, n_y, n_z	36*36*36
细胞大小	1*1*1m
N_{excit}	7*7*7 细胞
N_{inhib}	5*5*5 细胞
$E_{var}(x, y, z)$	1.5, 1.5, 1.5
$I_{var}(x, y, z)$	2, 2, 2
φ	0.0002
δ	0.1

表 5.3 多层头朝向细胞

参数	数值
n_θ, n_h	36*36
细胞大小	10deg*1m
N_{excit}	8*8 细胞
N_{inhib}	5*5 细胞
$E_{var}(\theta, h)$	1.9, 1.9
$I_{var}(\theta, h)$	3.0, 3.0
φ	0.0002
δ	0.001

此外，局部视图细胞的参数如表 5.4 所示。其中 d_m 为了调节视觉模板匹配的强度，阈值的设定至关重要。如果阈值过高，可能会导致过多的虚假匹配；而若阈值过低，则会减弱相似图像之间的关联性，进而使系统难以有效进行回环检测与修正。参数 S_x 和 S_y 定义了匹配过程中允许的 x 、 y 像素误差范围，而参数 vt_{step} 则表示同步定位系统进行图像输入时每隔多少帧输入一张图片。

表 5.4 局部视图细胞

参数	数值
d_m	0.15
S_x	5 像素
S_y	3 像素
vt_{step}	1 帧

在回环检测与位姿校正过程中，为了提升三维经验地图的构建精度，同样需要合理的设置经验地图相关参数，相关参数如表 5.5 所示。其中，阈值 S_{max} 用于控制回环校准中经验的生成，而参数 η 则表示回环校正的修正率，直接影响回环校正的稳定性。

表 5.5 经验地图相关参数

参数	数值
S_{max}	40
η	0.5

为了准确评估基于 SuperPoint 改进的 NeuroSLAM 算法生成的经验地图的精度，采用均方根误差（RMSE）作为主要评价指标。由于算法生成的轨迹节点数与真实轨迹的节点数可能不同，无法直接对比两条轨迹在同一时间点的位置，因此需要采取额外的步骤来确保算法轨迹与真实轨迹的准确对应。具体过程如下：首先，选择 1 号关键位置作为起点。然后，按照顺时针方向选择若干关键位置，并计算每个关键位置周围五帧数据的平均值。最后，通过计算每组关键位置平均值与实际轨迹之间的绝对误差，

从而更加精确地评估算法生成的地图精度。

绝对轨迹误差公式如下，其中 Δp_i 表示位置的差值， n 为关键点个数。

$$RMSE = \left(\frac{1}{n} \sum_{i=1}^n (\Delta p_i)^2 \right)^{\frac{1}{2}} \quad (5-1)$$

5.2.2 仿真实验结果

图 5.5 是在三维空间中三维位置细胞放电模式的实验结果，其中蓝色区域标识了细胞在特定位置的活跃放电现象。这些结果揭示了三维位置细胞能够根据不同的空间位置产生特定的放电模式，从而提供精确的空间定位信息。




图 5.5 三维位置细胞放电

图 5.6 展示了多层头朝向细胞的放电模式。第一行展示了运动主体在水平面上移动时，多层头朝向细胞的反应情况；第二行则展示了运动主体在上下坡时，细胞的活动变化情况。




图 5.6 多层头朝向细胞

基于 SuperPoint 改进的 NeuroSLAM 算法所生成的经验地图是一种简化的拓扑结构，主要展示地图元素之间的关系。该地图由点和连接线构成，具有较高的抽象性，能够有效减少资源占用，便于存储，并且适用于路径规划。由于其计算复杂度较低，具有较好的实用性。




图 5.7 停车场跑车实验轨迹对比

在轨迹图中，真实轨迹用红色曲线表示，IMU 估计轨迹则用绿色曲线标示，NeuroSLAM 估计的轨迹则用紫色曲线呈现，而蓝色曲线则是改进后的 NeuroSLAM 生成的轨迹。根据图 5.7 的实验结果，IMU 估计的轨迹与真实轨迹之间存在较大的偏差，而 NeuroSLAM 算法生成的轨迹与真实轨迹整体保持了较好的匹配，尤其在直线行驶时表现较为准确。然而，在转弯区域，存在一定的误差。改进后的 NeuroSLAM 算法在转弯区域的轨迹偏差有所减少，展现出了更好的鲁棒性和可靠性。




图 5.8 2011_09_26_drive_0009 轨迹对比

如图 5.8 在 2011_09_26_drive_0009 数据集上的轨迹对比实验结果所示，改进后的 NeuroSLAM 算法在转弯区域和直线行驶部分的精度和鲁棒性略有提升。

实验中关键位置的选择如图 5.9、5.10 所示。




图 5.9 停车场跑车实验关键位置




图 5.10 2011_09_26_drive_0009 关键位置

为了验证各种算法生成轨迹的准确性，分别对各种算法得到的轨迹与实际地面真值轨迹之间通过在每个关键点上进行绝对轨迹误差计算，来评价各种算法的性能。

表 5.6 停车场跑车实验关键位置的均方根误差

关键点序号	RMSE (m)		
	IMU	NeuroSLAM	本文方法
1	0.8533	0.2904	0.2785
2	1.1970	0.4038	0.2452
3	1.1776	0.7621	0.3762
4	0.4308	0.5951	0.1677
5	1.4789	0.7842	0.3004
6	1.4299	0.1068	0.1083
7	0.8890	0.0772	0.0647
8	0.8409	0.1534	0.3248

表 5.7 2011_09_26_drive_0009 关键位置的均方根误差

关键点序号	RMSE (m)		
	IMU	NeuroSLAM	本文方法
1	2.58	1.35	0.75
2	4.11	1.76	1.11
3	0.39	0.29	0.13
4	1.90	1.08	0.72
5	5.14	2.90	1.77
6	8.25	4.76	3.11

根据表 5.6 和表 5.7 可以计算得到各种算法生成的轨迹在两个数据集下的均方根误差，如表 5.8 所示。在两种数据集下，IMU 生成的轨迹误差最大，改进后的 NeuroSLAM 算法相较于 IMU 和原始 NeuroSLAM 算法都展现出了更低的 RMSE，改进后的 NeuroSLAM 算法定位误差为 0.2547m 和 1.59m，相比于 NeuroSLAM 算法降低了 46.87%和 36.14%。因此所提出的类脑同步定位算法具有良好的定位精度。

表 5.8 两种数据集下的均方根误差

实验数据	RMSE (m)		
	IMU	NeuroSLAM	本文方法
停车场跑车实验	1.0876	0.4794	0.2547
2011_09_26_drive_0009	4.51	2.49	1.59

5.3 三维高斯重建结果

为了验证三维重建算法的有效性，使用了 5.2 章节中所提到的两个数据集进行三维重建实验。在数据预处理部分通过第三章的特征提取和特征匹配，来生成初始的稀疏点云集和位姿估计，用于进行三维高斯重建实验。

在实验的硬件部分，为确保实验的公平性，所有实验均在相同的处理器配置下进行，并采用单张 4060Ti 显卡开展训练工作，具体的硬件及软件配置详情见表 5.9。

表 5.9 实验软件、硬件配置

软件、硬件	参数配置
处理器	13th Gen Intel(R) Core(TM)i5-13600KF
内存	32GB
显卡	NVIDIA GeForce RTX 4060 Ti
显存	8GB
操作系统	Windows11
模型框架	Pytorch 1.21.1+cuda11.6

在本章节实验中，训练过程的最大迭代次数被设定为 30000 次，并且模型会在第 7000 次和第 30000 次迭代时被保存，以便后续进行可视化展示和进一步的训练。输入图像的分辨率维持在原始尺寸，且在训练阶段未对图像执行任何下采样操作，球谐函数的阶数设置为 4。学习率的设定与原 3DGS 方法中的配置保持一致，位置、旋转、尺度、颜色和不透明度这五种属性特征的系数分别被设置为 0.00016、0.001、0.005、0.0025 和 0.05，优化器选择了 Adam 算法。三维高斯点云的自适应密度调节机制被配置为每 100 次迭代进行一次密度调整，直到第 15000 次迭代结束。之后，训练将集中于优化三维高斯点云的属性参数。

为了更加直观地对比本文三维重建的质量，本章节对模型的重建结果分别在停车场跑车实验数据集和 2011_09_26_drive_0009 数据集上进行了可视化，如图 5.11 和 5.12 所示：



图 5.11 停车场跑车实验可视化结果对比



图 5.12 2011_09_26_drive_0009 数据集可视化结果对比

本文改进的 3DGS 算法在训练时间上表现出了显著的优势，在停车场跑车实验和 2011_09_26_drive_0009 数据集上的训练时间分别为 25min 和 32min，相比于原始 3DGS 算法的 29min 和 37min 来说，改进的 3DGS 算法的训练时间平均减少了 14%左右。尽管改进的 3DGS 算法在训练时间上有所减少，但其建模质量与原始 3DGS 算法相比并未有显著下降。通过对比两个算法在两个数据集上的三维重建结果，两者在建模质量上相差无几，改进的 3DGS 算法生成的三维模型在细节表现和整体结构上与原始 3DGS 算法相当，均能较好地捕捉场景的几何特征和光照变化。综上所述，改进的 3DGS 算法在保持与原始 3DGS 算法相近的建模质量的同时，显著减少了训练时间。这一改进主要得益于算法在初始化稀疏点云上进行了优化，这使得算法能够更高效地利用计算资源，减少不必要的计算开销。因此，改进的 3DGS 算法在实际应用中具有更高的效率和实用性，特别是在需要快速生成高质量三维模型的场景中。

5.4 本章小结

在本章通过一系列实验验证了本文所提出的类脑同步定位与三维高斯重建方法的有效性与优越性。实验结果表明，改进的 NeuroSLAM 算法和三维高斯重建算法在复杂的大场景中展现出了优异的性能。首先，对基于 SuperPoint 改进的 NeuroSLAM 算法在停车场跑车实验和 2011_09_26_drive_0009 数据集上进行了测试，该算法在定位精度上显著优于 IMU 和传统 NeuroSLAM 算法。其次，在三维高斯重建实验中，也使用两个数据集进行了测试，改进的 3DGS 算法在保持与原始 3DGS 算法相近的建模质量的同时显著减少了训练时间。

综上所述，本章所提出的类脑同步定位与三维高斯重建方法在复杂的大场景下表现出了优异的性能。改进的 NeuroSLAM 算法在定位精度和鲁棒性方面具有显著优势，而改进的 3DGS 算法则在效率和实用性方面表现出色。

结 论

本论文主要围绕类脑同步定位与 3DGS 建图展开研究，提出了一种融合类脑计算的 SLAM 系统与基于 3DGS 的高效三维重建方法，以解决传统 SLAM 在复杂环境中的鲁棒性问题，并提高三维场景重建的质量，使得系统能够在复杂的环境中实现更加精准、稳定的定位与高质量建图。高质量的三维地图能够更准确地描述场景的几何结构与纹理细节，从而提升机器人在未知环境中的自主导航能力。

受到哺乳动物大脑导航机制的启发，构建了一个类脑 SLAM 系统，模拟了导航细胞的神经生物学特性。我们建立了一个数学仿真模型，以提升系统的自主定位能力。同时，提出了一种基于 SuperPoint 改进 NeuroSLAM 的方法，通过深度学习特征点提取，提高系统在复杂环境中的鲁棒性，并结合特征点匹配和位姿估计算法，优化视觉 SLAM 的精度和稳定性。在停车场跑车实验和 2011_09_26_drive_0009 数据集上的实验结果表明，算法在定位精度上显著优于 IMU 和 NeuroSLAM 算法，相比于 NeuroSLAM 算法误差降低了 46.87% 和 36.14%。

其次，研究了基于 3DGS 的高效三维重建方法，该方法采用显式的高斯分布对场景进行建模，并利用球谐函数编码颜色信息，使得三维重建质量大幅提高，并通过快速光栅化技术加快渲染速度。此外，提出了 3DGS 的优化方法，通过对初始点云集进行离散点的去除和去除过于密集的点来优化初始点云，和在训练过程中通过自适应密度控制算法，动态的调整高斯点的分布，实现欠拟合区域的克隆和过拟合区域的分裂，以优化重建质量并减少计算开销。实验结果表明，改进的 3DGS 算法在保持与原始 3DGS 算法相近的建模质量的同时，显著减少了训练时间，平均减少了约 14% 的训练时间。

未来的研究可以从以下几个方向进行探索和深入：

- 1、算法优化：进一步优化类脑同步定位算法和 3DGS 建图算法，提高算法的计算效率和实时性，使其更适用于资源受限的移动设备。
- 2、多传感器数据融合：研究将视觉信息与其他传感器数据（如激光雷达、IMU 等）结合，旨在提升定位精度和重建的稳定性。
- 3、硬件方面：可结合类脑芯片（如 Tianjic）实现低功耗部署，增强系统在资源受限平台下的实用性。

通过持续的研究和改进，预期类脑同步定位与 3DGS 建图的方法将在智能机器人

导航和三维环境重建领域发挥更大的作用，为相关产业的发展提供有力的技术支持。

参考文献

- [1] Zhong M, Yao Y, Xu X. A Robust Parallel Initialization Method for Monocular Visual-Inertial SLAM[J]. *Sensors*, 2022, 22(21): 8307.
- [2] Mahmoud N, Cirauqui I, Hostettler A. ORBSLAM-based endoscope tracking and 3D reconstruction[C]//Computer-Assisted and Robotic Endoscopy: Third International Workshop, CARE 2016, Held in Conjunction With MICCAI 2016, Athens, Greece, October 17, 2016, Revised Selected Papers 3. Springer International Publishing, 2017: 72-83.
- [3] Ytournal F, Teyssedre S, Roldan D. LDSO: A program to simulate pedigrees and molecular information under various evolutionary forces[J]. *Journal of Animal Breeding and Genetics*, 2012, 129(5): 417-421.
- [4] Pei J, Deng L, Song S. Towards artificial general intelligence with hybrid Tianjic chip architecture[J]. *Nature*, 2019, 572(7767): 106-111.
- [5] 韩慧妍, 韩方正, 韩燮. 室内机器人动态 SLAM 技术[J]. *计算机工程与设计*, 2024, 45(2): 530-539.
- [6] 周治国, 曹江微, 邸顺帆. 3D 激光雷达 SLAM 算法综述[J]. *仪器仪表学报*, 2023 (9): 13-27.
- [7] 田野, 陈宏巍, 王法胜. 室内移动机器人的 SLAM 算法综述[J]. *计算机科学*, 2021, 48(9): 223-234.
- [8] 王文照. 优化 RatSLAM 模型的路径规划类脑导航研究[D]. 中北大学, 2023. DOI:10.27470/d.cnki.ghbgc.2023.000988.
- [9] De Araujo I E T, Rolls E T, Stringer S M. A view model which accounts for the spatial fields of hippocampal primate spatial view cells and rat place cells[J]. *Hippocampus*, 2001, 11(6): 699-706.
- [10] 彭建鑫. 基于网格细胞编码的认知地图构建方法研究[D]. 四川大学, 2021. DOI:10.27342/d.cnki.gscdu.2021.000599.
- [11] 苑云鹤. 基于鼠脑海马认知机理的机器人导航方法研究[D]. 北京工业大学, 2018.
- [12] Angelaki D E, Laurens J. The head direction cell network: attractor dynamics, integration within the navigation system, and three-dimensional properties[J]. *Current opinion in neurobiology*, 2020, 60: 136-144.

- [13] 丛明,邹强,刘冬.定位细胞认知机理启发的机器人导航研究综述[J].机械工程学报,2019,55(23):1-12.
- [14] Aylin A ,Jonas R .Avian navigation: Head direction cells in the quail hippocampus[J].Current Biology,2021,31(12):R781-R783.
- [15] Yuri D .Grid cells, border cells, and discrete complex analysis [J].Frontiers in Computational Neuroscience,2023,171242300-1242300.
- [16] Ignacio J S ,Michael B .Home, head direction stability, and grid cell distortion.[J].Journal of neurophysiology,2020,123(4):1392-1406.
- [17] 陈孟元.鼠类脑细胞导航机理的移动机器人仿生 SLAM 综述[J].智能系统学报,2018,13(01):107-117.
- [18] Milford M J, Wyeth G F. Mapping a suburb with a single camera using a biologicallyinspired SLAM system[J]. IEEE Transactions on Robotics, 2008, 24(5): 1038-1053.
- [19] A J F ,Kerim A U ,Daoyun J .Place cells dynamically refine grid cell activities to reduce error accumulation during path integration in a continuous attractor model.[J].Scientific reports,2022,12(1):21443-21443.
- [20] Wiltschko R, Wiltschko W. Pigeon homing: change in navigational strategy duringontogeny[J]. Animal Behaviour, 1985, 33(2): 583-590.
- [21] 权美香,朴松昊,李国.视觉 SLAM 综述[J].智能系统学报,2016,11(06):768-776.
- [22] Milford M J, Wyeth G F. SeqSLAM: Visual route-based navigation for sunny summer daysand stormy winter nights[C]//2012 IEEE international conference on robotics andautomation. IEEE, 2012: 1643-1649.
- [23] Kazmi S M A M, Mertsching B. Gist+ ratslam: An incremental bio-inspired place recognition front-end for ratslam[C]//Proceedings of the 9th EAI International Conference on Bio-inspired Information and Communications Technologies (formerly BIONETICS). 2016: 27-34.
- [24] Zhou S C, Yan R, Li J X. A brain-inspired SLAM system based on ORB features[J]. International Journal of Automation and Computing, 2017, 14(5): 564-575.
- [25] Chancón M, Hernandez-Nunez L, Narendra A. A hybrid compact neural architecture for visual place recognition[J]. IEEE Robotics and Automation Letters, 2020, 5(2): 993-1000.
- [26] 吴德伟,何晶,韩昆.无人作战平台认知导航及其类脑实现思想[J].空军工程大学学报

- (自然科学版),2018,19(06):33-38.
- [27] 于乃功,魏雅乾,王林.基于卷积神经网络的仿鼠脑海马结构认知地图构建方法[J].模式识别与人工智能, 2020, 33(1): 50-58.
- [28] Fangwen Y ,Jianga S ,Youjian H.NeuroSLAM: a brain-inspired SLAM system for 3D environments.[J].Biological cybernetics,2019,113(5-6):515-545.
- [29] Zeng T, Si B. A brain-inspired compact cognitive mapping system[J]. Cognitive Neurodynamics, 2021, 15: 91-101.
- [30] 边雪.基于类脑认知的机器人经验地图构建与导航[D].大连理工大学, 2022.
- [31] 郑太雄,黄帅,李永福.基于视觉的三维重建关键技术研究综述[J].自动化学报,2020,46(04):631-652.DOI:10.16383/j.aas.2017.c170502.
- [32] 佟帅,徐晓刚,易成涛.基于视觉的三维重建技术综述[J].计算机应用研究,2011,28(07):2411-2417.
- [33] 常远,盖孟.基于神经辐射场的视点合成算法综述[J].图学学报. 2021, 42(03) :376-384.
- [34] Fehn C. Depth-image-based rendering (DIBR), compression, and transmission for a new approach on 3D-TV[C]. in: Stereoscopic displays and virtual reality systems XI.SPIE, 2004: 93-104.
- [35] Debevec P E, Malik J. Recovering high dynamic range radiance maps from photographs [M]//Seminal Graphics Papers: Pushing the Boundaries, Volume 2. 2023: 643-652.
- [36] Takeda M, Ina H, Kobayashi S. Fourier-transform method of fringe-pattern analysis for computer-based topography and interferometry[J]. JOSA, 1982,72(1): 156-160.
- [37] Nishimura T ,Fujimura S ,Ito T.Measurement of 3-D Shape for Glossy Objects Using M-Array Coded Light Source[J].IEEE Transactions on Electronics, Information and Systems,2008,112(2):97-101.
- [38] Hirschmuller H. Stereo processing by semiglobal matching and mutual information[J].IEEE Transactions on pattern analysis and machine intelligence. 2007, 30(2) : 328-341.
- [39] Chaurasia G, Duchene S, Sorkine-Hornung O, Drettakis G. Depth synthesis and local warps for plausible image-based navigation[J]. ACM transactions on graphics (TOG).2013, 32(3) : 1-12.
- [40] Moulon P, Monasse P, Marlet R. Global fusion of relative motions for robust, accurate and scalable structure from motion[C]. in: Proceedings of the IEEE international conference

- on computer vision. 2013: 3248-3255.
- [41] 宁小娟,巩亮,韩怡.结合语义分割与模型匹配的室内场景重建方法[J].中国图象图形学报,2023,28(10):3149-3162.
- [42] 任飞,常青玲,刘兴林.基于点云的室内结构三维重建综述[J].计算机科学,2022,49(S2): 351-361.
- [43] Penner E, Zhang L. Soft 3d reconstruction for view synthesis[J]. ACM Transactions on Graphics (TOG). 2017, 36(6) : 1-11.
- [44] Wanjun L ,Junkai W ,Haicheng Q.Hierarchical MVSNet with cost volume separation and fusion based on U-shape feature extraction[J].Multimedia Systems,2022,29(1):377-387.
- [45] Chen R, Han S, Xu J. Point-based multi-view stereo network[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 1538-1547.
- [46] Korycki A ,Yeaton C ,Gilbert S G.NeRF-Accelerated Ecological Monitoring in Mixed-Evergreen Redwood Forest[J].Forests,2025,16(1):173-173.
- [47] 朱方.3D 场景表征—神经辐射场（NeRF）近期成果综述[J].中国传媒大学学报(自然科学版),2022,29(05):64-77.DOI:10.16196/j.cnki.issn.1673-4793.2022.05.007.
- [48] Cui D ,Wang W ,Hu W.3D reconstruction of building structures incorporating neural radiation fields and geometric constraints[J].Automation in Construction,2024,165105517-105517.
- [49] Chen L ,Hu Y ,Zhang Y.Frequency-importance gaussian splatting for real-time lightweight radiance field rendering[J].Multimedia Tools and Applications,2024,83(35):83377-83401.
- [50] Fei B, Xu J, Zhang R. 3d gaussian splatting as new era: A survey[J]. IEEE Transactions on Visualization and Computer Graphics, 2024.
- [51] Luo J ,Huang T ,Wang W.A review of recent advances in 3D Gaussian Splatting for optimization and reconstruction[J].Image and Vision Computing,2024,151105304-105304.
- [52] 苑立彬.基于 RGB-D 传感器室内场景三维重建关键技术研究[D].北京邮电大学,2019.
- [53] 雷成,吴福朝,胡占义.Kruppa 方程与摄像机自标定[J].自动化学报,2001,(05):621-630. DOI:10.16383/j.aas.2001.05.004.
- [54] 谢楠.单目视觉与激光雷达融合的巷道三维重建与掘进机定位方法[D].西安科技大学,2021.DOI:10.27397/d.cnki.gxaku.2021.000382.

- [55] Alsadik B, Karam S. The simultaneous localization and mapping (SLAM)-An overview [J]. Surv.Geospat. Eng. J, 2021, 2: 34-45.
- [56] Booij O, Terwijn B, Zivkovic Z. Navigation using an appearance based topologicalmap [C]//Proceedings 2007 IEEE International Conference on Robotics and Automation. IEE E,2007: 3927-3932.
- [57] 张彦雯,胡凯,王鹏盛.三维重建算法研究综述[J].南京信息工程大学学报(自然科学版), 2020,12(05):591-602.DOI:10.13878/j.cnki.jnuist.2020.05.009.
- [58] 喻伟东,鲁静,程晗蕾.基于 NeRF 的 SLAM 研究综述[J].计算机系统应用,2025,34(04): 18-33.DOI:10.15888/j.cnki.csa.009865.
- [59] Lin J, Li Z, Tang X. Vastgaussian: Vast 3d gaussians for large scene reconstruction[C]//P roceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2 024: 5166-5175.
- [60] 赵辰豪,吴德伟,韩昆.基于多尺度网格细胞的路径整合模型[J].系统工程与电子技术,2 021,43(10):2961-2967.
- [61] DeTone D, Malisiewicz T, Rabinovich A. Superpoint: Self-supervised interest point dete ction and description[C]//Proceedings of the IEEE conference on computer vision and pa ttern recognition workshops. 2018: 224-236.
- [62] Liu Y, Xu M, Jiang G. Target localization in local dense mapping using RGBD SLAM a nd object detection[J]. Concurrency and Computation: Practice and Experience, 2022, 34 (4): e6655.
- [63] Sarlin P E, DeTone D, Malisiewicz T. Superglue: Learning feature matching with graph neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and p attern recognition. 2020: 4938-4947.
- [64] Yu A, Li R, Tancik M, Li H, Ng R, Kanazawa A. Plenotrees for real-time renderingof n eural radiance fields[C]. in: Proceedings of the IEEE/CVF InternationalConference on C omputer Vision. 2021: 5752-5761.
- [65] Merrill D G, Grimshaw A S. Revisiting sorting for GPGPU stream architectures[C].in: Proceedings of the 19th international conference on Parallel architectures and compilation techniques. 2010: 545-546.